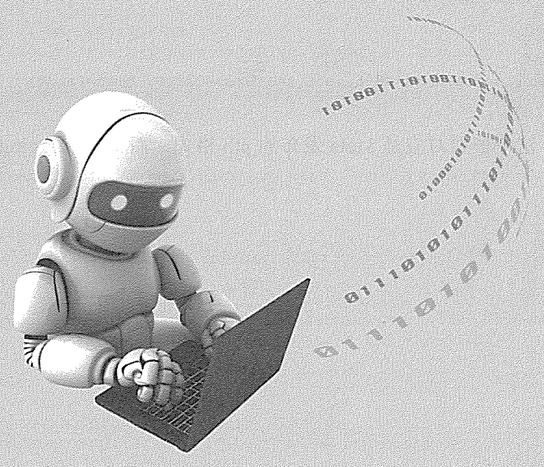
第5章

大语言模型



5.1　什么是大语言模型

目前我们关注的 GPT、Llama 都属于大语言模型。大语言模型是预训练模型的一种。

预训练模型是一种已经在大量数据集上进行了初步训练的模型。这种模型可以被用作下游任务的起点，如文本分类、命名实体识别、情感分析等。预训练模型的优点是它们可以利用在大规模数据集上学习到的知识，这样在特定任务上就不需要从零开始训练。这种方法通常被称为迁移学习。

大语言模型，如 GPT-3，相对于其他预训练模型有以下几个主要特点。

（1）更大规模的训练数据：大语言模型通常使用了更大规模的训练数据，这使它们能够理解和生成各种各样的人类语言，包括各种领域的知识、各种类型的文本，以及各种语言风格。

（2）更深的模型结构：大语言模型通常具有更深的神经网络结构，这使它们能够学习和表示更复杂的语言模式。

（3）强大的生成能力：大语言模型通常具有强大的文本生成能力，能够生成连贯、有意义的长文本。这一点与一些其他类型的预训练模型不同，比如 BERT 只能用于文本分类、实体识别等任务，而不擅长生成文本。

（4）更强的泛化能力：由于在大量数据上进行训练，大语言模型具有很强的泛化能力。这意味着它们可以在许多不同的任务和领域中表现良好，只需要少量的微调。

（5）零样本或小样本学习：大语言模型如 GPT-3，可以在没有任何微调的情况下（即零样本学习），或者只给出少量示例的情况下（即小样本学习），就完成各种任务。这是因为它们在训练过程中已经学习到了大量的背景知识和任务相关的模式。

5.2　GPT简介

最著名的大语言模型是 OpenAI 的产品 GPT 和 ChatGPT。

GPT 是基于 Transformer 架构的预训练语言模型。它通过在大规模文本数据上进行自监督学习，从而学习到丰富的语言知识和潜在的语义理解。GPT 可以用于各种自然语言处理任务，如文本生成、机器翻译、问答系统等。它的特点是能够生成连贯、有逻辑性的文本，并具备一定的理解和推理能力。

ChatGPT 是基于 GPT 系列模型的一个特定应用，专注于对话式交互。它被训练用于与用户进行对话，并生成有意义的回复。

ChatGPT 通过在大量的对话数据上进行微调，使其更好地理解对话的上下文和用户的意图，从而提供更准确和流畅的对话体验。

ChatGPT 是 GPT 系列模型的一个特定应用，它在 GPT 的基础上进行了任务特定的微调。ChatGPT 所使用的模型架构和参数设置可能与原始的 GPT 模型相同或类似，但通过在对话数据上进行微调，使其更适合于对话交互。

可以将 ChatGPT 看作是 GPT 模型在对话任务上的一种变体或扩展。它利用 GPT 模型的强大生成能力和语言理解能力，为用户提供自然、流畅的对话体验。

GPT-4 是 OpenAI 于 2023 年 3 月 14 日发布的模型，它是一种自回归语言模型。GPT-4 从各方面来说都优于 OpenAI 之前发布的 GPT-3 和 GPT-3.5。由于 OpenAI 从 GPT-3 后不再开源，