所以无从知道 GPT-4 的具体参数，目前只有 GPT-3 系列模型的改进版本 GPT-3.5 的参数。

GPT-3.5 的主要参数和架构如下。

模型规模：GPT-3.5 包含了 1 750 亿个参数，比 GPT-3 稍小，但仍然是当前最大的语言模型之一。

模型架构：GPT-3.5 采用了和 GPT-3 相同的 Transformer 架构，具有 28 个 Transformer 层和 2 048 个隐藏单元。相比较小的语言模型，GPT-3.5 的模型架构更深、更宽，可以处理更复杂的语言模式和关系。

预训练数据集：GPT-3.5 使用了数十万亿级别的文本数据进行预训练，包括来自网络、书籍、新闻、百科全书等不同来源的数据。通过利用更多的数据，模型可以学习到更广泛和多样化的语言知识。

任务特定微调：除了使用大规模的自监督学习来预训练模型外，GPT-3.5 还支持在各种任务上进行微调。例如，可以通过在特定领域的数据集上进行微调，使模型更好地适应该领域的任务和问题。

控制生成输出：GPT-3.5 还支持对生成输出进行控制，以便在不同任务和场景中生成合适的文本内容。例如，可以通过提供特定的文本提示来引导模型生成符合特定要求的文本内容，如写作风格、情感、主题等。

5.3 Llama简介

相对于不开源的 GPT-3、GPT-4，Meta 的 Llama 模型作为一种开源模型得到大家的关注，也成为大家研究大语言模型的主要对象。

Llama 模型迄今为止推出了 Llama（或称 Llama 1）和 Llama 2。本书用 Llama 统称两个版本相同的地方，用 Llama 2 指第二版特有的地方。

Llama 是基于 Transformer 的人工神经网络，以一系列单词作为输入，递归地预测下一个单词来生成文本。Llama 经过对来自 20 种不同语言的文本进行训练，包括来自 CCNet、C4、Wikipedia、arXiv 和 Stack Exchange 等公开可用的文本。

Llama 1 提供 7B、13B、33B、65B（650 亿）四个版本，参数见表 5-1。其数据集来源都是公开数据集，无任何定制数据集，保证其工作与开源兼容和可复现，整个训练数据集在标记化之后大约包含 1.4 T 的 token。Llama 的性能非常优异：具有 130 亿参数的 Llama 1 模型“在大多数基准上”可以胜过 GPT-3（参数量达 1 750 亿），而且可以在单块 V100 GPU 上运行；而最大的 650 亿参数的 Llama 1 模型可以媲美谷歌的 Chinchilla-70B 和 PaLM-540B。

表 5-1　Llama 1 模型的参数

参数	维度	头数	层数	学习率	批长度	标记数
6.7B	4096	32	32	3.00E-04	4 M	1.0 T
13.0B	5120	40	40	3.00E-04	4 M	1.0 T
32.5B	6656	52	60	1.50E-04	4 M	1.4 T
65.2B	8192	64	80	1.50E-04	4 M	1.4 T

Llama 2 是 Llama 1 的升级模型，它在多个方面进行了显著的改进。以下是 Llama 2 模型的主要特点和升级之处。

（1）模型规模：Llama 2 提供了 7B、13B 和 70B 参数三个规模的版本。与 Llama 1 相比，训练数据量增加了 40%，接受了 20 万亿个标记的训练。上下文长度是 Llama 1 的两倍，达到 4096，可以理解和生成更长的文本。

（2）模型架构：Llama 2 采用了标准的 Transformer 架构，使用 RMSNorm 进行预归一化，使用 SwiGLU 作为激活函数，以及旋转位置嵌入。其与 Llama 1 的主要架构差异包括增加了上下文长度和分组查询注意力。

（3）分组查询注意力：这是一个新的注意力机制，可以提高大模型的推理可扩展性。它的工作原理是将键和值投影在多个头之间共享，而不会大幅降低性能。

（4）超参数：使用 AdamW 优化器进行训练，其中 β_1=0.9，β_2=0.95，eps=10^{-5}。使用余弦学习率计划，预热 2 000 步，衰减最终学习率降至峰值学习率的 10%。使用 0.1 的权重衰减和 1.0 的梯度裁剪。

（5）分词器：Llama 2 使用与 Llama 1 相同的分词器；它采用字节对编码算法，使用 SentencePiece 实现。将所有数字拆分为单独的数字，并使用字节来分解未知的 UTF-8 字符。总词汇量为 32k 个 token。

（6）Llama 2-Chat：Llama 2-Chat 模型接受了超过 100 万个新的人类注释的训练，通过强化学习从人类反馈中继续提升，注重模型的安全性和帮助性。

（7）性能：在多项推理、编码、知识测试的基准上，Llama 2 的表现优于其他开源语言模型。在 MMLU（Massive Multitask Language Understanding，大规模多任务语言理解）和 GSM8K 上的表现接近 GPT-3.5，但在编码基准上存在显著差异。几乎在所有基准上，llama-2-70b 的结果都与谷歌 PaLM-540B 持平或表现更好，与 GPT-4 和 PaLM-2-L 的性能仍存在较大差距。

（8）微调：Llama 2-Chat 是数月实验研究和对齐技术迭代应用的结果，包括指令微调和 RLHF，需要大量的计算和数据标注资源。有监督微调指令数据质量非常重要，包括多样性，注重隐私安全不包含任何元用户数据。

（9）安全性：使用三个常用基准评估了 Llama 2 的安全性，针对三个关键维度：真实性，采用 TruthfulQA 基准；毒性，采用 ToxiGen 基准；偏见，采用 BOLD 基准。

（10）语言优化：Llama 2 主要针对英文优化，由于词表大小限制，直接应用于中文效果一般，需要进行中文特定的增强训练。

Llama 2 模型有多个版本，可以按三个维度区别：①参数量：7B、13B、70B；②基础模型和对话模型（chat）；③ PT 格式和 Hugging Face 格式（hf）。

最后形成多种模型，具体见表 5-2。

表 5-2　Llama 2 开源的模型名称

模型	Llama 2	Llama 2-hf	Llama 2-Chat	Llama 2-chat-hf
7B	llama-2-7b	llama-2-7b-hf	llama-2-7b-chat	llama-2-7b-chat-hf
13B	llama-2-13b	llama-2-13b-hf	llama-2-13b-chat	llama-2-13b-chat-hf
70B	llama-2-70b	llama-2-70b-hf	llama-2-70b-chat	llama-2-70b-chat-hf