5.4 Llama的训练

大语言模型在大量文本语料库上训练后，已经显示出它们能够从文本指令或少量示例中执行新的任务。这些小样本特性首次出现在将模型扩展到足够大的规模时，从而形成了一系列关注进一步扩展这些模型的工作。这些努力是基于更多参数将导致更好性能的假设。

Llama 13B 在大多数基准测试中优于 GPT-3，尽管大小只有后者的 1/10。在更高端的规模上，Llama 的 65B 参数模型也与最佳的大规模语言模型（如 Chinchilla 或 PaLM-540B）相竞争。

5.4.1 训练数据

与 Chinchilla、PaLM 或 GPT-3 不同，Llama 仅使用公开可得的数据，而大多数现有模型则依赖于不公开可得或未经记录的数据（例如“Books–2TB”或“Social Media Conversations”）。

Llama 1 预训练数据大约包含 1.4 T tokens，对于绝大部分的训练数据，在训练期间模型只见到过 1 次，Wikipedia 和 Books 这两个数据集见过 2 次。

表 5-3 所示为 Llama 1 预训练数据的含量和分布，其中包含 CommonCrawl 和 Books 等不同域的数据。

表 5-3 Llama 训练数据构成

数据集	样本比例 / %	Epochs	磁盘大小
CommonCrawl	67.00	1.1	3.3 TB
C4	15.00	1.06	783 GB
Github	4.50	0.64	328 GB
Wikipedia	4.50	2.45	83 GB
Gutenberg and Books3	4.50	2.23	85 GB
arXiv	2.50	1.06	92 GB
Stack Exchange	2.00	1.03	78 GB

English CommonCrawl：对五个 CommonCrawl 数据集进行预处理，时间跨度从 2017 年到 2020 年，使用 CCNet 流水线。该过程在行级别进行数据去重，使用 fastText 线性分类器进行语言识别，以删除非英语页面，并使用 n-gram 语言模型过滤低质量内容。此外，还训练了一个线性模型，用于将页面分类为 Wikipedia 中的引用页面与随机抽样页面，并丢弃未被分类为引用的页面。

C4：C4 的预处理还包括去重和语言识别步骤：与 CCNet 的主要区别在于质量过滤，这主要依赖于标点符号的存在或网页中的词语和句子数量等启发式方法。

Github：使用 Google BigQuery 上可用的公共 GitHub 数据集。只保留了在 Apache、BSD 和 MIT 许可下发布的项目。此外，使用基于行长度或字母数字字符比例的启发式方法过滤低质量文件，并使用正则表达式删除了诸如头文件之类的样板文件。最后，对生成的数据集进行了文件级别的去重，使用完全匹配的方法。

Wikipedia：添加了来自 2022 年 6—8 月期间的 Wikipedia 数据快照，涵盖 20 种语言。

处理数据以去除超链接、评论和其他格式样板。

Gutenberg and Books3：添加了两个书的数据集，分别是 Gutenberg 以及 ThePile（训练大语言模型的常用公开数据集）中的 Book3 部分。处理数据时执行重复数据删除，删除内容重叠超过 90% 的书籍。

arXiv：处理了 arXiv Latex 文件，以添加科学数据到数据集中。移除了第一节之前的所有内容，以及参考文献。还移除了 .tex 文件中的注释，并且内联展开了用户编写的定义和宏，以增强论文之间的一致性。

Stack Exchange：作者添加了 Stack Exchange，这是一个涵盖各种领域的高质量问题和答案网站，范围从计算机科学到化学。作者从 28 个最大的网站保留数据，从文本中删除 HTML（超文本标记语言）标签并按分数对答案进行排序。

Llama 2 的训练语料包括了一个新的公开可用数据的混合，其中不包括来自 Meta 产品或服务的数据。Meta 努力删除了来自某些已知包含大量关于私人个人信息的网站的数据。他们在 2 万亿标记的数据上进行训练，因为这提供了一个良好的性能 - 成本权衡，对最有事实性的来源进行上采样，以增加知识和减少幻觉。他们进行了各种预训练数据调查，以便用户更好地理解他们的模型的潜在能力和局限性。

5.4.2 预训练

为了创建新的 Llama 2 模型系列，Meta 从预训练方法开始，使用一个优化的自回归 Transformer，但做了一些改进性能的改变。具体来说，其进行了更强大的数据清洗，更新了其数据混合，训练了 40% 以上的 token，加倍了上下文长度，并使用分组查询注意力来提高其更大模型的推理可扩展性。

Llama 2 采用了 Llama 1 的大部分预训练设置和模型架构。

图 5-1 显示了使用这些超参数的 Llama 2 的训练损失。

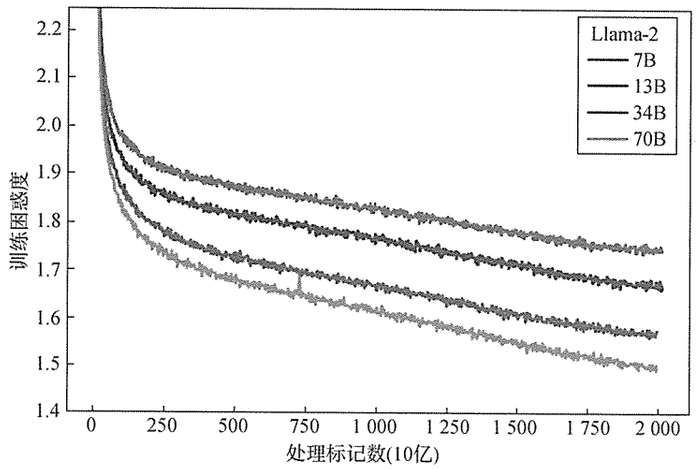


图5-1 Llama 2模型的训练损失

通过比较 Llama 2 系列模型的训练损失，可以观察到，在 2 T 标记上进行预训练后，模型仍然没有显示出任何饱和的迹象。