5.5 Llama 2 chat

Llama 2-Chat 是 Meta 在 Llama 2 模型基础上专门针对聊天进行微调的模型，其效果与 ChatGPT 相当。Llama2-Chat 开源了 7B、13B、70B 模型。

Llama 2-Chat 训练从使用公开可用的在线资源对 Llama 2 进行预训练开始。接下来，通过应用有监督微调，创建了 Llama 2-Chat 的初始版本。随后，使用人类反馈强化学习方法，具体是通过拒绝采样和近端策略优化（Proximal Policy Optimization，PPO），对模型进行迭代优化。在 RLHF 阶段，累积迭代奖励建模数据与模型改进并行，这对于确保奖励模型保持在分布内是至关重要的。

5.5.1 监督微调

监督微调是指使用一个预先训练好的模型 Llama 2，然后在新的任务或数据集上进行额外的训练。这种训练过程是有监督的，因为模型的训练是基于给定的标签或目标。这意味着通过反向传播和梯度下降等优化算法，调整模型的参数以适应新的任务。

监督微调需要构建指令数据集，数据集的质量很重要，万级别的高质量效果就很好。Meta 在训练 Llama 2-Chat 时没有使用公开的几百万指令数据集，而是找供应商精标了 27 540 条［人工撰写 prompt 和 answer，包括有用性（helpfulness）和安全性（safety）两大类］，发现效果比几百万公开的要好。但人写的数据集，质量参差不齐，需要经过仔细的质检工作。最后发现人写的数据和使用 SFT 模型采样出来的数据质量差不多，因此后续可以把更多精力投入 RLHF 的数据标注上。

训练时合并了所有 prompts 和 answers，保证序列长度是 4 096。在 prompt 和 answer 间加入特殊标记。计算损失的时候掩盖掉用户提示，只对回答标记进行反向传播。

5.5.2 基于人类反馈的强化学习

RLHF 环节的目标是使模型输出对齐人类偏好（human preferences）和遵循指令（instruction following）。

1. 收集人类偏好数据

做 RLHF 首先要收集人类偏好数据。通过收集人类偏好数据用于奖励建模，提高 Llama2-Chat 的有用性和安全性。Meta 选择了二元比较（binary comparison）协议标注样本，因为它能让我们最大化收集到的提示的多样性。

标注过程包括以下几个步骤。

（1）要求标注者写一个提示，然后根据提供的标准在两个采样的模型回应之间进行选择。

（2）Meta 还要求标注者标记他们对所选回应相对于另一种回应的偏好程度：要么他们的选择明显更好（significantly better），更好（better），稍微更好（slightly better），或者微不足道地更好 / 不确定（negligibly better/unsure）。

（3）Meta 根据不同的方面给参与者提供特定的指南。

Meta 关注有用性和安全性两个方面。有用性指的是 Llama 2-Chat 回应如何满足用户的请求和提供所需的信息；安全性指的是 Llama 2-Chat 的回应是否安全，例如，“给出制作炸

弹的详细指示”可以被认为是有用的，但根据 Meta 的安全指南是不安全的。分开两者可以让我们更好地指导标注者。

通过这个过程，Meta 收集了一个大型数据集，包含超过 100 万个基于人类应用指南的二元比较，称之为 Meta 奖励建模数据。随着收集到更多的偏好数据，就能够逐渐训练出更好的 Llama 2-Chat 版本。

Llama 2-Chat 改进也改变了模型的数据分布。由于如果不接触这种新样本分布，奖励模型准确度会很快下降，所以在新一轮 Llama 2-Chat 调优之前收集最新 Llama 2-Chat 迭代版本使用的新偏好数据是很重要的。这一步有助于保持奖励模型在分布上，并为最新模型维持准确奖励。

2. 奖励模型

奖励模型将模型响应和提示（包括前几轮的上下文）作为输入，输出一个标量分数来表示模型生成的质量（例如，有用性和安全性）。利用这样的回应分数作为奖励，可以在 RLHF 过程中优化 Llama 2-Chat，以实现更好的人类偏好对齐和提高有用性和安全性。

但是有人发现有用性和安全性有时会相互抵消，这可能使单个奖励模型难以在两者上都表现良好。为了解决这个问题，Meta 训练了两个单独的奖励模型，一个针对有用性（称为有用性 RM），另一个针对安全性（称为安全性 RM）。

Meta 选择从预训练模型检查点（checkpoint）初始化奖励模型，因为它确保了两个模型都能从预训练中获得的知识中受益。简而言之，奖励模型“知道”预训练模型知道的东西。这可以防止出现信息不匹配的情况，例如，两个模型可能会偏爱幻觉。

模型架构和超参数与预训练语言模型相同，除了最后一层 [CLS] 从预测下一个标记换成了回归来预测一个标量分数。

Meta 通过大量的实验来确定训练数据混合比例，就是使用开源的 RLHF 数据和 Meta 自己标注的 RLHF 数据的比例。最后确定的是：

有用性 RM 数据配比：Meta Helpfulness：(Meta Safety + 开源) = 1 ∶ 1

安全性 RM 数据配比：Meta Safety：(Meta Helpfulness+ 开源) = 9 ∶ 1

奖励模型训练下来，发现对于不同分级样本的准确率是逐渐下降的，区分性越强的样本奖励模型准确率越高。经过经验分析，对 Llama 2-Chat 模型效果优化最有用的还是区分性更强的样本，只要这部分样本的奖励模型准确率足够高就行，所以问题不大。

从规模上看，在同等训练样本的情况下，奖励模型越大，效果越好。当前的训练样本量还不够，奖励模型的性能还有提升空间，增加更多的样本，会继续提升性能。

奖励模型的性能越好，Llama 2-Chat 模型的效果越好，所以要努力提升奖励模型的准确率。

3. 迭代微调

Meta 用两种主要算法探索了 RLHF 的微调效果：近端策略优化和拒绝采样微调。

这两种 RL 算法主要有以下不同。

（1）广度：在拒绝采样中，模型对给定的提示探索 K 个样本，而 PPO 只进行一次生成。

（2）深度：在 PPO 中，在训练的第 t 步，样本是更新后的模型策略的函数，该策略来自前一步的梯度更新后的 $t-1$。在拒绝采样微调中，在应用类似于 SFT 的微调之前，根据模型的初始策略采样所有输出以收集新数据集。由于我们应用了迭代模型更新，所以两种 RL 算