法之间的基本差异不太明显。

直到 RLHF（V4），Meta 只使用了拒绝采样微调，之后，将两者顺序结合起来，在再次采样之前，在拒绝采样检查点上应用 PPO。

5.6 Llama 2模型结构

Llama 2 提供的三种参数的模型的情况见表 5-4。

表 5-4 Llama 2 的三种参数模型

模型	参数	上下文长度	GQA	标记数	学习率
Llama 2	7B	4k	✗	2.0 T	3.0×10^{-4}
Llama 2	13B	4k	✗	2.0 T	3.0×10^{-4}
Llama 2	70B	4k	✔	2.0 T	1.5×10^{-4}

模型下载网址：https://huggingface.co/meta-llama

利用下面程序可以读出 llama-2-7b 模型 hf 格式的模型结构：

```
from transformers import AutoModelForCausalLM
import torch

model = AutoModelForCausalLM.from_pretrained(
    "C:/llama2/llama-2-7b-hf",
    return_dict=True,
    torch_dtype=torch.float16,
    trust_remote_code=True,
    device_map="cpu",
)

print(model)
```

程序的输出是

```
LlamaForCausalLM(
  (model): LlamaModel(
    (embed_tokens): Embedding(32000, 4096, padding_idx=0)
    (layers): ModuleList(
      (0-31): 32 x LlamaDecoderLayer(
        (self_attn): LlamaAttention(
          (q_proj): Linear(in_features=4096, out_features=4096, bias=False)
          (k_proj): Linear(in_features=4096, out_features=4096, bias=False)
          (v_proj): Linear(in_features=4096, out_features=4096, bias=False)
          (o_proj): Linear(in_features=4096, out_features=4096, bias=False)
          (rotary_emb): LlamaRotaryEmbedding()
        )
          (mlp): LlamaMLP(
          (gate_proj): Linear(in_features=4096, out_features=11008, bias=False)
          (up_proj): Linear(in_features=4096, out_features=11008, bias=False)
          (down_proj): Linear(in_features=11008, out_features=4096, bias=False)
          (act_fn): SiLUActivation()
        )
        (input_layernorm): LlamaRMSNorm()
        (post_attention_layernorm): LlamaRMSNorm()
      )
    )
```



```
    (norm): LlamaRMSNorm()
  )
  (lm_head): Linear(in_features=4096, out_features=32000, bias=False)
```

这个模型使用了多层 LlamaDecoderLayer 堆叠而成，并在每个 Decoder Layer 中应用了自注意力机制和多层感知机。在模型的最后一层，通过线性层（lm_head）将隐藏状态映射到输出空间（词汇表大小）。整个模型的参数是通过训练得到的，用于生成具有因果性质的语言模型输出。

LlamaForCausalLM

model：LlamaModel 的实例，表示模型的主要组成部分。

lm_head：一个线性层，用于将模型的隐藏状态映射到词汇表大小（55 296）的输出空间。

LlamaModel

embed_tokens：一个 Embedding 层，将词索引映射为对应的嵌入向量。词汇表大小为 32 000，每个词嵌入的维度为 4 096。

layers：一个 ModuleList，包含 32 个 LlamaDecoderLayer。

LlamaDecoderLayer

每个 LlamaDecoderLayer 包含以下组件。

（1）self_attn：LlamaAttention 的实例，表示自注意力机制。它接收输入的查询（q）、键（k）和值（v），并计算自注意力得分。

q_proj：一个线性层，将输入查询特征（4 096 维）映射到注意力空间的维度（4 096 维）。

k_proj：一个线性层，将输入键特征（4 096 维）映射到注意力空间的维度（4 096 维）。

v_proj：一个线性层，将输入值特征（4 096 维）映射到注意力空间的维度（4 096 维）。

o_proj：一个线性层，将自注意力加权的值特征映射回原始特征维度（4 096 维）。

rotary_emb：LlamaRotaryEmbedding 的实例，用于应用旋转位置编码。

（2）mlp：LlamaMLP 的实例，表示多层感知机。该 MLP 由门控投影（gate_proj）、上投影（up_proj）、下投影（down_proj）和激活函数（act_fn）组成。

gate_proj：一个线性层，将输入特征（4 096 维）映射到门控输出（11 008 维）。

up_proj：一个线性层，将输入特征（4 096 维）映射到上投影输出（11 008 维）。

down_proj：一个线性层，将上投影输出（11 008 维）映射回原始特征维度（4 096 维）。

act_fn：SiLUActivation 的实例，表示激活函数。

（3）input_layernorm：LlamaRMSNorm 的实例，表示输入层归一化。用于对输入进行归一化处理，以减少内部协变量偏移（internal covariate shift）。

（4）post_attention_layernorm：LlamaRMSNorm 的实例，表示注意力层后的归一化。

模型中用到以下处理：

LlamaRMSNorm：归一化层，结合了根均方归一化（Root Mean Square Normalization）和可学习的偏置参数，用于对输入进行归一化处理。

LlamaRotaryEmbedding：旋转位置编码的实现，用于为注意力机制引入位置信息。

SiLUActivation：激活函数，使用 Sigmoid-Linear Unit 的形式，也称作 SiLU。SiLU 其实就是 beta 为 1 时的 Swish 激活函数

Linear：线性层，对输入进行线性变换的操作。