5.7 Llama 2权重文件夹

Meta 在发布 Llama 2 时，提供两种模型权重文件格式：一种是 pth 格式，或称原始格式；一种是 huggingface 格式，简称 hf。llama-2-7b 是 pth 格式权重文件夹，目录是这样的：

```
checklist.chk                 100
consolidated.00.pth  13,476,925,163
params.json                   102
```

其中，params.json 是模型的参数：

{"dim": 4096, "multiple_of": 256, "n_heads": 32, "n_layers": 32, "norm_eps": 1e-05, "vocab_size": -1}

pth 文件中的格式对应 github 中 Llama 2 源代码，并可以用 huggingface/transformers 的 convert_llama_weights_to_hf.py 程序转换为 hf 格式。llama-2-7b-hf 是 hf 格式权重文件夹，目录是这样的：

```
config.json                                578
generation_config.json                     132
pytorch_model-00001-of-00002.bin  9,976,634,558
pytorch_model-00002-of-00002.bin  3,500,315,539
pytorch_model.bin.index.json           26,788
README.txt                              7,232
special_tokens_map.json                   411
tokenizer.json                      1,842,767
tokenizer.model                       499,723
tokenizer_config.json                     745
```

其中，尺寸最大的两个文件是bin文件，这是模型的权重文件，其中包含了经过训练的模型权重。bin 文件按照最大不超过 10 GB 进行分割，这里的 7b 文件有 13 G，所以分成两个文件。

pytorch_model.bin.index.json 提供了参数文件的索引信息，用于快速检索和加载参数。

config.json 是模型的配置信息，包括模型的架构、超参数等，也有特殊标记定义，但和 generation_config.json 有重叠：

```
{
  "architectures": [
    "LlamaForCausalLM"
  ],
  "bos_token_id": 1,
  "eos_token_id": 2,
  "hidden_act": "silu",
  "hidden_size": 4096,
  "initializer_range": 0.02,
  "intermediate_size": 11008,
  "max_position_embeddings": 2048,
  "model_type": "llama",
  "num_attention_heads": 32,
  "num_hidden_layers": 32,
  "num_key_value_heads": 32,
```



```
  "pad_token_id": 0,
  "pretraining_tp": 1,
  "rms_norm_eps": 1e-05,
  "rope_scaling": null,
  "tie_word_embeddings": false,
  "torch_dtype": "float16",
  "transformers_version": "4.31.0",
  "use_cache": true,
  "vocab_size": 32000
}
```

generation_config.json 包含了生成器（generator）的配置信息，用于控制生成文本的方式和风格：

```
{
  "_from_model_config": true,
  "bos_token_id": 1,
  "eos_token_id": 2,
  "pad_token_id": 0,
  "transformers_version": "4.31.0"
}
```

special_tokens_map.json 定义了特殊标记（special tokens），如文本的起始和结束标记等：

```
{
  "bos_token": {
    "content": "<s>",
    "lstrip": false,
    "normalized": true,
    "rstrip": false,
    "single_word": false
  },
  "eos_token": {
    "content": "</s>",
    "lstrip": false,
    "normalized": true,
    "rstrip": false,
    "single_word": false
  },
  "unk_token": {
    "content": "<unk>",
    "lstrip": false,
    "normalized": true,
    "rstrip": false,
    "single_word": false
  }
}
```

tokenizer.model、tokenizer.json 是词汇表，一个是二进制，一个是 json 格式。

tokenizer_config.json 包含了分词器的配置信息，用于初始化和加载分词器。

```
{
  "add_bos_token": true,
  "add_eos_token": false,
  "bos_token": {
    "__type": "AddedToken",
    "content": "<s>",
```