```
    "lstrip": false,
    "normalized": true,
    "rstrip": false,
    "single_word": false
  },
  "clean_up_tokenization_spaces": false,
  "eos_token": {
    "__type": "AddedToken",
    "content": "</s>",
    "lstrip": false,
    "normalized": true,
    "rstrip": false,
    "single_word": false
  },
  "legacy": true,
  "model_max_length": 1000000000000000019884624838656,
  "pad_token": null,
  "sp_model_kwargs": {},
  "tokenizer_class": "LlamaTokenizer",
  "unk_token": {
    "__type": "AddedToken",
    "content": "<unk>",
    "lstrip": false,
    "normalized": true,
    "rstrip": false,
    "single_word": false
  }
}
```


5.8 参数量计算

在深度学习模型中，参数量是指模型中可学习参数的总数。这些参数包括神经网络中的权重和偏置。

5.8.1 标准Transformer解码器模型

对于大语言模型，参数量的计算取决于模型的架构。以 Transformer 解码器模型为例（这是 GPT 系列模型的基础），其参数量主要来自以下几个部分。

（1）词嵌入层：这一层将输入的标记（词或词片段）映射到一个连续的向量空间。参数量取决于词汇表大小（V）和嵌入维度（d_model）。计算公式是：V × d_model。

（2）Transformer 层：模型包含多个 Transformer 层（L）。每一层的 Transformer 包括一个自注意力机制和一个前馈神经网络。

① 在自注意力层中，Q、K、V 的权重矩阵 $\boldsymbol{W}_Q$、$\boldsymbol{W}_K$、$\boldsymbol{W}_V$ 的形状应该是 [d_model, d_model/n_heads]。这是因为在多头注意力机制中，模型的嵌入维度 d_model 会被分割成 n_heads 个头，每个头的维度是 d_model/n_heads。而输出权重矩阵 $\boldsymbol{W}_O$ 的形状是 [d_model, d_model]。4 个偏置的形状为 [d_model]。所以自注意力层的参数量应该是 n_heads × (3 × d_model × d_model/n_heads) + d_model × d_model+4 × d_model = 4 × d_model × d_model + 4 × d_model。

② 前馈网络层由 2 个线性层组成，一般地，第一个线性层是先将维度从 d_model 映射到前馈网络的大小（d_ff），偏置的形状为 d_ff，第二个线性层再将维度从 d_ff 映射到 d_model。偏置的形状为 [d_model]。所以前馈网络层的参数量应该是 d_model × d_ff+ d_ff +d_ff × d_model+ d_model = 2 × d_ff × d_model+d_ff+d_model。图 5-2 显示了前馈网络层的形状变化。

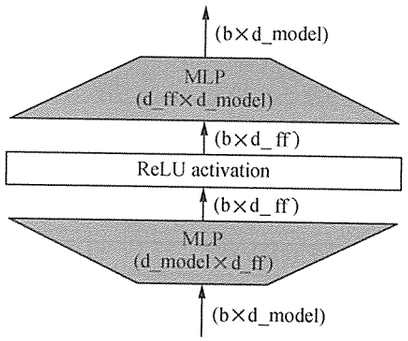


图5-2　前馈网络层的形状变化

③ 自注意力层和前馈网络层各有一个层归一化，包含了 2 个可训练模型参数：缩放参数和平移参数，形状都是 d_model。一个层归一化的参数量为 2 × d_model。

所以，每个 Transformer 层的参数量为 4 × d_model × d_model +4 × d_model+2 × d_ff × d_model+d_ff+d_mode+4 × d_model = 4 × d_model × d_model+2 × d_ff × d_model+d_ff+5 × d_model。

（3）输出层：这一层将模型的输出映射回词汇表中的标记。参数量通常与词嵌入层的参数量相同，因为在很多模型中，这两个层共享参数。

模型的总参数量就是这些部分的参数量之和。这里的计算只是一个估计，实际的参数量可能会有所不同，因为模型的设计和实现可能会有一些额外的参数和细节差异。

对于 GPT-3 的一个版本（125M 参数），其参数设置大致是：V=50257, d_model=768, L=12, num_heads=12, d_ff=3072。根据上面的公式，我们可以计算出其参数量：

50 257 × 768+12 × ((4 × 768 × 768)+(2 × 768 × 3 072)+ 3 072+5 × 768) = 123.6M

对于解码器模型，有 2 个多头注意力层、1 个前馈网络层、3 个归一化层（图 5-3），则 Transformer 层的参数计算公式为

2 × (4 × d_model × d_model+4 × d_model)+2 × d_ff × d_model+ d_ff+d_model+3 × 2 × d_model=8 × d_model^2+4 × d_ff × d_model+ d_ff+15 × d_model

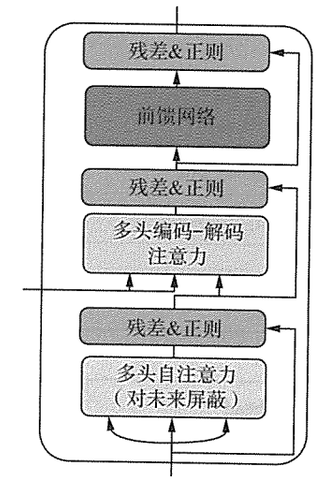


图5-3　解码器构成

5.8.2 Llama 2模型

通过查看 Llama 2 模型的 config.json 和 pytorch_model.bin.index.json，得到 Llama 2 不同尺寸模型的超参数（表 5-5）。

表 5-5　Llama 2 模型大小和参数

参数量	模型大小	嵌入维度 d_model	层数 L	中间维度 d_ff
6.7B	13476839424	4096	32	11008
13.0B	26031738880	5120	40	13824
32.5B	65057902592	6656	60	17920
70B	137953316864	8192	80	28672