其中，模型尺寸是 pytorch_model.bin.index.json 文件中 metadata. total_size 值。

为获得 Llama 2 模型的准确结构，在开源代码基础上编写程序读取模型目录中的模型架构。表 5-6 是 Llama 2 7B、70B 模型结构形状，其中 13B、32B 模型的架构除了超参数不同外，和 7B 类似，而 70B 的注意力层 self_attn.k_proj、self_attn.v_proj 有点特殊。

表 5-6　Llama 2 模型结构形状（7B、70B）

输入：		
	7B	70B
embed_tokens	[32000, 4096]	[32000, 8192]
每层参数（7B 32 层，70B 80 层）：		
self_attn.q_proj	[4096, 4096]	[8192, 8192]
self_attn.k_proj	[4096, 4096]	[1024, 8192]
self_attn.v_proj	[4096, 4096]	[1024, 8192]
self_attn.o_proj	[4096, 4096]	[8192, 8192]
self_attn.rotary_emb.inv_freq	[64]	[64]
mlp.gate_proj	[11008, 4096]	[28672, 8192]
mlp.up_proj	[11008, 4096]	[28672, 8192]
mlp.down_proj	[4096, 11008]	[8192, 28672]
input_layernorm	[4096]	[8192]
post_attention_layernorm	[4096]	[8192]
输出：		
norm	[4096]	[8192]
lm_head	[32000, 4096]	[32000, 8192]

公式中词汇表长度固定为 V = 32000。rotary_emb.inv_freq 数据类型为 F32，其他为 F16。

参数量的计算公式如下。

1. 6.7B、13B、32.5B 三个模型

$$V \times d_model + L \times (4 \times d_model \times d_model + 3 \times d_ff \times d_model + 2 \times d_model + 64) + d_model + V \times d_model$$

模型文件的字节数为

$$2 \times V \times d_model \times 2 + L \times (4 \times d_model \times d_model + 3 \times d_ff \times d_model + 2 \times d_model) \times 2 + L \times 64 \times 4 + d_model \times 24$$

2. 70B 模型

$$V \times d_model + L \times (2 \times d_model \times d_model + 2 \times 1024 \times d_model + 3 \times d_ff \times d_model + 2 \times d_model + 64) + d_model + V \times d_model$$

按照上面的公式可以计算模型文件的字节数，见表 5-7，结果与表 5-5 相对应。

表 5-7　计算参数的数量

参数	嵌入维度 d_model	层数 L	中间维度 d_ff	计算参数数
6.7B	4096	32	11008	6738417664
13.0B	5120	40	13824	13015866880
32.5B	6656	60	17920	32528947456
70B	8192	80	28672	68976645120

5.8.3　用Transformers模块计算

用 Hugging Face 的 Transfomers 模块可以读取模型中的参数量：

```
from transformers import AutoModel

# 加载模型
model = AutoModel.from_pretrained("c:/llama2/llama-2-7b-hf")

# 计算模型参数总数
total_params = sum(p.numel() for p in model.parameters())

print(f'Total parameters: {total_params}')
```

计算得到 Llama 2 7B 模型的参数量为：660734361。

继续执行以下代码：

```
for p in model.parameters():
    print( p.shape)
```

显示模型参数共有 290 个张量，1+32 × 9+1=290，各自形状如下：

```
1 torch.Size([32000, 4096])
---------------------------
以下重复32层
2 torch.Size([4096, 4096])
3 torch.Size([4096, 4096])
4 torch.Size([4096, 4096])
5 torch.Size([4096, 4096])
6 torch.Size([11008, 4096])
7 torch.Size([11008, 4096])
8 torch.Size([4096, 11008])
9 torch.Size([4096])
10 torch.Size([4096])
---------------------------
299 torch.Size([4096])
```

5.8.4　直接解析模型文件

1. 文件构成

Hugging Face 的模型权重文件格式现在已成为大语言模型的标准。包括 Llama 模型在内，几乎所有大语言模型都有 hf 格式存在，并且可以方便地从 Hugging face 网站下载。