

閱讀摘要：RFM ranking – An effective approach to customer segmentation (A7)

本摘要整理 Christy et al. (2021) 論文原文重點，供本論文「投資人行為分群與個人化基金推薦」之 RFM 特徵工程設計、K-means 分群方法與分群評估策略參考使用。

文獻代號：A7 (Journal of King Saud University – Computer and Information Sciences , ScienceDirect 同儕審查期刊)

對應本論文章節：第二章文獻探討 (RFM 分群方法)、第三章研究方法 (RFM 特徵設計、K-means、Fuzzy C-Means 比較)

目錄

- 1. [論文基本資訊](#)
- 2. [研究背景與動機](#)
- 3. [研究目的與問題](#)
- 4. [RFM 模型說明](#)
- 5. [研究方法](#)
- 6. [分群演算法比較：K-means vs. Fuzzy C-Means](#)
- 7. [實驗設計與資料](#)
- 8. [實驗結果](#)
- 9. [研究結論](#)
- 10. [研究限制](#)
- 11. [對本論文的啟發與關聯](#)

1. 論文基本資訊

項目	內容
英文標題	RFM ranking – An effective approach to customer segmentation
作者	A.J. Christy、A. Umamakeswari、L. Priyatharsini、Nooraeni

項目	內容
期刊	Journal of King Saud University — Computer and Information Sciences
年份	2021 (投稿 2018, 出版 2021, Vol. 33, Issue 9)
DOI	https://doi.org/10.1016/j.jksuci.2018.09.004
關鍵字	RFM、customer segmentation、K-means clustering、Fuzzy C-Means、RFM ranking
取得方式	✅ 2026-08-26 PDF 全文已取得 (ScienceDirect)

2. 研究背景與動機

- 企業面對龐大的顧客資料庫，如何有效識別高價值顧客、針對不同群體制定差異化行銷策略，成為 CRM 的核心挑戰。
- 傳統 RFM 模型 (Recency、Frequency、Monetary) 雖廣泛應用，但各指標的**相對重要性**在不同情境下有所不同，若三個構面等權加總，可能無法精確反映顧客的真實價值。
- 現有研究對 RFM 的各種**排名方式 (ranking)** 缺乏系統性比較，尤其是不同排名策略對後續分群結果的影響。
- 分群演算法的選擇 (硬分群 vs. 模糊分群) 對顧客分群結果有實質影響，值得並列比較。

3. 研究目的與問題

3.1 研究目的

提出一套以 **RFM 排名 (RFM Ranking)** 為核心的顧客分群方法，透過對 RFM 三個構面進行排名並整合，再以 K-means 與 Fuzzy C-Means 進行分群，評估哪種組合在顧客分群上更為有效。

3.2 核心研究問題

- 不同 RFM 排名方式 (如等分法、百分位、組合加總) 對分群結果有何影響？
- K-means 與 Fuzzy C-Means 分別應用於 RFM 資料時，分群品質有何差異？
- 哪種方法組合在顧客分群上表現最佳？

4. RFM 模型說明

4.1 三個構面定義

構面	英文全稱	定義	商業意義
R (Recency)	最近一次消費	距今最後一次購買的天數	R 越小，顧客越活躍、互動越近期
F (Frequency)	購買頻率	研究期間內的購買次數	F 越高，顧客忠誠度與黏著度越強
M (Monetary)	購買金額	研究期間內的累計消費金額	M 越高，顧客貢獻度越大

4.2 RFM Ranking（核心貢獻）

- 本研究的核心創新在於提出並比較多種 **RFM 排名方式**，包括：
 - 等分法 (Quintile Ranking)**：將 R、F、M 各自排序後均分為 N 等分，賦予 1~N 分
 - 百分位排名 (Percentile Ranking)**：依各指標分布計算百分位數
 - 加總組合 (Composite Score)**：三構面分數加總或加權後排名
- 不同排名方式產生不同的顧客分數分佈，進而影響分群結果。

4.3 RFM 指標的方向性

構面	分數方向	說明
R	越小越好	最近購買天數少 → 顧客越活躍 → 分數應較高
F	越大越好	購買次數多 → 忠誠度高 → 分數應較高
M	越大越好	消費金額高 → 貢獻度大 → 分數應較高

注意：R 構面在賦分時方向相反（R 值越小 → R 分數越高），需在前處理中反轉。

5. 研究方法

5.1 整體流程

- 顧客交易資料
- 計算 R、F、M 三構面原始值
 - RFM Ranking（等分法 / 百分位 / 加總等方式）
 - 標準化 / 正規化
 - 分群演算法（K-means 或 Fuzzy C-Means）
 - 分群評估（Silhouette Score、戴維森堡丁指數等）
 - 顧客分群輪廓詮釋

5.2 標準化處理

- RFM 三構面原始值的量綱不同（天數 vs. 次數 vs. 金額），需進行標準化（Z-score 或 Min–Max Normalization）後再輸入分群演算法，避免量綱差異主導距離計算。

6. 分群演算法比較：K-means vs. Fuzzy C-Means

6.1 K-means（硬分群）

項目	說明
分群邏輯	每個樣本被唯一指派至最近的群心（硬性分群）
距離計算	歐氏距離（Euclidean Distance）
優點	計算效率高、易於解釋
缺點	對離群值敏感；假設球形群簇；需事先指定 K 值
收斂	最小化組內平方和（Within–Cluster Sum of Squares, WCSS）

6.2 Fuzzy C-Means（模糊分群）

項目	說明
分群邏輯	每個樣本對所有群體有隸屬度（membership degree），介於 0 至 1 之間
特點	允許樣本同時「部分屬於」多個群體，適合邊界模糊的情況
優點	對行為介於多個群體之間的顧客更具彈性
缺點	解釋與後續應用較 K-means 複雜；計算成本較高

6.3 比較結論（原文實驗結果）

- 兩種演算法皆能有效識別 RFM 資料中的顧客群體。
- 在分群品質指標（Silhouette Score）上，兩者表現接近，但在特定資料集上 K-means 略優或相當。
- 硬分群（K-means）在實務應用與解釋上更為直觀，適合多數商業情境。

7. 實驗設計與資料

項目	內容
資料來源	電子商務或零售顧客交易資料（詳見原文）
分析單位	每位顧客（per-customer）的 RFM 彙整值
最佳 K 值	依 Elbow Method 與 Silhouette Score 選定
評估指標	Silhouette Score、戴維森堡丁指數（Davies–Bouldin Index）

8. 實驗結果

- RFM Ranking（排名法）相較於直接使用原始 RFM 值，能產生**更均衡的分群分佈**，避免少數極端值主導群心。
- K-means 與 Fuzzy C-Means 均能識別出行為特徵各異的顧客群體（如高價值型、流失風險型、潛力成長型等）。
- 不同排名方式（等分法 vs. 百分位）對分群結果有輕微影響，但整體趨勢一致。
- **等分法（Quintile）是最常用且效果穩健的 RFM 排名方式**，在實務中應用最廣。

9. 研究結論

1. **RFM Ranking 是有效的顧客分群前處理方法**：相較於直接使用原始值，排名後的 RFM 分數具備更好的分佈特性，有助於提升 K-means 與 FCM 的分群品質。
2. K-means 適合多數顧客分群場景，FCM 則在顧客行為邊界模糊時提供更細緻的刻畫。
3. RFM 三構面的排名方式選擇會影響最終分群結果，應依資料分佈特性決定。
4. 分群後的各群顧客需以商業意義命名，才能有效轉化為行銷策略。

10. 研究限制

- 實驗以一般電商或零售資料為主，不直接涵蓋金融商品投資人情境。
- RFM 三構面的相對權重設定（若採加權方式）會影響分群，但本研究以排名法繞過此問題。
- 靜態 RFM 無法捕捉顧客行為隨時間的動態演變（如季節效應、交易頻率變化趨勢）。
- K 值的選定仍依賴手肘法等啟發式方法，不同 K 值可能導致不同詮釋。

11. 對本論文的啟發與關聯

本節為研讀者延伸整理，非原文內容，用於連結至「投資人分群與基金推薦」研究。

面向	A7 作法	對本論文的啟發
RFM 特徵設計	R（最近購買）、F（購買頻率）、M（購買金額）	可直接對應本論文「投資版 RFM」：R→最近申購距今天數、F→申購次數、M→累計申購金額
排名法 (Ranking)	等分法將 R/F/M 各自分成 N 等分賦分	本論文可採等分法對投資人 RFM 分數排名，解決基金金額分佈偏態問題
R 方向性處理	R 值越小賦分越高（方向反轉）	在特徵工程中需特別注意：最近申購天數越少 → 活躍度越高 → 賦分方式反轉
K-means vs. FCM	比較硬分群與模糊分群	支撐本論文選用 K-means 的合理性；若需進一步說明，可引用 A7 指出「K-means 在 RFM 資料上表現穩健且易解釋」
分群評估	Silhouette Score、戴維森堡丁指數	本論文第三章評估指標設計可引用 A7 的評估框架
群體命名	依 RFM 分群結果賦予商業意義名稱	直接支撐第四章「投資人群體命名與詮釋」的寫作方式

與其他文獻的連結： – 與 [[A6-tan-2025-kmeans-investor-behavior-malaysian-derivatives-reading-summary]] (A6) 形成方法互補：A7 提供 RFM + K-means 的基礎方法論，A6 提供金融交易場景的實證應用，兩篇合用可完整支撐本論文方法設計。 – 與 [[A12-cheng-2010-rfm-som-adaptive-recommendation-reading-summary]] (A12) 比較：同為 RFM 分群應用，A7 聚焦排名方式與演算法比較，A12 聚焦分層後差異化推薦策略——兩者可在第二章共同引用，呈現 RFM 研究的不同側重。 – A7 的 K-means 硬分群結論，可作為本論文不採 Fuzzy C-Means 的方法論依據（K-means 在 RFM 情境效能相當且更易解釋）。

建立日期：2026-08-26

文件性質：論文閱讀摘要（整理原文重點，含研讀者延伸關聯）