

閱讀摘要：基於 RFM 分析法之顧客適性化產品推薦機制（A12）

本摘要整理鄭婕妤（2010）碩士論文原文重點，供本論文「投資人行為分群與個人化基金推薦」之方法論參考與文獻對照使用。

文獻代號：A12（崇越論文大賞，全文開放） 對應本論文章節：分群方法（RFM + SOM）、推薦機制（混合式推薦）、顧客忠誠度分層

目錄

- 1. [論文基本資訊](#)
- 2. [研究背景與動機](#)
- 3. [研究目的與問題](#)
- 4. [文獻回顧重點](#)
- 5. [研究方法總覽](#)
- 6. [核心方法一：RFM 分析與顧客分群](#)
- 7. [核心方法二：SOM 自組織映射圖網路](#)
- 8. [核心方法三：混合式推薦與 PRI](#)
- 9. [實驗設計與資料](#)
- 10. [實驗結果與討論](#)
- 11. [研究結論與限制](#)
- 12. [對本論文的啟發與關聯](#)

1. 論文基本資訊

項目	內容
中文標題	基於 RFM 分析法之顧客適性化產品推薦機制
作者	鄭婕妤
機構	朝陽科技大學 資訊管理系（碩士論文）
年份	2010

項目	內容
關鍵字	RFM 分析、自組織映射圖網路（SOM）、顧客忠誠度、適性化推薦、混合式推薦
取得方式	崇越論文大賞，全文開放 PDF

2. 研究背景與動機

- 電子商務與網路購物普及，商品數量龐大，消費者面臨**資訊過載**，難以有效篩選合適產品。
- 企業累積大量顧客交易紀錄，如何從中萃取顧客價值並提供**個人化推薦**，成為維繫顧客關係與提升銷售之關鍵。
- 傳統推薦系統（內容導向、協同過濾）各有其**冷啟動**、**稀疏資料**等限制，單一方法難以兼顧不同顧客特性。
- **顧客並非同質**：高價值 / 高忠誠顧客與低價值 / 低忠誠顧客的行為模式不同，宜採**差異化的推薦策略**。

3. 研究目的與問題

3.1 研究目的

提出一套結合 **RFM 分析法**與 **SOM 分群**的顧客適性化產品推薦機制，依顧客忠誠度分層後，對不同客群施以最適推薦方法，以提升推薦準確度。

3.2 研究問題

1. 如何以 RFM 指標衡量顧客價值並區分**高忠誠度** / **低忠誠度**客群？
2. 針對不同忠誠度客群，應採用何種推薦策略較為適配？
3. 混合式推薦是否較單一（內容導向、協同過濾）推薦更具效能？

4. 文獻回顧重點

主題	重點整理
RFM 分析	以最近購買（Recency）、購買頻率（Frequency）、購買金額（Monetary）衡量顧客價值；常搭配顧客五等分法（Miglausch,

主題	重點整理
	2000) 進行分級
顧客關係管理	依顧客價值分群，將行銷資源集中於高價值顧客
內容導向式推薦 (CB)	依商品屬性與顧客偏好匹配，可緩解冷啟動，但受限於商品特徵萃取
協同過濾式推薦 (CF)	依相似顧客行為推薦，效果佳但受稀疏資料與新顧客冷啟動影響
混合式推薦 (Mixed)	結合 CB 與 CF，互補單一方法不足
自組織映射圖網路 (SOM)	非監督式類神經網路，可將高維顧客資料映射至低維、形成分群
產品購買週期	不同商品有其重複購買間隔，可作為推薦時機依據

5. 研究方法總覽

本研究之推薦機制流程可概括為：

顧客交易紀錄

→ RFM 分析 (計算 R、F、M 值)

→ 顧客五等分法分級 → 界定高 / 低忠誠度客群

└ 高忠誠度客群 → 產品推薦區間 (PRI) + 混合式推薦

└ 低忠誠度客群 → SOM 分群 → 群內混合式推薦

→ 產生個人化推薦清單

→ 以 Precision / Recall / F1 評估

核心設計理念：先分群、再分策略——不對所有顧客採用單一推薦法，而是依忠誠度施以差異化機制。

6. 核心方法一：RFM 分析與顧客分群

6.1 RFM 三構面

構面	定義	意義
Recency (R)	最近一次購買距今時間	R 越小，顧客越活躍
Frequency (F)	一段期間內購買次數	F 越高，黏著度越強

構面	定義	意義
Monetary (M)	一段期間內購買金額	M 越高，貢獻度越大

6.2 顧客五等分法 (Miglausch, 2000)

- 將 R、F、M 各自由高至低排序後均分為五等分，分別給予 5~1 分。
- 三構面加總或組合後，區分顧客等級。
- 本研究據此界定**高忠誠度顧客** (RFM 分數高) 與**低忠誠度顧客** (RFM 分數低)。

6.3 忠誠度分層的用意

- **高忠誠度顧客**：購買行為穩定、具規律性 → 適合以「產品購買週期 / 推薦區間 (PRI)」預測其下次購買時機與品項。
- **低忠誠度顧客**：行為較不規律、資料較稀疏 → 改以 SOM 分群，找出行為相近的群體再行推薦。

7. 核心方法二：SOM 自組織映射圖網路

7.1 為何使用 SOM

- SOM 為**非監督式**類神經網路，不需事先標記即可自動將顧客依行為特徵分群。
- 能將高維顧客特徵 (RFM 等) 映射至二維拓樸圖，**保留樣本間相似關係**，相近顧客落於鄰近節點。

7.2 SOM 於本研究的角色

- 針對**低忠誠度客群**進行分群，將行為相似的顧客歸為同群。
- 群內再運用混合式推薦，借助「相似顧客」的購買資訊補足個別顧客資料稀疏之不足 (近似 CF 精神)。

8. 核心方法三：混合式推薦與 PRI

8.1 內容導向式 (CB) 與協同過濾式 (CF)

- **CB**：依商品屬性與顧客過去偏好匹配推薦。
- **CF**：依相似顧客的購買行為推薦。
- 兩者單獨使用皆有其限制 (冷啟動、稀疏資料)。

8.2 混合式推薦 (Mixed = CB + CF)

- 本研究將 CB 與 CF 結合，互補單一方法之不足，作為兩類客群共同的推薦核心。

8.3 產品推薦區間 (Product Recommender Interval, PRI)

- 針對高忠誠度顧客，依其產品購買週期推估下次可能購買的時間區間與品項。
- 在適當時機推薦，提升推薦命中率與顧客回應率。

9. 實驗設計與資料

9.1 資料集

項目	內容
資料來源	Foodmart2000 交易資料庫
顧客數	2,780 位
交易筆數	121,764 筆

9.2 比較方法

方法	說明
CB	內容導向式推薦 (對照組)
CF	協同過濾式推薦 (對照組)
Mix	本研究提出之混合式推薦

9.3 評估指標

指標	用途
Precision (準確率)	推薦清單中命中的比例
Recall (召回率)	實際購買中被推薦命中的比例
F1	Precision 與 Recall 之調和平均

10. 實驗結果與討論

- 混合式推薦（Mix）在 Precision 與 F1 上優於傳統單一的 CB 與 CF 推薦。
- 超過半數顧客的推薦成功率達 50% 以上，顯示分層 + 混合機制具實用價值。
- 對高忠誠度顧客導入 PRI（產品推薦區間）有助於掌握購買時機、提升推薦效果。
- 對低忠誠度顧客先以 SOM 分群再推薦，可緩解個別顧客資料稀疏之問題。

11. 研究結論與限制

11.1 結論

1. 以 RFM + 五等分法界定顧客忠誠度，再依忠誠度施以差異化推薦策略，較單一推薦法有效。
2. 混合式推薦綜合效能（Precision、F1）優於單一 CB 或 CF。
3. PRI（產品推薦區間）能為規律性高的顧客提供適時推薦。
4. SOM 分群適合處理低忠誠度、資料稀疏之客群。

11.2 限制

- 實驗以 Foodmart2000 零售交易資料為主，屬一般消費品情境，與金融商品特性不同。
- RFM 指標權重、五等分切點的設定會影響分群結果。

12. 對本論文的啟發與關聯

本節為研讀者延伸整理，非原文內容，用於連結至「投資人分群與基金推薦」研究。

面向	A12 作法	對本論文的啟發
顧客分群	RFM + 五等分法界定忠誠度	基金投資人亦可用 RFM（近期申購、申購頻率、投資金額）分層；可延伸為投資行為多維指標
差異化策略	高 / 低忠誠度採不同推薦法	對高黏著度投資人與新手 / 低頻投資人可設計不同推薦邏輯
分群技術	SOM 非監督式分群	可與本論文考慮之分群方法（如 K-means、K-medoids）並列比較
推薦方法	混合式（CB + CF）	支持本論文採用混合式推薦優於單一方法之立論

面向	A12 作法	對本論文的啟發
推薦時機	PRI 產品購買週期	基金申購 / 定期定額具週期性，可轉化為「申購時機推薦」概念
評估指標	Precision / Recall / F1	可作為本論文推薦模型之標準評估指標

與其他文獻的連結： – 分群 + 推薦的整合流程，可與 KL-KM 基金推薦論文（Chiou-Wei & Lee, 2024）對照——後者聚焦基金情境的 KL 距離相似度，A12 則提供「忠誠度分層 + 混合推薦」的整體架構。

建立日期：2026-07-29 文件性質：論文閱讀摘要（整理原文重點，含研讀者延伸關聯）