

閱讀摘要：基於動態效用學習之個人化基金推薦（B2）

本摘要整理 Wei & Liu（2025）論文原文重點，供本論文「投資人行為分群與個人化基金推薦」之方法論參考與文獻對照使用。

文獻代號：B2（*Financial Innovation*，開放取用） 論文連結：DOI [10.1186/s40854-024-00720-5](https://doi.org/10.1186/s40854-024-00720-5) 對應本論文章節：個人化推薦（強化學習）、動態偏好學習、探索－利用權衡

目錄

- [1. 論文基本資訊與摘要](#)
- [2. 研究背景與問題](#)
- [3. 文獻回顧重點](#)
- [4. 研究貢獻](#)
- [5. 系統架構與互動流程](#)
- [6. 核心方法一：效用函數與偏好學習](#)
- [7. 核心方法二： \$\epsilon\$ -greedy 推薦演算法](#)
- [8. 評估指標](#)
- [9. 數值實驗設計](#)
- [10. 實驗結果與討論](#)
- [11. 結論、限制與未來方向](#)
- [12. 對本論文的啟發與關聯](#)

1. 論文基本資訊與摘要

項目	內容
英文標題	Personalized fund recommendation with dynamic utility learning
中文標題	基於動態效用學習之個人化基金推薦
作者	Jiaxin Wei（魏佳欣）、Jia Liu（劉甲，通訊作者）
機構	西安交通大學 數學與統計學院

項目	內容
期刊	<i>Financial Innovation</i> , 2025, 11:48
關鍵字	個人化基金推薦、 ϵ -greedy 演算法、動態效用學習
收稿 / 接受	2023-07-04 收稿；2024-11-11 接受；2025-01-15 線上刊登

原文摘要（中譯）

本研究提出一套結合 ϵ -greedy 演算法與增量學習（incremental learning）框架的基金推薦系統。系統模擬顧客瀏覽基金產品網頁時的互動：顧客點選其偏好的基金，系統蒐集點擊序列，持續估計並更新其效用函數。系統以 ϵ -greedy 產生推薦清單——每項產品有 $1-\epsilon$ 機率被選為**利用（exploitation）策略**， ϵ 機率被選為**探索（exploration）策略**。研究以一系列數值測試評估不同 ϵ 值之估計效能。

2. 研究背景與問題

2.1 研究背景

- 數位科技與人工智慧革新金融服務，基金推薦為金融機構重要議題。
- 為留住投資人，金融機構需提供**準確且個人化**的產品推薦。
- **傳統基金推薦**多以隨機或預設排序清單推薦，無法滿足金融科技時代的個人化需求。

2.2 研究問題

- 如何在顧客與系統的**動態互動**中，持續學習並更新其偏好？
- 如何兼顧「推薦最符合顧客當前口味的產品（利用）」與「推薦新產品以更清楚了解其偏好（探索）」之間的權衡？
- 傳統偏好誘導（preference elicitation）多屬**監督式**，需事先蒐集顧客選擇，且可能出現與歷史選擇矛盾而導致**不可行（infeasibility）**的問題。

3. 文獻回顧重點

研究路線	代表作法	侷限
協同過濾（CF）	User-based / Item-based；神經網路 CF、深度學習 CF、圖式深度 CF	需大量資料，個人化程度仍不足

研究路線	代表作法	侷限
聯合分析 (conjoint analysis)	以線性效用函數衡量偏好，推薦高效用產品	核心在效用函數之誘導
偏好誘導三途徑	成對比較、評分擬合、由歷史決策以反向最佳化 / 反向強化學習誘導	多屬監督式，可能不可行
偏好穩健最佳化	建構效用函數的模糊集 (ambiguity set)，採最壞情況決策	只重誘導效率，忽略顧客體驗
強化學習	探索新選項、避免陷入區域最佳	Alsabah et al.(2021) 以 RL 學習風險偏好
增量學習	持續由新資料更新模型，不需完整重訓	逐步精進推薦

研究缺口： 偏好誘導的**效率**與顧客**滿意度**需取得平衡，這正是典型的**探索－利用**問題。本研究以此切入。

4. 研究貢獻

- 據作者所知，提出**首個**基於增量學習與最佳化的**動態效用學習模型**。
- 有別於傳統偏好誘導與推薦系統，本研究納入**互動成本 (cost of interaction)**，引入探索－利用之平衡問題。
- 提出**新的量化指標**，衡量效用擬合改善所帶來的報酬。
- 模擬結果驗證效用學習模型之**收斂性**，以及 ϵ -greedy 演算法在平衡探索與利用上的**效率**。

5. 系統架構與互動流程

系統包含兩大部分：**效用學習 / 更新模型**與**推薦系統**，形成循環互動：

建立基金池 Y (自市場選取若干基金)

- 系統以產品清單 S_k 於網頁推薦 n 檔基金
- 顧客依真實效用點選偏好基金 → 產生點擊序列 C_k
- 系統依 C_k 以最佳化模型估計 / 更新名目效用 $\hat{a}^k$ (增量學習)
- 下次造訪時以 ϵ -greedy 產生新清單
- 反覆循環，持續學習與更新顧客效用

- 基金屬性：** 以 5 項代表性屬性描述每檔基金——**年化報酬 (annualized return)**、**波動度 (volatility)**、**規模 (size)**、**周轉率 (turnover ratio)**、**排名 (ranking)**。

- **點擊序列假設**：顧客先點選者效用高於後點選者；被點選者效用高於未被點選者。

6. 核心方法一：效用函數與偏好學習

6.1 線性效用函數

假設顧客持有對基金 y 的線性效用函數：

$$U(a, y) = a_1 x^1_y + a_2 x^2_y + \dots + a_m x^m_y$$

其中 $a = [a_1, \dots, a_m]$ 為**載荷因子 (loading factor)**，描述顧客對各屬性的偏好程度； a^* 為真實效用之載荷因子， $\hat{a}^k$ 為第 k 次互動後之名目（估計）載荷因子。

6.2 首次互動的效用學習 (QP1)

- 首次造訪無先驗資訊，系統**隨機**推薦直到取得首個點擊序列。
- 以最佳化模型學習效用參數：最小化 $\|a\|^2$ ，並滿足點擊順序約束（先點>後點、已點>未點）與載荷因子總和約束 $\sum a_i = M$ 。
- 因 U 為線性，可改寫為**二次規劃 (QP1)** 求解，得 $\hat{a}^1$ 。

6.3 後續互動的效用更新 (QP2)

- 第 k 次 ($k \geq 2$) 造訪時，保留前一輪名目效用 $\hat{a}^{k-1}$ 作為參考。
- 目標改為**最小化 $\|a - \hat{a}^{k-1}\|^2$** ，在符合本輪新點擊序列約束下，尋找最接近前一輪效用者——既納入新偏好資訊，又保留既有資訊。

6.4 不一致點擊的可行性處理 (ICEA)

- 顧客可能誤點或漏看高效用產品，導致成對比較約束**互相衝突**、可行域為空集。
- 提出**迭代約束刪除演算法 (ICEA)**：將不一致約束分組，逐步移除衝突約束並重解，找出可提供可行解的**最大子集**，確保系統持續運作。

7. 核心方法二： ϵ -greedy 推薦演算法

7.1 探索與利用

- **利用 (exploitation)**：依當前名目效用排名，推薦分數最高的基金（貪婪動作），短期最大化期望報酬、維持顧客黏著度。

- **探索 (exploration)**：自產品集**隨機推薦**，短期可能犧牲滿意度，但長期有助於更完整學習顧客效用。

7.2 演算法邏輯

- 清單中每項產品以 **$1-\epsilon$ 機率**採利用（取當前效用最高者，並自基金池移除以避免重複），以 **ϵ 機率**採探索（隨機推薦）。
- ϵ 值決定探索率； $\epsilon=0$ 為純利用、 $\epsilon=1$ 為純探索兩種極端。
- 每輪推薦後蒐集顧客回饋作為**報酬 (reward)**，用於評估系統長期表現。

8. 評估指標

指標	全名	用途
SUD	Single Utility Difference upper bound	名目效用與真實效用之最大差距上界，衡量擬合誤差（越小越好）
RF	Recommendation Fitness	推薦擬合度：前 n 檔推薦效用與最佳 n 檔真實效用之標準化平均差（越小越好）
互動成本	interaction cost	每次互動固定成本（實驗設為 0.5 美元）
CR	Cumulative Reward	累積報酬， $R_k = RF(k) - 0.5$ ，對前 K 次加總
AR	Average Reward	平均報酬， $AR(K) = CR(K)/K$

9. 數值實驗設計

- **市場與基金池**：中國基金市場，於 2022-08-26 選取 **113 檔基金**（含 31 股票型、40 混合型、15 指數型、26 債券型、1 QDII 型），蒐集 5 項屬性並正規化。
- **虛擬顧客**：預設真實效用 $a^* = [2, -4, 10, 0, -2]$ ，效用門檻為 0（僅點選效用 ≥ 0 之產品）；設定 $M=6$ 。
- **互動次數**：模擬造訪網頁 **3000 次**。
- **ϵ 測試值**：0、0.1、0.3、0.5、0.8、1。
- **穩健性測試**：另設 3 位不同真實效用之虛擬顧客重複測試。

10. 實驗結果與討論

10.1 效用估計收斂

- ϵ 越大（探索機率越高），學得的係數越接近真實值；但**效益有上限**—— $\epsilon=1$ 的結果並未明顯優於 $\epsilon=0.8$ 。
- SUD 隨互動次數增加而下降； ϵ 越大最終 SUD 越小。
- $\epsilon=0$ （純利用）**無法保證收斂**：一旦點擊順序與名目效用一致，系統便停止更新，陷入區域最佳。
- $\epsilon=1$ （純探索）未善用點擊偏好資訊。

10.2 累積報酬（兼顧擬合與成本）

- $\epsilon=1$ 累積報酬最低（隨機性過高）； $\epsilon=0$ 次低（探索為零，第 3 次互動後報酬固定）。
- $\epsilon=0.1$ 表現最佳（在此實驗設定下累積報酬最高）； $\epsilon=0.8$ 雖能較早學到完整偏好，但後續大量隨機推薦未能有效利用已學效用，報酬較低。
- 平均報酬（AR）：小 ϵ （0.1、0.3、0.5）隨互動增加而上升趨穩；大 ϵ （0.8）先升後降； $\epsilon=1$ 持續下降。

10.3 穩健性

- 3 位虛擬顧客的 SUD 曲線均收斂；部分因基金池有限、效用函數對既定基金非唯一，SUD 收斂但未必歸零——**惟最佳 8 檔基金的排序仍與真實效用一致**，可透過擴大基金池數量與多樣性改善。
- ϵ 的最佳選擇因顧客而異，仍為未來值得研究的課題。

11. 結論、限制與未來方向

11.1 結論

- 提出結合 ϵ -greedy 與增量學習的基金推薦系統，可在動態互動中持續學習顧客效用並平衡探索—利用。
- 適度探索（如 $\epsilon=0.1$ ）在兼顧學習效率與推薦滿意度下表現最佳。

11.2 限制

- 資料僅取自**中國基金市場**（具借貸法規嚴格、放空受限等特性），未涵蓋國際市場。
- 僅考慮**固定 ϵ** 的 ϵ -greedy。

11.3 未來方向

- 令 ϵ **自適應 (self-adaptive)**：早期採較大 ϵ 多探索、後期減小以多利用。
- 將方法推廣至**不同類型產品**，並可將顧客在某類產品的偏好**遷移學習**至其他產品類別。

12. 對本論文的啟發與關聯

本節為研讀者延伸整理，非原文內容，用於連結至「投資人分群與基金推薦」研究。

面向	B2 作法	對本論文的啟發
偏好建模	以線性效用函數 + 載荷因子刻畫投資人偏好	可作為刻畫基金投資人屬性偏好的量化基礎
動態學習	增量學習，由點擊序列持續更新效用	支持「投資人偏好會隨時間演化」之立論，呼應數位券商即時互動情境
推薦策略	ϵ -greedy 平衡探索與利用	為個人化推薦引入強化學習視角，可與傳統 CF / 混合式推薦對照
冷啟動	首次隨機推薦，逐步學習	提供新投資人（無歷史紀錄）情境下的可行推薦流程
基金屬性	年化報酬、波動度、規模、周轉率、排名 5 項	可直接借鑑為本論文基金特徵向量之設計參考
評估指標	SUD、RF、累積 / 平均報酬	補充 Precision/Recall/F1 之外，考量「效用擬合」與「互動成本」的評估思維

與其他文獻的連結： – 與 [[A12–cheng–2010–rfm–som–adaptive–recommendation–reading–summary]] (A12) 相比：A12 以 RFM+SOM 做**靜態分群後推薦**；B2 則以強化學習做**動態偏好學習**，兩者可互補為「先分群、後動態調整」之整體架構。 – 與 KL-KM 基金推薦論文 (Chiou-Wei & Lee, 2024) 同屬**基金情境**，但 B2 強調線上互動與探索—利用，KL-KM 著重相似度計算。

建立日期：2026-07-29 文件性質：論文閱讀摘要（整理原文重點，含研讀者延伸關聯）