

國立臺北商業大學
資訊與決策科學研究所
碩士學位論文

應用投資人分群與個人化推薦模型於數位
券商基金投資服務之研究

A Study on Applying Investor Segmentation and
Personalized Recommendation Models to Digital
Brokerage Fund Investment Services

研究生：黃子甄 撰
指導教授：王亦凡 博士

中華民國一一六年六月

目錄

表目錄	5
圖目錄	6
第一章 緒論	7
1.1 研究背景與動機	7
1.2 研究問題	8
1.3 研究目的	8
1.4 研究範圍與限制	9
研究範圍	9
研究不包含（不做事項清單）	10
研究限制	10
1.5 研究流程	11
1.6 論文架構說明	12
第二章 文獻探討	13
2.1 投資人行為與數位金融	13
2.2 投資人／顧客分群相關文獻	17
2.2.1 投資人／顧客分群方法	17
2.2.2 RFM 與機器學習分群	21
2.3 個人化推薦系統與 FinTech 應用相關文獻	29
2.3.1 個人化推薦系統文獻脈絡	30
2.3.2 基金／金融商品推薦文獻脈絡	34
2.3.3 FinTech 與數位券商應用文獻脈絡	39
2.3.4 金融商品推薦與一般電商推薦之差異	44
2.4 文獻整理與研究缺口分析	44
2.4.1 研究缺口彙整表	44
2.4.2 與國內先行研究之比較：許仲廷（2022）、王怡（2023）	47
2.4.3 本研究如何填補缺口	48

2.4.4 綜合性論述	49
第三章 研究方法	50
3.1 研究架構設計	50
3.1.1 設計理念：管線順序與基準階梯之理由	50
3.1.2 五層架構總覽與層間資料介面	51
3.1.3 第一層：資料蒐集	52
3.1.4 第二層：特徵工程與資料前處理	53
3.1.5 第三層：投資人分群	53
3.1.6 第四、五層：個人化推薦模型與評估	53
3.1.7 貫穿五層之方法論層級承諾	54
3.2 研究流程說明	54
3.2.1 步驟一：資料蒐集與整合規劃	55
3.2.2 步驟二：資料前處理與特徵工程	56
3.2.3 步驟三：投資人分群	56
3.2.4 步驟四：個人化推薦模型建置	56
3.2.5 步驟五：模型評估與比較	57
3.2.6 步驟六：結果整合與應用建議	57
3.3 資料來源與資料說明	58
3.3.1 研究場域與資料期間	58
3.3.2 GA4 使用者行為資料.....	58
3.3.3 基金交易資料	62
3.3.4 用戶屬性資料	63
3.3.5 資料倫理與脫敏方式	64
3.3.6 資料限制與待確認事項	64
3.4 資料前處理方法	65
3.4.1 資料串接與識別碼歸戶（前置步驟）	65
3.4.2 缺值處理策略	67
3.4.3 RFM 特徵計算公式	68
3.4.4 GA4 行為特徵計算方式.....	70
3.4.5 特徵標準化方法	71

3.4.6 資料限制與待確認事項	73
3.5 投資人分群方法	73
3.5.1 分群特徵之計算期間與資料洩漏防範	73
3.5.2 分群特徵之尺度組成	74
3.5.3 分群演算法選擇：K-prototypes	75
3.5.4 最佳分群數選取方法	77
3.5.5 方法論承諾與待驗證項目	78
3.6 個人化推薦模型方法	79
3.6.1 推薦模型設計總覽	79
3.6.2 熱門推薦（Baseline）	81
3.6.3 內容導向推薦	82
3.6.4 協同過濾（ALS 隱性回饋矩陣分解）	83
3.6.5 分群輔助 CF：候選集篩選整合方式（方案 A）之操作型定義	84
3.6.6 方法論承諾與待驗證項目	85
3.7 模型評估方法	86
3.7.1 訓練集／測試集切分方式	86
3.7.2 評估指標定義與計算方式	87
3.7.3 分數之意義與模型間比較邏輯	90
3.7.4 RQ3 群體間差異之計算方式	91
3.7.5 方法論承諾與待驗證項目	93
參考文獻	94
中文文獻	94
西文文獻	95

表目錄

表 2-1	研究缺口彙整表	44
表 3-1	GA4 使用者行為資料欄位分類	58
表 3-2	用戶屬性資料欄位分類	63
表 3-3	分群特徵之尺度組成	74
表 3-4	個人化推薦模型設計總覽	79
表 3-5	評估所需資料欄位	89

圖目錄

圖 3-1	五層資料處理架構圖	52
圖 3-2	研究流程圖	55

第一章 緒論

1.1 研究背景與動機

台灣數位券商市場現況：根據臺灣證券交易所統計，截至 2025 年底，台股累積總開戶數達 1,376.78 萬人，較 2024 年底成長 55.18 萬人，創歷史新高；其中 61 歲以上族群占全年新增開戶數近 4 成，30 歲以下則占新開戶數 62.4%，顯示投資人結構同時朝高齡化與年輕化兩端擴散（工商時報，2026）。同時，證交所統計顯示 2026 年 8 月電子式交易占市場成交比重達 80.38%（筆數）／80.43%（金額），反映交易通路高度數位化（臺灣證券交易所，2026）。在此背景下，數位券商已具備完整的線上使用者行為追蹤能力，但基金等理財商品之個人化推薦服務仍相對不足，形成本研究之市場機會。

台灣基金市場現況：根據中華民國證券投資信託暨顧問商業同業公會（SITCA）統計，台灣境內基金總規模持續創新高，截至 2025 年 10 月底突破 10.9 兆元，創歷史新高（經濟日報，2025）。基金已成為台灣投資人資產配置之重要工具，惟基金商品數量與複雜度同步攀升——以本研究對象好好證券為例，其於 2019 年 9 月經金管會核准辦理金融科技創新實驗，2021 年 6 月正式完成沙盒實驗並改制為證券商，是全台首例以科技業身分合規經營基金業務之券商（自由財經，2021）；依好好證券內部資料，可交易共同基金型錄約達 4,000+ 檔。相較於股票交易，基金投資涉及風險等級、資產類別、計價幣別、配息方式等更多維度之商品屬性，投資人選擇難度更高，也更凸顯個人化推薦機制之必要性。

進一步從投資人規模與投資行為觀察，SITCA 官方新聞稿指出，截至 2025 年 8 月底，境內基金受益人數達 1,674 萬 1,699 人，較前月增加 0.85%（中華民國證券投資信託暨顧問商業同業公會〔SITCA〕，2025），顯示基金投資人基數龐大且持續成長，個人化推薦若能落地，具規模化效益。同時，投信投顧公會資料顯示，2026 年 7 月境內基金定期定額（SIP）投資人數達 56.6 萬人、扣款筆數超過 114 萬筆，雙創歷史新高（中國時報，2026），反映「長期、持續性」的基金投資行為正快速擴大。此類定期定額投資人之風險偏好與資金能力可能隨時間變化，

凸顯建立可隨投資人行為動態調整之個人化推薦機制的必要性，而非僅依賴一次性、靜態的商品推薦。

投資人面臨資訊過載、個人化服務不足：依資產管理人才培育與產業發展基金委託之《2021 基金投資人投資行為與偏好問卷調查分析》，投資人在選擇基金資訊管道與交易平台時，高度仰賴平台提供之資訊完整性與便利性（鄭天澤等，2021）。然而，以本研究對象好好證券為例，承前所述之 4,000+ 檔型錄規模，遠超過一般投資人可自行比較、篩選之能力範圍，容易造成資訊過載，若僅依賴熱門排行榜等靜態推薦方式，難以滿足不同風險偏好與投資行為投資人之差異化需求。

網站使用者行為資料 × 交易資料整合作為解方的技術背景：隨著數位券商累積大量網站／App 使用者行為資料（可能透過 GA4、BigQuery 或內部資料庫蒐集），加上既有之基金交易紀錄，兩者具備 user_id 層級串接之技術可行性。此雙軌資料若能整合為投資人行為特徵，將可作為投資人分群與個人化推薦模型之基礎，是本研究採用「投資人分群 + 推薦模型」作為解決方案之技術背景。

1.2 研究問題

- **RQ1（分群識別）：**如何整合網站使用者行為資料、基金交易資料與用戶屬性資料，針對研究期間內有基金交易記錄之投資人，建立具商業意義的投資人分群？
- **RQ2（推薦成效比較）：**相較於熱門推薦（baseline）、內容導向推薦與協同過濾（ALS 隱性回饋矩陣分解）等基準模型，導入分群輔助之個人化基金推薦，是否能在 Precision@K、Recall@K、MAP 等指標上提升推薦成效？
- **RQ3（群體間差異）：**不同投資人分群，從分群輔助之個人化推薦中所獲得的成效提升，是否存在顯著差異？

1.3 研究目的

- **目的 1（對應 RQ1）：**整合網站使用者行為資料（可能結合 GA4、BigQuery、內部資料庫等來源）、基金交易資料與用戶屬性資料，針對研

究期間內有基金交易記錄之投資人，建立可解釋、具商業意義的投資人分群模型，作為後續個人化推薦之基礎。

- **目的 2（對應 RQ2）：**依序建立熱門推薦、內容導向推薦、協同過濾（ALS 隱性回饋矩陣分解）與分群輔助 CF 四種推薦模型，並以 Precision@K、Recall@K、MAP 等指標比較各模型成效，驗證分群輔助 CF 相較於基準模型是否具有增量效果。
- **目的 3（對應 RQ3）：**分析不同投資人分群在分群輔助推薦下的成效提升幅度，探討個人化推薦效益是否因投資人群體而異，作為未來差異化推薦策略之依據。

1.4 研究範圍與限制

研究範圍

- **研究場域：**好好證券（數位券商）之基金投資服務平台
- **研究對象：**研究期間內有基金交易記錄之投資人。此為分群（RQ1）所涵蓋之對象範圍；推薦模型評估（RQ2、RQ3）因採訓練期／測試期時間切分設計，實際評估對象進一步縮限為「訓練期與測試期皆有交易紀錄」之投資人子集合，範圍界定與可能之樣本縮減幅度詳見下方「研究限制」與第三章 3.7.1
- **研究期間：**最近 12–18 個月（暫定 2024/10 – 2026/03，實際區間依資料取得狀況調整）
- **商品範圍：**共同基金，可交易型錄約 4,000+ 檔
- **資料來源：**網站使用者行為資料（可能結合 GA4、BigQuery、內部資料庫等來源）、基金交易資料、投資人基本屬性資料（如 KYC 風險等級）
- **方法範圍：**投資人分群（K-prototypes，K-means 僅作為方法論對照，不納入正式分群結果與比較實驗，詳見第三章 3.5）+ 四種推薦模型（熱門推薦、內容導向推薦、協同過濾／ALS 隱性回饋矩陣分解、分群輔助 CF）之比較評估

研究不包含（不做事項清單）

1. 不建立完整 robo-advisor 系統（不含自動下單、資產配置、再平衡等功能）
2. 不做基金報酬／績效預測，不對未來投資報酬提供預測或保證
3. 不開發全新演算法，聚焦既有方法（K-prototypes、ALS 等）之組合應用與特徵工程設計
4. 不涵蓋共同基金以外之金融商品（如股票、ETF、保險等）
5. 不進行即時線上推薦系統開發與部署，僅做離線實驗與評估
6. 不做跨平台／跨券商比較，僅以好好證券單一平台資料為範圍

研究限制

- **資料隱私限制：**僅能使用公司提供之匿名化／去識別化資料，無法取得使用者真實身份資訊，可能影響部分行為特徵之精細度
- **研究期間限制：**僅涵蓋近 12–18 個月資料，可能無法涵蓋完整市場週期（如牛熊市轉換），分群與推薦結果可能受此期間特殊市場環境影響
- **資料完整性限制：**網站使用者行為資料（如經由 GA4／BigQuery 蒐集）可能存在追蹤遺漏之情形；跨裝置識別問題可部分解決——第三章 3.4.1 節規劃以使用者登入事件建立跨裝置之識別碼對照，使同一投資人於不同裝置登入後之行為得以歸戶至同一帳戶，惟殘餘限制有二：(1) 使用者於訓練期內從未登入即完成之匿名瀏覽行為仍無法歸戶；(2) 若裝置為多人共用（如家用電腦），為避免誤將他人行為歸戶至登入者，規劃僅回溯歸戶與登入事件同一連續造訪（session）內之匿名行為，不回溯歸戶該裝置之其他歷史瀏覽，故仍會有部分匿名行為資料無法完整歸戶，影響行為特徵之準確性
- **模型泛化性限制：**分群與推薦模型基於單一平台、單一商品類型（共同基金）資料訓練，結果可能不完全適用於其他券商平台或其他金融商品
- **研究對象限制：**僅涵蓋「研究期間內有交易記錄」之用戶，未涵蓋僅瀏覽未交易之潛在客群，可能造成樣本偏誤（survivorship bias）
- **評估樣本進一步縮限之限制：**第三章 3.7.1 為避免資料洩漏，採訓練期／測試期時間切分設計，推薦模型之評估對象須同時滿足三層條件：(1) 訓練

期有交易紀錄；(2) 測試期有交易紀錄；(3) 測試期之交易須至少包含一檔訓練期未持有之「新基金」（而非全數為既有持股之複購或定期定額續扣），此第三層條件呼應 3.7.1 節「ground truth 排除複購」之定義而生——若僅要求測試期有交易紀錄，測試期僅續扣舊有定期定額之使用者雖有交易紀錄，其 ground truth（新基金購買）仍為空集合，Recall 分母仍為零，此為本研究刻意排除之情形。三層條件之交集，較僅「訓練期與測試期皆有交易紀錄」之範圍更窄。基金投資屬低頻交易行為（相較股票交易，申購週期通常以月甚至季計），且定期定額投資人之測試期交易可能全數為既有基金之續扣，此一三層縮限之樣本流失幅度可能不小，將使推薦模型之評估結果聚焦於「持續嘗試新基金之相對活躍投資人」，對於僅維持既有定期定額、交易頻率較低或已流失之投資人，本研究結果之外推適用性須保守看待，實際縮減比例將於第四章資料集描述中揭露

1.5 研究流程

本研究流程共分八個步驟（正式排版時建議繪成流程圖）：

1. **問題界定與研究設計**：確認研究題目、範圍、不做事項與推薦模型組合方向
2. **文獻探討與研究缺口確認**：整理投資人分群、RFM、推薦系統與數位券商相關文獻，界定研究定位
3. **資料蒐集**：取得研究期間內網站使用者行為資料（GA4／BigQuery／內部資料庫）與基金交易資料
4. **資料前處理與特徵工程**：清理缺值、計算 RFM 與行為特徵、進行標準化
5. **投資人分群**：以 K-prototypes 建立分群模型（K-means 僅作方法論對照），選定最佳 K 值並為各群體命名
6. **個人化推薦模型建置**：依序建立熱門推薦、內容導向推薦、協同過濾（ALS）、分群輔助 CF 四種模型
7. **模型評估與比較分析**：以 Precision@K、Recall@K、MAP 比較各模型成效，分析不同分群間之效益差異
8. **結論與建議撰寫**：整理研究發現、學術貢獻、實務應用建議與研究限制

1.6 論文架構說明

本論文共分五章。**第一章緒論**說明研究背景與動機、研究問題與目的、研究範圍與限制，並概述研究流程與論文架構。**第二章文獻探討**依序回顧投資人行為與數位金融文獻、投資人／顧客分群方法與 RFM 機器學習分群文獻並整合小結，接續探討個人化推薦系統與 FinTech 數位券商應用相關文獻，最後彙整現有研究之缺口。**第三章研究方法**說明研究架構與流程、資料來源與前處理方式、投資人分群方法（K-prototypes，K-means 僅作方法論對照），以及熱門推薦、內容導向推薦、協同過濾（ALS）與分群輔助 CF 四種個人化推薦模型之設計，並定義 Precision@K、Recall@K、MAP 等評估指標。**第四章實驗結果與分析**呈現資料集描述、投資人分群結果、各推薦模型之實驗結果，以及分群輔助推薦相較基準模型之效果比較。**第五章結論與建議**總結研究發現、說明學術貢獻與實務應用建議，並說明研究限制與未來研究方向。

第二章 文獻探討

2.1 投資人行為與數位金融

1. 研究主題演進

投資人行為研究早期多建立於行為財務學理論，核心關注投資人在不確定情境下為何未必依循傳統效用最大化假設進行決策，而是受到心理與認知因素影響，形成偏離完全理性之投資決策。吳忠義（2008）以國內某商業銀行大台北、新竹、台中、高雄地區之財富與非財富客群為對象的實證研究，具體示範了這種非理性的樣貌：該研究依風險承受度將投資人分為保守、穩健、積極三級，商品亦依風險分為對應三級，並檢驗兩者是否一致。結果顯示，保守型與穩健型投資人的商品偏好大致符合其風險屬性，但**積極型投資人理論上應偏好積極型（第三級）商品，實際上卻有 65% 偏好穩健型（第二級）商品**，兩者出現顯著落差；同樣的落差也出現在「專業人士」這個目標客群——其行為風險屬性被歸類為積極，商品偏好卻趨於保守。這個反直覺的發現說明：僅憑問卷測得的風險屬性宣稱，未必能準確預測投資人的實際商品選擇，「宣稱偏好」與「實際行為」之間存在系統性缺口。

近十年來，隨著行動交易平台、數位券商、投資 App、社群媒體與金融科技服務快速發展，投資人行為研究逐漸由「投資人是否理性」延伸至「數位介面與平台機制如何形塑投資行為」，也開始出現以數位足跡取代靜態問卷、動態捕捉投資人心理狀態的研究路線。許信輝（2023）以台灣上市大型公司 2012 年 7 月至 2022 年 6 月共十年之週資料，將 Google 搜尋趨勢指數（Search Volume Index, SVI）作為投資人情緒的代理變數，透過 Hansen（1999）縱橫門檻迴歸模型發現：SVI 對股票報酬的影響存在單一門檻（門檻值 -4.8086%）——當股票報酬跌破此門檻（大跌）時，搜尋量越高、報酬跌得越深，反映投資人的「恐慌搜尋」；報酬未跌破門檻的一般情況下，搜尋量越高、報酬反而越高，反映「順勢搜尋」。此外，SVI 與報酬交乘後，對股價波動風險呈現收斂效果，顯示投資人關注度的提升有助於降低資訊不對稱對波動風險的衝擊。這項研究證實：投資人的網路搜

尋行為本身即可作為傳統問卷或帳戶靜態屬性之外的**動態、即時的投資人意圖代理變數**。

因此，本類文獻的演進可概括為三個階段：第一，從行為財務觀點辨識投資人心理偏誤與交易決策偏差，吳忠義（2008）之研究即屬此類，以橫斷面問卷指出「宣稱風險偏好」與「實際商品選擇」的落差；第二，納入線上交易與數位金融服務情境，分析科技使用如何改變投資流程；第三，進一步關注平台資料、使用者互動與即時行為軌跡，如許信輝（2023）以搜尋量作為情緒代理變數，將投資人行為視為可被資料化、分群化與個人化服務設計所回應的研究對象。

2. 常見資料來源

投資人行為與數位金融相關研究常見資料來源，可由既有文獻的實際設計具體歸納：

- **問卷調查資料**：吳忠義（2008）以 S 商業銀行大台北、新竹、台中、高雄地區之財富與非財富客群為對象，發出 430 份問卷、回收 201 份、有效 190 份（有效回收率 44.19%），問卷分五部分（個人資料、投資人風險屬性、投資商品風險屬性、共同基金相關訊息與投資行為、政治經濟相關訊息與投資行為），並將受訪者依職業區分為公教人員、公司領薪員工（已婚／單身）、退休、家管、專業人士六類目標客群。
- **市場與搜尋行為資料**：許信輝（2023）以臺灣經濟新報（TEJ）資料庫取得財務資料，並以 Google Trends 取得 Google 搜尋趨勢指數（SVI），樣本為台灣上市資本額百億元以上公司（不含金融股）共 82 家、2012 年 7 月至 2022 年 6 月共十年之週資料，每間公司 517 筆觀察值；作者說明排除中小型股之原因為其 SVI 資料多為 0（股東人數與流通量較少），採週資料而非日資料亦是為避免早期日頻 SVI 大量為 0 的問題。
- **質性觀察與平台介面資料**：Tan, G. K. S.（2020）採參與者－觀察者（participant-observer）研究法，以真實付費投資人身分開立並實際出資新加坡四家 robo-advisor 帳戶（AutoWealth、StashAway、Kristal.AI、MoneyOwl），完整經歷 KYC 風險評估問卷、投資組合建立、帳戶儀表板互動與客服溝通等流程，並輔以線上財經論壇討論串、業者行銷素材與監理機關文件作為佐證資料。

既有研究中，問卷調查（吳忠義，2008）與市場層級的公開財務／搜尋資料（許信輝，2023）仍是最常見的兩類來源；相較之下，將個別投資人層級的網站行為資料、App 使用資料與實際交易資料整合分析的研究相對有限。此一現象與本研究欲結合數位券商平台行為資料及基金交易資料的研究設計具有直接關聯。

3. 常用方法

本類文獻之研究方法可依上述三篇文獻具體歸納為三類：

- **問卷統計分析：**吳忠義（2008）以 Cronbach's α 信度分析檢驗問卷一致性（各構面 α 介於 0.610~0.731），以敘述性統計描述人口統計變數分布，再以卡方列聯表檢定投資人屬性、商品屬性與人口變數之關聯性，並以多變量變異數分析（MANOVA）檢視共同基金及政治經濟相關訊息對不同風險等級投資人的影響。
- **縱橫資料迴歸與門檻模型：**許信輝（2023）先以 F 檢定（固定效果 vs. 混合迴歸）、LM 檢定（隨機效果 vs. 混合迴歸）、Hausman 檢定（固定效果 vs. 隨機效果）之序列邏輯選擇最適縱橫資料模型設定；進一步以 Hansen（1999）縱橫門檻迴歸模型（Panel Threshold Regression）檢驗 SVI 對報酬的影響是否存在門檻效果，並以 Engle（1982）ARCH／Bollerslev（1986）GARCH(1,1) 模型估計股價條件變異數，作為衡量股價波動風險之應變數。
- **質性民族誌方法：**Tan, G. K. S.（2020）以民族誌式的參與觀察，記錄 robo-advisor 帳戶開立、風險評估問卷、投資組合建立與儀表板互動之實際使用歷程，並輔以文本分析（官網行銷素材、監理文件、線上論壇討論）交叉檢視演算法如何形塑投資人主體性。

三類方法分別對應「靜態橫斷面問卷」（吳忠義，2008）、「動態縱橫時間序列」（許信輝，2023）與「質性深度個案」（Tan, G. K. S., 2020）三種不同的研究取徑，顯示投資人行為與數位金融領域的方法論日趨多元，也共同指向本研究應同時掌握投資人的靜態屬性與動態行為訊號，而非僅依賴單一時間點的問卷測量。

4. 主要發現

綜合吳忠義（2008）與許信輝（2023）兩篇文獻，可見投資人行為具有高度異質性，且投資決策不僅受產品報酬與風險影響，也受到心理偏誤、資訊呈現方式、

市場情緒與過往投資經驗影響：前者以橫斷面問卷證實「積極型投資人實際偏好穩健型商品」的靜態落差，後者以十年期縱橫資料證實投資人的搜尋行為會隨股價漲跌呈現「恐慌搜尋」與「順勢搜尋」兩種動態非線性反應。兩篇研究雖分析單位不同（前者為個別投資人問卷、後者為公司層級搜尋量與報酬），但共同指向同一個結論：投資人「宣稱」或「理論上應有」的行為，與其實際反應之間，存在系統性、可觀測的落差，這正是本研究不以靜態風險屬性問卷作為分群唯一依據、而須納入交易與平台行為資料的立論基礎。此外，Tan, G. K. S. (2020) 以新加坡機器人理財顧問（robo-advisor）市場之質性研究進一步指出，演算法與現代財務理論常以「客觀理性」包裝推薦結果，但投資人對推薦邏輯的理解程度有限，形成透明度與信任落差；此一發現提醒本研究在設計推薦系統時，應同時考量推薦結果的可解釋性，而非僅追求準確度指標。

在數位金融環境下，平台降低交易門檻並提升資訊即時性，可能改善投資便利性與服務可及性，但也可能如許信輝（2023）所示，提高投資人因搜尋熱度而產生過度樂觀或過度悲觀反應的風險。對金融機構而言，若僅以單一產品銷售或傳統人口統計變數理解投資人，容易忽略投資人在數位平台上的行為差異。因此，整合交易資料與平台行為資料，並據此建立更細緻的投資人分群，有助於提升投資服務的適切性與個人化程度。

5. 與本研究之關聯

本研究題目聚焦於「應用投資人分群與個人化推薦模型於數位券商基金投資服務」，因此投資人行為與數位金融文獻提供三項基礎。第一，吳忠義（2008）「宣稱風險偏好與實際商品選擇不一致」的發現，說明投資人並非同質且完全理性，支持本研究將投資人依行為特徵（而非僅風險屬性問卷）進行分群。第二，許信輝（2023）以搜尋量作為情緒代理變數的研究設計，支持本研究納入網站或 App 行為資料作為投資人分群特徵，而非僅以交易紀錄衡量投資人；其發現之門檻式非線性反應，也提醒本研究在特徵工程階段應考量投資人對行為訊號的反應可能因情境（如近期報酬正負）而異。第三，Tan, G. K. S. (2020) 對演算法透明度與投資人信任的討論，支持本研究在建立基金推薦模型時，同步考量推薦結果的可解釋性，並檢驗其相對於熱門推薦或傳統推薦方式的效果。

換言之，本類文獻可作為第二章中說明研究背景與問題意識的基礎：數位券商不只是交易通路，而是能持續蒐集投資人行為訊號並提供個人化服務的平台；投資人行為分群則是將行為財務洞察轉化為可操作服務模型的重要中介。

2.2 投資人／顧客分群相關文獻

承上，既有投資人行為文獻說明投資人具有心理與行為異質性，本節進一步整理將此異質性轉化為可操作分群結果的兩類文獻：一般性之投資人／顧客分群方法（2.2.1），以及本研究採用之 RFM 與機器學習分群取徑（2.2.2）。

2.2.1 投資人／顧客分群方法

1. 研究主題演進

顧客分群研究源於市場區隔理論，早期多以人口統計、地理區域、所得、生活型態與消費金額作為分群基礎，目的在於協助企業辨識不同顧客群體並制定差異化行銷策略。在金融服務領域，顧客分群常用於客戶價值管理、交叉銷售、風險管理、流失預測、產品推薦與關係管理。傳統分群方式較依賴靜態屬性，例如年齡、收入、資產規模與風險屬性，雖具備管理上的可解釋性，但對於動態投資行為與數位互動模式的掌握較為不足。

近十年來，隨著金融機構累積大量交易資料、互動資料與數位足跡，顧客分群研究逐漸轉向資料驅動與機器學習方法，研究焦點由「事先定義區隔」轉為「從資料中辨識潛在群體」。Aliyev et al.（2020）以亞塞拜然 Unibank 之真實客戶交易資料為例，具體示範了這個轉向：作者原先同時嘗試以年齡、性別、地區、收入等人口統計變數搭配 K-Modes 進行分群，但效果不理想，最終捨棄人口統計路線、完全聚焦於以交易資料驅動的行為分群。這個「人口統計分群失敗、行為分群奏效」的實證案例，直接支持本研究以交易與平台行為資料（而非問卷式風險屬性）作為投資人分群依據之合理性。

Tan, E. H. L. et al.（2025）則以馬來西亞衍生性商品市場（Bursa Malaysia Derivatives）約 1,100 萬筆交易紀錄，示範資料驅動分群如何應用於金融市場監理與投資人保護：其研究動機明確指出，傳統依賴 KYC 問卷等靜態屬性的投資人分類，缺乏以實際交易行為驅動的動態刻畫能力，而大規模交易行為資料提供了

以資料驅動方式建立投資人輪廓（investor profiling）的機會。這與本研究欲整合網站行為資料與基金交易資料、建立可解釋投資人分群的問題意識高度一致。

在投資與財富管理情境中，投資人分群進一步涉及風險承受度、投資目標、商品偏好、交易行為、資訊搜尋行為與顧問服務需求。相較於一般零售顧客，投資人分群必須兼顧金融商品的風險屬性、法規適合度與投資人保護，因此不能僅以購買金額或活躍程度作為分群標準。

2. 常見資料來源

投資人／顧客分群研究常見資料來源，同樣可由 Aliyev et al.（2020）與 Tan, E. H. L. et al.（2025）之實際設計具體歸納：

- **銀行原始交易資料：**Aliyev et al.（2020）使用亞塞拜然 Unibank 之真實客戶交易紀錄，原始欄位包含持卡人、交易編號、交易金額與交易日期；資料品質不佳，含重複值（因交易編號重複而需去重）、低相關特徵已移除、缺值以平均值填補，反映真實銀行資料常見的前處理挑戰。
- **大規模衍生性商品交易資料：**Tan, E. H. L. et al.（2025）使用馬來西亞交易所（BURSA Malaysia）2022 年 1 月至 12 月單一年度之 FCPO（粗棕櫚油期貨）與 FKLI（吉隆坡股市指數期貨）兩項商品共 1,100 萬餘筆交易紀錄，以「券商參與者 ID → 投資人 ID → 帳戶 ID」階層優先順序之雜湊主鍵，彙整為 9,852 個唯一帳戶（對應 8,816 位不重複投資人、13 家券商參與者），扣除 79 個無已實現損益之主鍵後，最終 **9,773 筆帳戶層級資料**進入分群分析；六項工程特徵分別為總交易筆數、總交易金額、總已實現損益、平均投資報酬率、帳戶年資與持倉天數中位數（皆為帳戶層級之彙整指標，而非原始逐筆交易欄位）。
- **靜態人口統計屬性（對照組）：**Aliyev et al.（2020）亦嘗試以年齡、性別、地區、收入等人口統計變數進行分群，但發現分群效果不理想，最終捨棄此路線，僅保留行為交易資料作為主要分群依據——此一「嘗試後放棄」的過程本身即是資料來源選擇的重要參考。

現有研究在銀行與衍生性商品市場情境中，皆顯示交易行為資料比靜態人口統計屬性更能有效驅動分群；在數位券商情境下，若能進一步整合網站行為、商品瀏

覽、基金篩選、觀察清單與實際基金申購資料，將能更完整描述投資人從資訊搜尋到投資決策的歷程。

3. 常用方法

投資人／顧客分群方法可區分為規則式、統計式與機器學習式三類，其中機器學習式分群之效能與適用性差異，可由 Aliyev et al. (2020) 與 Tan, E. H. L. et al. (2025) 的實際比較具體說明：

- **規則式分群**：依管理者經驗或業務規則設定分群條件，例如高資產客戶、活躍交易者、沉睡客戶、新手投資人、保守型投資人等。此方法可解釋性高，但容易受主觀假設限制。
- **統計式分群**：包含因素分析、主成分分析、層級分群、K-means (MacQueen, 1967)、兩階段分群與潛在類別分析。Aliyev et al. (2020) 實際比較 K-means、DBSCAN 與階層式分群三種演算法：K-means 計算效率最高（複雜度 $O(nkd)$ ）；階層式分群雖能呈現群體結構，但複雜度達 $O(n^3)$ ，在大型資料集上不可行而遭放棄；DBSCAN 雖調參較困難，卻能有效識別交易金額或頻率異常大的高價值離群客戶。
- **機器學習式分群於大規模金融資料之應用**：Tan, E. H. L. et al. (2025) 以 K-means 對 1,100 萬筆真實交易資料進行分群，並在前處理階段以反雙曲正弦轉換 (IHS) 處理金融交易資料常見的嚴重右偏分佈問題，避免高值樣本主導群心距離計算；最佳群數則以手肘法 (Elbow Method, Thorndike, 1953)、輪廓係數 (Silhouette Score, Rousseeuw, 1987)、Davies-Bouldin Index (Davies & Bouldin, 1979) 與 Calinski-Harabasz Index (Caliński & Harabasz, 1974) 四項指標綜合收斂判斷，最終確定 $k=5$ 。許仲廷 (2022) 則以台灣統一證券真實客戶資料，從三大財管業務（保代、海外市場、財富管理）之 K-means 分群出發，再比較 K-means 與 K-prototype (Huang, 1997) 兩種方法：因年齡與證券成交金額尺度差異過大，直接以歐氏距離為準則的 K-means 不適合處理年齡變數，作者以 ANOVA 檢定驗證分群變數之顯著性，結果顯示 K-prototype（將年齡編碼為類別變數後併入分群）在 1% 顯著水準下全部變數顯著，優於 K-means 僅 5% 水準顯著，另以卡

方檢定驗證類別變數顯著性，兩相比較後才確定採用 **K-prototype**，而非一開始即以 **K-prototype** 分群。

在金融服務應用中，模型的可解釋性尤其重要。若分群結果無法轉譯為業務可理解的投資人輪廓，將難以支援後續服務策略。因此，近年研究常將資料驅動分群與 RFM、客戶價值、風險屬性或產品偏好標籤結合，以提升分群結果的管理意義。

4. 主要發現

既有研究普遍指出，資料驅動分群能比單一人口統計分類更有效揭示顧客行為差異。例如同一年齡或所得區間的投資人，可能在交易頻率、基金偏好、風險承擔、資訊搜尋與平台互動上具有顯著差異；反之，不同人口統計背景的投資人也可能因相似行為模式而屬於同一服務區隔。

分群研究亦顯示，不同分群方法各有優缺點。**K-means** 具備效率高、易實作與結果易解釋等優點，但需事先指定群數且對尺度與離群值敏感；層級分群有助於呈現群體結構，但 Aliyev et al. (2020) 指出其計算複雜度達 $O(n^3)$ ，在大型資料集上計算成本過高而不可行；GMM 能處理重疊群體，較符合顧客行為可能不完全分離的情境，但解釋性與參數估計要求較高。值得注意的是，Aliyev et al. (2020) 進一步指出，密度式分群 (DBSCAN) 雖在高維度資料上調參困難，卻擅長辨識「離群值」——其研究發現，交易金額與頻率異常高的離群樣本，實際上正是銀行最有價值的貴賓客戶，這是單純 **K-means** 較難自然捕捉到的洞察，對本研究後續處理極端交易行為投資人（如高資產大戶）具有參考價值。

然而，既有顧客分群研究仍常以一般零售、銀行存款、信用卡或電商交易為主要場景，直接針對台灣數位券商基金投資服務的研究相對不足。此一論述必須先正視最貼近的既有研究：許仲廷 (2022) 以台灣統一證券真實客戶資料，從財富管理、保代、海外市場三大業務之 **K-means** 分群出發，比較 **K-means** 與 **K-prototype** 後（**K-prototype** 在 1% 顯著水準下全部變數顯著，優於 **K-means**）採用 **K-prototype** 建立客戶素描，並以羅吉斯迴歸分類預測新開戶客戶購買大財管商品的機率，是目前**唯一**直接以台灣券商真實資料進行分群的公開研究，且方法論（混合型變數分群、分群後接分類模型）與本研究高度相似。但許仲廷 (2022) 的分類模型輸出僅止於「會不會買」的二元機率，並未建立排序型的推薦清單，也未以 **Precision@K**、**Recall@K** 或 **MAP** 等指標評估推薦成效，且分類目標是大財

管商品整體而非個別基金；此外，許仲廷（2022）亦坦言其分群結果之顯著變數逐年變化，靜態模型的泛化性有限。這正是本研究與許仲廷（2022）之研究的關鍵差異所在：本研究在分群之後進一步建構並比較熱門推薦、內容導向推薦、協同過濾與分群輔助 CF 四種個人化推薦模型，並以標準的 Top-K 推薦評估指標驗證分群對推薦成效的增量貢獻，是許仲廷（2022）尚未觸及的下一步。Tan, E. H. L. et al.（2025）之研究則雖以衍生性商品市場之大規模真實交易資料建立投資人輪廓，並以決策樹驗證分群之可解釋性與內部一致性，但其研究對象為衍生性商品交易者，作者亦於研究限制中指出，分群結果能否遷移至持有期間更長、交易頻率較低的共同基金投資人，仍待進一步驗證——此一缺口正是本研究以共同基金投資人為對象的定位所在。

5. 與本研究之關聯

本研究可承接投資人／顧客分群文獻，將分群定位為個人化基金推薦之前置步驟。具體而言，本研究若整合投資人基本屬性、基金交易紀錄與數位平台行為資料，即可從「誰是投資人」與「投資人買了什麼」進一步延伸至「投資人如何搜尋、比較與接觸基金資訊」。此種分群設計有助於建立更貼近數位券商服務情境的投資人輪廓。

此外，分群結果亦可作為推薦模型的特徵或策略基礎。例如不同群體可採用不同推薦邏輯：對新手或低活躍投資人，可重視風險適配與教育型內容；對高活躍投資人，可重視商品多樣性、過往偏好與再平衡需求；對潛在流失投資人，可重視喚回與低門檻基金服務。此一連結使分群不僅是描述性分析，而能轉化為基金推薦服務設計的實證基礎。

2.2.2 RFM 與機器學習分群

1. 研究主題演進

RFM 模型由 Arthur Hughes 提出（原始出處見於陳一慈（2021）、鄭婕妤（2010）之文獻回顧引用，本研究以次級引用方式處理），以最近一次行為時間（Recency）、行為頻率（Frequency）與金額價值（Monetary）衡量顧客價值，是顧客關係管理與直效行銷中常見的行為分群工具；傳統作法多依 Miglautsch

(2000) 之顧客五等分法，將 R、F、M 三構面各自排序後均分為五等分、賦予 1 至 5 分並加總，形成高低忠誠度之判斷依據。Christy et al. (2021) 之研究即採用此一標準五分位評分法（如原文 Table 3 所示，Recency 7/30/90/180/365 天分別對應 5 至 1 分），並未提出新的排名方式；其實質貢獻在於分群演算法本身——作者指出傳統 K-Means 隨機選取初始群心的作法會導致分群品質不穩定，因此提出「RM K-Means (Repetitive Median based K-Means)」：將 R、F、M 排序後依群數切分區段、以各區段中位數作為初始群心，取代隨機初始化。

然而，Aliyev et al. (2020) 以亞塞拜然 Unibank 之真實客戶交易資料指出，傳統 RFM 五分位評分法存在鑑別力不足的根本限制：由於 R、F、M 各切五個分位，理論上僅有 $5^3 = 125$ 種分數組合，只要樣本數夠大，無論資料實際分佈為何，分群結果的組合圖形恆定，代表這種評分法本質上只是「粗略估計」。作者因此主張捨棄離散的 RFM 評分卡，改將 R、F、M 的連續數值直接作為特徵，餵入非監督式機器學習演算法進行分群，藉此保留資料中真實的分佈資訊與鑑別力。須說明的是，此篇為 arXiv 預印本、非同儕審查文獻，屬 ADA University 學生專題報告性質，方法交代清楚但未使用 Silhouette Score 等量化指標驗證分群品質，引用層級應作為補充佐證，不宜單獨作為核心設計主張的唯一支撐。所幸「離散評分卡本身鑑別力有限」這個結論，與陳一慈 (2021) 之發現方向一致：陳一慈 (2021) 以電商交易資料實證指出，Frequency 與 Monetary 若採機械式五等分，會因分布極度懸殊（如 78% 顧客僅消費一次）而失真，須依實際分布調整級距——這與 Aliyev et al. 之連續數值主張，同樣是在批判機械式等分位切分本身的鑑別力問題，兩篇合觀已足以支撐特徵工程設計方向。須特別澄清：Christy et al. (2021) 之研究採用的正是標準固定門檻五分位評分法（詳見原文 Table 3），並未提出改良排名法或對機械式評分卡提出批判。這個共識直接影響本研究的特徵工程設計：本研究應避免機械式的等分位離散化，優先採用連續型 RFM 數值或依實際分布調整之級距作為分群輸入。

近年研究進一步將 RFM 與機器學習分群結合，不再僅依固定規則切分 RFM 分數，而是搭配 K-means、Fuzzy C-Means、DBSCAN、階層式分群或自組織映射圖網路 (Self-organizing Map, SOM) 等方法，自動辨識行為相似的顧客群體。鄭婕妤 (2010) 即提出「RFM+SOM」的分層混合設計：先以 RFM 五等分法界定顧客忠誠度高低，再依忠誠度施以差異化策略——對高忠誠度顧客，以其產品購買週

期建立「產品推薦區間 (Product Recommender Interval, PRI)」預測下次購買時機；對低忠誠度、資料較稀疏的顧客，則先以 SOM 進行非監督式分群，找出行為相近的群體後再行推薦。此一「先分群、再分策略」的設計理念，說明 RFM 與機器學習分群並非互斥，而可視資料特性分層並用。

在金融服務領域，RFM 與機器學習分群常被用於銀行顧客區隔、投資人交易行為分群與客戶價值分析。對基金投資服務而言，RFM 的概念可由一般購買轉化為投資行為：Recency 可表示最近一次基金申購、贖回、瀏覽或互動；Frequency 可表示申購次數、登入或瀏覽基金頁次；Monetary 可表示投資金額、資產規模或基金持有價值。此一轉化使 RFM 能成為投資人行為分群的可操作框架。

2. 常見資料來源

RFM 與機器學習分群研究常見的資料來源與規模差異甚大。陳一慈 (2021) 以 Kaggle 公開之電商美妝日用品交易資料為例，原始資料達 2,069 萬筆、涵蓋 2019 年 10 月至 2020 年 2 月共 5 個月，經前處理後保留 128 萬餘筆、對應 11 萬餘位不重複顧客；Tan, E. H. L. et al. (2025) 則使用馬來西亞 BURSA 交易所 FCPO、FKLI 兩項商品約 1,100 萬筆真實交易紀錄，彙整為總交易筆數、總交易金額、總已實現損益、平均 ROI、帳戶年資、持倉天數中位數六項帳戶層級特徵，最終進入分群分析者為 9,773 筆帳戶（詳見前段說明）。相對地，鄭婕妤 (2010) 使用的 Foodmart2000 交易資料庫規模較小，僅 2,780 位顧客、12 萬餘筆交易；Aliyev et al. (2020) 之 Unibank 銀行交易資料亦屬中小規模且品質參差（含重複值、需以平均值填補缺值）。

上述文獻顯示，公開資料集多以電商交易或中小型銀行資料為主，金融投資場景（尤其是共同基金）之大規模行為資料公開可得性甚低，仍高度仰賴機構內部資料。這也凸顯本研究若能取得數位券商基金平台之內部交易與網站行為資料，將有機會補足既有文獻在「基金投資情境」上的實證缺口。

3. 常用方法

RFM 特徵建構：依資料分佈調整級距，而非機械式等分

陳一慈 (2021) 在建構 RFM 三構面時，並未對所有構面採取機械式的五等分：由於 Recency 分佈較為均勻，採等距切分（以 30 天為一組距）；但 Frequency 與

Monetary 因分佈極度懸殊（如僅消費一次者占比高達 78%），改依實際資料分佈自訂級距。此一設計提醒本研究：基金投資人之申購頻率與投資金額分佈同樣可能高度偏態，RFM 級距切分不宜直接套用等分法，而應依實際資料分佈調整。Christy et al.（2021）進一步指出，R 構面在賦分方向上與 F、M 相反——最近購買天數越小，代表顧客越活躍，賦分時須反轉方向，此一細節在特徵工程階段須特別留意。

分群演算法比較：K-means、Fuzzy C-Means、RM K-Means、DBSCAN 與階層式分群

Christy et al.（2021）以 UCI Online Retail 公開資料集（英國線上零售商一年份交易紀錄，前處理後 772 筆）比較 K-means（硬分群）、Fuzzy C-Means（模糊分群）與作者自行提出的 **RM K-Means（Repetitive Median based K-Means）** 三種演算法，固定分群數 $k=10$ 。實驗結果（原文 Table 4）顯示：**Fuzzy C-Means 之平均輪廓寬度（0.43）明顯優於傳統 K-means（0.33）**，但代價是迭代次數（193 次 vs. 4 次）與執行時間（24.80 秒 vs. 2.00 秒）遠高於 K-means，效率明顯較差；而作者提出的 RM K-Means——以 R、F、M 排序後之分段中位數取代隨機值作為初始群心——在三項指標上全面勝出（迭代 2 次、耗時 1.49 秒、輪廓寬度 0.49），證實初始群心的選取方式對分群效率與品質皆有實質影響。這與坊間常見「K-means 計算效率高但品質普通、Fuzzy C-Means 品質較佳但成本高」的取捨並不衝突，但 Christy et al. 的貢獻具體指出：**透過改良初始化方式（而非更換演算法本身），可同時兼顧效率與品質**，此一設計思路對本研究之 K-prototypes 分群初始化具有直接參考價值（K-means 於第三章 3.5 僅作為方法論對照，不納入正式比較實驗）。Aliyev et al.（2020）則另外比較 K-means、DBSCAN 與階層式分群三種演算法：K-means 計算效率最高（複雜度 $O(nkd)$ ），適合快速建模；階層式分群計算複雜度達 $O(n^3)$ ，在大型資料集上不可行，作者因此放棄採用；DBSCAN 雖在高維度資料上調參困難，卻能有效偵測「離群值」，而其研究發現這些離群值往往正是交易金額或頻率異常大的高價值客戶——這是單純 K-means 較不易自然捕捉到的洞察。

在特徵前處理方面，Tan, E. H. L. et al.（2025）指出金融交易資料通常呈現嚴重右偏分佈（少數高頻大量交易者、多數低頻小量交易者），若直接以原始數值分

群，將使高值樣本主導群心距離計算而造成分群偏差。該研究採用反雙曲正弦轉換（Inverse Hyperbolic Sine Transformation, IHS）處理此一問題：相較於 log 轉換無法處理零值，IHS 轉換可同時處理零值與負值，並有效壓縮右尾極端值使分佈趨近常態，同時保留變數間的相對大小關係。這對本研究處理投資人交易金額、瀏覽次數等偏態行為特徵，提供了具體可行的前處理方案。

分群結果驗證

Tan, E. H. L. et al. (2025) 除以手肘法（Elbow Method, Thorndike, 1953）與輪廓係數（Silhouette Score, Rousseeuw, 1987）決定最佳群數外，更進一步以決策樹分類器驗證分群結果的可解釋性：將 K-means 分群標籤作為決策樹的目標變數進行訓練，若決策樹能以少數特徵高準確率重現分群結果，即代表分群具備內部一致性與可解釋性，同時可產出特徵重要性排名，協助理解哪些行為指標最能區分投資人類型。此一「決策樹驗證」作法，可作為本論文分群完成後向指導教授或口試委員展示分群可解釋性的具體方法。

核心先行研究：Thompson et al. (2021) 之 k-prototypes 與擴充版 RFM 分群

Thompson et al. (2021) 以加拿大某註冊投資交易商之真實資料（52,025 個帳戶、23,970 名客戶）為對象，提出擴充版 RFM 模型 **RFMP**（Recency、Frequency、Monetary、Profile，Profile 為 KYC 與帳戶衍生之靜態屬性），並以 **k-prototypes**（Huang, 1997）進行分群——因特徵同時包含數值型（年齡、交易金額）與類別型（性別、居住地、婚姻狀況）變數，距離公式為數值變數歐氏距離與類別變數簡單配對相異度之加總，與本論文第三章 3.5.3 節之混合距離設計原理一致；最佳分群數以 Silhouette 係數與 Davies-Bouldin score 交叉決定於 $k=5$ ，與本論文 3.5.4 節規劃之驗證指標組合亦高度一致。此篇同儕審查期刊論文之方法論堆疊（k-prototypes 分群+RFM 擴充特徵+KYC 屬性+統計檢定比較群間差異）與本論文重疊程度，是目前所讀文獻中最高者。

該研究最核心之發現為：**KYC 人口統計資訊（性別、居住地、婚姻狀況）對客戶交易行為之解釋力甚微，反而是交易頻率與金額等行為特徵最具資訊量（objective and subjective KYC data have little influence on trading behaviours）**。此一發現對本研究具雙重意涵：一方面正面支持本研究「行為資料優於靜態屬性」之前提，呼應本研究採用交易 RFM 與行為 RFM 雙軌特徵之設計方向；另一方面

也對本研究第三章 3.5.2 節之 KYC 特徵選用構成須正面回應之挑戰。本研究依鑑別力逐項評估公司提供之 KYC 欄位，並未照單全收——性別、年齡、職位因直接對應 Thompson et al. (2021) 之發現，判斷鑑別力有限，已排除於分群特徵之外，僅作第四章資料集描述之樣本輪廓統計使用；原規劃之「資產區間」實際並無對應欄位，改以年收入（連續數值）納入，且以連續數值直接參與距離計算，無須如類別化資產區間般承擔額外之鑑別力風險；僅風險等級（次序類別）與交易經驗／投資時長（次序類別，性質上為客觀行為衍生指標而非靜態人口統計）予以保留。換言之，本研究之特徵選用設計已較單純援用 KYC 全部欄位更能回應 Thompson et al. (2021) 之挑戰，惟風險等級仍屬使用者自陳之主觀屬性，其鑑別力是否確實不及行為特徵，仍待第四章實際分群結果驗證，此一風險已於第三章 3.5 節說明因應方式。

在群間差異之統計檢定設計上，Thompson et al. (2021) 以推斷風險容忍度分數為外部效度變數，先以參數 ANOVA 與無母數 Kruskal-Wallis 檢定 (Kruskal & Wallis, 1952) 雙軌並行檢定群體間分布是否有顯著差異，再以對應之事後檢定——Tukey's test (Tukey, 1949) 與 Dunn's test (Dunn, 1964)——找出具體差異之群體配對。此一「參數／無母數雙軌檢定＋對應事後檢定」之邏輯，與本論文第三章 3.7.4 節 RQ3 之統計檢定決策準則高度一致，為本論文方法選擇合理性之直接佐證；唯一差異在於本論文之比較對象是「分群輔助推薦相對 baseline 之效果提升幅度（ Δ 值）」，而非群體本身之外部效度變數，此為本論文相較 Thompson et al. (2021) 更進一步銜接至推薦成效驗證之延伸。

RFM 分群之外：購物籃分析作為交叉推薦的延伸

除 RFM 分群外，陳一慈 (2021) 同時以關聯規則 (Association Rules) 之 Apriori 演算法進行購物籃分析，從 40,772 件商品中找出 1,049 組具共同購買機率的產品組合，並以支持度 (support)、信賴度 (confidence) 與提升度 (lift) 三項指標判別組合強度，作為商品搭售與交叉銷售策略之依據。此一方法提供 RFM 分群以外的另一種顧客洞察視角：RFM 回答「誰是高價值顧客」，購物籃分析則回答「哪些商品經常被一起購買」。對本研究而言，此一思路可延伸為分析「常被同一投資人一起申購或持有的基金組合」，作為基金交叉推薦 (cross-sell) 之補充

依據，與 RFM 分群結果並用，但受限於研究範圍與時程，本研究以 RFM 分群與機器學習分群為主要方法，購物籃分析僅作為未來延伸方向。

4. 主要發現

綜合上述文獻，RFM 與機器學習分群研究呈現三項一致性發現。第一，RFM 評分方式的設計選擇（等分法是否依實際分佈調整、離散評分卡或連續數值）會實質影響分群品質與鑑別力，機械式的五等分評分卡在樣本夠大時容易失去鑑別力（Aliyev et al., 2020）。第二，分群演算法各有取捨：K-means 計算效率最高且結果易於解釋，是多數研究的預設選擇；但 Fuzzy C-Means 在分群品質（輪廓寬度）上可能優於 K-means，代價是迭代次數與運算時間大幅增加（Christy et al., 2021）；DBSCAN 則在辨識離群高價值客戶上具備 K-means 不易取代的優勢（Aliyev et al., 2020）。Christy et al.（2021）進一步指出，透過改良初始群心選取方式（以中位數取代隨機值，即 RM K-Means），可同時兼顧 K-means 的效率與 Fuzzy C-Means 的品質，是本研究第三章分群初始化設計的具體參考。第三，分群結果須經驗證才具備可信度與可解釋性，無論是以決策樹重現分群標籤（Tan, E. H. L. et al., 2025），或是以分群結果與業務端人員核對命名是否符合實務認知（Aliyev et al., 2020），驗證步驟都是分群研究不可省略的一環。第四，靜態屬性（如 KYC 人口統計資訊）之分群鑑別力可能不如行為特徵：Thompson et al.（2021）以真實金融交易資料證實，客戶之性別、居住地、婚姻狀況等 KYC 屬性對交易行為之解釋力甚微，交易頻率與金額才是關鍵區分變數，此一發現提醒後續分群特徵設計須謹慎評估靜態屬性之實質貢獻，而非僅因具業務意義即納入。

不過，既有文獻亦指出限制：Christy et al.（2021）之實驗僅以 772 筆前處理後之小規模電商資料驗證，固定 $k=10$ 未討論最佳分群數選取；Tan, E. H. L. et al.（2025）雖以大規模金融交易資料為對象，卻是流動性與交易頻率遠高於共同基金的衍生性商品市場；若僅使用交易型 RFM，容易忽略尚未完成申購但已展現高度興趣的投資人（例如頻繁瀏覽基金頁面卻尚未申購者），這也是本研究納入網站行為資料的關鍵動機。

5. 與本研究之關聯

上述六篇文獻（含 Thompson et al., 2021）共同構成本研究分群方法設計的直接基礎，其中 Thompson et al. (2021) 因方法論堆疊與本研究重疊程度最高，為核心先行研究。在特徵工程層面，本研究可參照陳一慈（2021）之依分布調整級距作法，並輔以 Aliyev et al. (2020，補充佐證層級）之連續數值主張，避免機械式等分位離散化；同時參照陳一慈（2021）與 Tan, E. H. L. et al. (2025) 之作法，依基金投資人申購頻率、投資金額之實際分佈決定級距或轉換方式（如 IHS 轉換），同時分別建立「交易 RFM」（申購、贖回、投資金額）與「行為 RFM」（基金頁面瀏覽、搜尋、觀察清單使用）兩組特徵，以同時掌握已完成交易的偏好訊號與交易前的興趣訊號。

在分群演算法層面，Aliyev et al. (2020) 之比較結論指出 K-means 計算效率最高、結果易於解釋，惟其僅適用於純數值資料；本研究因候選特徵同時包含連續、次序類別與無序類別三種尺度（詳見第三章 3.5.2），故採用可處理混合型資料之 **K-prototypes** 作為正式分群方法，K-means 則保留為第三章 3.5.3 之方法論對照（用以說明何以不能直接套用純數值分群演算法），不納入正式比較實驗。Christy et al. (2021) 提出的 RM K-Means 初始化設計——以 R、F、M 排序後之分段中位數取代隨機值作為初始群心——雖原為 K-means 之改良，其「以分段中位數取代隨機初始化」之設計思路，仍可作為 K-prototypes 初始化方式之參考，測試是否能在本研究資料上同時降低迭代次數並提升分群品質。若分群後發現部分投資人落於離群邊界，亦可參照 Aliyev et al. (2020) 之作法，將其視為高資產或高頻交易之重點客群，而非強行併入某一主群。在分群驗證層面，可參照 Tan, E. H. L. et al. (2025) 以決策樹驗證分群結果之可解釋性與特徵重要性，並可參照 Thompson et al. (2021) 以 Silhouette 係數與 Davies-Bouldin score 交叉決定最佳分群數之作法，與本研究第三章 3.5.4 節規劃之驗證指標組合直接對應。在群間差異驗證層面，Thompson et al. (2021) 之 ANOVA/Kruskal-Wallis 雙軌檢定 + 對應事後檢定設計，為本研究第三章 3.7.4 節 RQ3 統計檢定決策準則之直接方法論佐證。

最後，鄭婕妤（2010）「先分群、再分策略」的整體設計理念，直接支持本研究將分群結果進一步銜接至個人化推薦模型：本研究可將分群結果作為推薦模型的

分層依據，並與熱門推薦、內容導向推薦、協同過濾（ALS）等 baseline 比較，驗證分群輔助推薦是否具有增量效果，若分群式推薦能在 Precision@K、Recall@K、MAP 等指標上優於基準模型，即可支持投資人行為分群對數位券商基金投資服務具有實務價值。

文獻整合小結：綜合 2.1、2.2.1、2.2.2 三節文獻，投資人行為與數位金融文獻提供本研究之情境與問題意識：投資人具有心理與行為異質性，且數位平台改變了投資資訊取得與決策過程；投資人／顧客分群方法（如 Aliyev et al., 2020；Tan, E. H. L. et al., 2025）提供將此異質性轉化為可操作服務區隔的分析工具；RFM 與機器學習分群（鄭婕妤，2010；陳一慈，2021；Christy et al., 2021；Tan, E. H. L. et al., 2025；Aliyev et al., 2020）則提供可由交易與行為資料出發、兼顧可解釋性與資料驅動性的具體方法，構成本研究第三章分群方法設計之直接文獻基礎。

三者共同指向以下論點：投資人行為在數位金融環境下已變得更可觀測也更複雜，不宜僅依賴傳統人口統計或單次問卷衡量；透過多維資料辨識差異化群體，有助於金融機構提供更精準的產品與服務；而 RFM 與機器學習分群提供一套可實作的行為分群框架，可支援基金個人化推薦模型之建構與評估。

據此，在數位券商基金投資服務中，整合投資人之交易資料與網站／App 行為資料，並以 RFM 概念及機器學習方法建立投資人分群，再據以發展個人化推薦模型，有助於補足既有研究多偏重單一交易資料、一般零售或銀行場景、且較少針對台灣數位券商基金推薦進行實證比較之不足。

2.3 個人化推薦系統與 FinTech 應用相關文獻

本節整理與個人化基金推薦直接相關之三類文獻脈絡：個人化推薦系統文獻脈絡（2.3.1）、基金／金融商品推薦文獻脈絡（2.3.2）、FinTech 與數位券商應用文獻脈絡（2.3.3），並釐清金融商品推薦與一般電商推薦之差異（2.3.4）。整理重點包含研究主題演進、常見推薦方法或模型、資料型態、評估指標、應用場景、主要研究發現，以及與數位券商基金投資服務之關聯。整體而言，近年文獻已由「提高推薦準確率」逐步轉向「結合行為資料、金融商品特性、投資人風險屬性與可解釋性」之推薦系統設計；此一轉向正好構成本研究以 GA4 使用者行為資料結合基金交易資料，建構投資人分群與個人化基金推薦模型之理論基礎。

2.3.1 個人化推薦系統文獻脈絡

1. 研究主題演進

個人化推薦系統早期多應用於電子商務、影音平台與內容服務，核心目的在於解決資訊過載問題，透過使用者歷史互動或商品特徵預測其偏好，進而提升點擊率、購買率或使用者黏著度。Wu & Li (2025) 以 PRISMA 系統性文獻回顧方法，檢索 Web of Science 與中國知網共 65 篇 2018–2024 年金融商品推薦文獻後指出，此領域已由傳統協同過濾 (CF) 與內容式推薦，發展至「精準行銷式推薦」(含混合式推薦、圖神經網路、序列推薦)、「時間序列分析式推薦」與「文本探勘式推薦」三大研究方向，其中精準行銷式推薦是與本研究最直接相關的支線，且已有 Chou et al. (2022) 之 GraphDCF 等圖神經網路方法明確針對**基金**推薦場景。

Wei & Liu (2025) 進一步將個人化推薦問題定位為「動態偏好學習」：其研究指出傳統偏好誘導多屬監督式，需事先蒐集顧客選擇資料，容易因與歷史選擇矛盾而產生不可行解；作者因此提出結合增量學習與 ϵ -greedy 演算法的架構，讓系統得以在顧客與平台的持續互動中，一邊推薦、一邊更新對顧客效用函數的估計，兼顧短期推薦品質 (利用) 與長期偏好掌握 (探索)。

因此，個人化推薦系統文獻的演進可概括為三個階段：第一，從使用者—商品評分矩陣出發，重視偏好預測；第二，納入瀏覽、點擊、搜尋與購買等行為序列，提升對即時偏好的捕捉能力，Wei & Liu (2025) 以點擊序列動態更新效用函數即屬此類；第三，結合混合式模型、深度學習與圖結構設計，如 Wu & Li (2025) 歸納之精準行銷式推薦方向，使推薦結果不僅準確，也能反映金融商品特有的風險與時間敏感性。

2. 常見推薦方法或模型

個人化推薦系統常見方法包括以下幾類。第一為協同過濾 (Collaborative Filtering, CF)，可區分為 User-based CF 與 Item-based CF。第二為內容式推薦 (Content-based Recommendation)，透過商品屬性與使用者偏好特徵進行匹配。第三為混合式推薦 (Hybrid Recommendation)，結合協同過濾與內容式推薦，以降低單一模型在冷啟動或資料稀疏情境下的限制。第四為矩陣分解與深度學習模型，例如 SVD、Neural Collaborative Filtering、圖神經網路與序列模型，藉由潛在特徵或網

路結構捕捉複雜互動關係——Wu & Li (2025) 指出此類方法（如 GraphDCF、DIEN）正是為因應金融商品「寬廣特徵空間」與「時間敏感性」而發展。第五為強化學習式推薦，Wei & Liu (2025) 之 ϵ -greedy 演算法即屬此類：清單中每項產品以 $1-\epsilon$ 機率採「利用」（推薦當前估計效用最高者），以 ϵ 機率採「探索」（隨機推薦以學習新偏好），該研究以中國基金市場 113 檔基金之模擬實驗發現，適度探索（如 $\epsilon=0.1$ ）在累積報酬上表現最佳，純利用（ $\epsilon=0$ ）容易陷入區域最佳、純探索（ $\epsilon=1$ ）則報酬最低。

在本研究中，較適合採用的模型路徑並非單純追求最複雜的深度模型，而是建立「熱門推薦 Baseline → 內容導向推薦 → 協同過濾（ALS 隱性回饋矩陣分解）→ 分群輔助 CF」由簡至繁排序之基準階梯（baseline ladder）比較架構——四模型依序疊加個人化程度（無個人化 → 個人歷史偏好 → 跨使用者協同訊號 → 分群資訊），使分群輔助 CF 相較 ALS 之增量貢獻得以乾淨歸因於分群此一單一變數。此一設計可對應第二章文獻脈絡，也能在第三章研究方法與第四章實驗結果中清楚說明各模型之理論基礎與增量效果。

3. 資料型態

個人化推薦研究常見資料型態包括：一、顯性回饋資料，如評分、收藏或問卷偏好；二、隱性回饋資料，如瀏覽、搜尋、點擊、停留時間與購買；三、使用者屬性資料；四、商品屬性資料；五、序列與時間資料。Wu & Li (2025) 針對金融商品推薦進一步歸納出三類特徵：金融商品特徵（技術指標、基本面指標、風險等級）、使用者特徵（人口統計、財務狀況、風險承受度、投資目標、行為資訊）與外部環境資訊（產業樣態、政策法規、重大社會事件），並將金融商品推薦問題形式化為 $P(u_i, s_j, d_t, \text{act})$ ——預測投資人 u_i 於日期 d_t 對商品 s_j 產生買或賣（act）之機率，凸顯金融推薦相較一般推薦多了「時間」與「互動方向」兩個維度。Wei & Liu (2025) 之基金屬性設計則提供具體範例：以年化報酬、波動度、規模、周轉率、排名五項屬性描述每檔基金，作為效用函數之輸入特徵。

對本研究而言，GA4 使用者行為資料可視為隱性回饋資料，概念上包括瀏覽次數、基金頁面瀏覽、搜尋次數、平均瀏覽時長、最近造訪天數與行動裝置使用比例等行為特徵；基金交易紀錄則提供較強的偏好訊號，概念上包括基金代碼、申購／贖回、金額、日期與基金類型等。兩類資料結合後，可彌補單純交易資料無法觀

察「尚未購買但已有興趣」之限制，也能補足單純網站行為資料無法確認實際投資偏好之問題。以上為文獻回顧階段依常見隱性回饋設計歸納之示意性特徵類別，非 GA4 匯出資料之實際欄位名稱；實際取得樣本後確認之 GA4 欄位總表與特徵計算方式，詳見第三章資料前處理相關章節。

4. 評估指標

推薦系統常見評估指標可分為預測誤差、排序品質與商業效果三類，其中 Precision@K、Recall@K、MAP、NDCG (Järvelin & Kekäläinen, 2002) 等排序品質指標最適用於 Top-K 推薦清單評估；Precision@K、Recall@K、MAP 源自資訊檢索領域長期發展之慣例指標，並無單一可歸屬之原始文獻，本研究依循領域慣例直接採用。Wei & Liu (2025) 則額外提出效用學習觀點下的評估指標：SUD (Single Utility Difference upper bound，衡量估計效用與真實效用之最大差距)、RF (Recommendation Fitness，推薦擬合度) 與累積／平均報酬 (納入每次互動的固定成本)，這些指標補充了 Precision/Recall 之外，「效用擬合」與「互動成本」的評估思維，對本研究若考慮動態調整推薦策略時具有參考價值。

本研究預計以 Precision@K、Recall@K 與 MAP 作為主要模型評估指標，並以熱門基金推薦作為 Baseline。此設計相較於只呈現模型準確率，更符合推薦系統「前 K 名清單是否命中投資人實際購買基金」的實務情境。若後續資料允許，也可補充分群別 Precision@K，以分析不同投資人群體對個人化推薦的反應差異。

5. 應用場景

個人化推薦系統的應用場景已由電商商品、影音內容、新聞資訊，擴展至金融科技平台與數位投資服務。Wu & Li (2025) 指出，金融商品推薦具有「多目標性」(同時追求獲利與個人化)、「平行互動行為」(投資人對同一商品同時存在買、賣兩種方向) 等一般電商推薦少見的特性，因此金融推薦不能僅以點擊或購買作為成功標準，還需同時考量商品風險、投資人風險承受度、投資目標、適合度與監理要求。

本研究所處之數位券商基金投資服務場景，推薦系統可用於基金探索、相似基金推薦、熱門基金比較、新手投資引導與分群化投資服務。然而，在設計上必須避

免將推薦簡化為「刺激交易」工具，而應定位為協助投資人降低資訊搜尋成本、提高商品理解度與改善基金選擇品質之輔助機制。

6. 主要研究發現

整體而言，個人化推薦系統文獻指出，推薦模型若能有效整合使用者歷史行為、商品屬性與即時互動訊號，通常能優於非個人化或熱門排序推薦。Wei & Liu (2025) 之模擬實驗具體證實：純粹依賴既有效用估計進行推薦（純利用）容易停滯於區域最佳解、不再更新對顧客的理解，適度納入探索機制才能持續學習偏好並在長期報酬上勝出。Wu & Li (2025) 之系統性回顧則指出，現有金融商品推薦研究已能處理特徵的多樣性與時間敏感性，但對「多目標特徵」與「平行互動行為」的挖掘仍不充分，未來可朝多行為推薦（同時分析瀏覽、收藏、買、賣等多類互動）與多任務推薦（同時學習個人化偏好與投資報酬）方向發展。

因此，第二章在引用此類文獻時，將其定位為本研究「推薦系統方法論基礎」，而非直接等同於金融商品推薦。其可支撐本研究採用協同過濾、矩陣分解、混合式推薦與 Top-K 評估指標的合理性；但金融商品推薦仍需進一步納入風險、適合度與投資人保護之特殊要求，此點於下一節「基金／金融商品推薦文獻脈絡」進一步說明。

7. 與數位券商基金投資服務之關聯

個人化推薦系統文獻可支持本研究的三項設計。第一，使用者行為資料可作為投資偏好之間接代理，支撐本研究納入 GA4 行為特徵；Wu & Li (2025) 之特徵分類架構（金融商品特徵、使用者特徵、外部環境資訊）可作為本研究特徵工程的完整參考清單。第二，協同過濾與矩陣分解可作為基金推薦模型的基本方法，支撐本研究建立模型比較架構。第三，Wei & Liu (2025) 動態效用學習與探索－利用權衡的觀點，提醒本研究：即使不採用強化學習方法，也應留意投資人偏好可能隨時間演化，若僅以歷史交易資料訓練靜態模型，可能無法反映投資人最新的興趣轉變。

2.3.2 基金／金融商品推薦文獻脈絡

1. 研究主題演進

基金與金融商品推薦研究雖承襲一般推薦系統方法，但其研究重點已明顯不同。一般電商推薦多以提升購買率或使用者的參與為主要目標；基金推薦則需面對商品風險、投資人適合度、金融知識差異、行為偏誤與監理要求。因此，近年金融商品推薦文獻逐漸由「推薦相似商品」進一步發展為「推薦適合投資人風險屬性與行為特徵之金融商品」。

本節核心文獻為 Chou et al. (2022) 提出的 GraphDCF (Graphical Deep Collaborative Filtering)，是本研究「基金與金融商品推薦系統」最核心、也是與本研究場域最直接吻合的文獻：該研究以台灣某商業銀行 2016 年 6 月至 2019 年 2 月之真實資料 (93,132 位顧客、2,614 檔基金、5,941,170 筆申購與贖回交易)，將顧客建模為圖節點、以「曾購買同一檔基金」建立邊，再以 GraphSAGE 產生節點嵌入向量並結合深度嵌入協同過濾 (DECF)，同時納入顧客與基金的「固定屬性」(KYC 風險等級、基金風險分級) 與「動態行為」(歷史交易平均淨值變化、基金週期性報酬與交易量排名)。實驗顯示 GraphDCF 較 NCF 提升 Precision@k 達 2.3%，且改以「交易順序」而非「共同購買」建圖後，邊數可從 1,115 萬條大幅降至約 9,900 條，在犧牲極少精準度下大幅提升可擴展性。Wei & Liu (2025) 之動態效用學習模型 (詳見前節) 則提供另一種路線：透過網頁點擊序列以 ϵ -greedy 演算法持續更新對投資人效用函數的估計。Wu & Li (2025) 之系統性文獻回顧進一步將上述兩篇定位在「精準行銷式推薦」方向，並指出金融商品推薦具有多目標性、寬廣特徵空間、時間敏感性與平行互動行為四項有別於一般推薦領域的特性。

Chiou-Wei & Lee (2024) 之 KL-KM 方法則提供了另一種較輕量、適合新手投資人的路線：該研究以改進 KL 散度衡量基金評分分布之相似度，再以 K-medoids (而非 K-means) 分群產生推薦——選用 K-medoids 的關鍵理由是其群中心 (medoid) 為實際存在的基金，而非抽象平均中心，較符合「推薦結果必須是真實可交易標的」之金融商品推薦實務限制。實驗顯示最佳分群數為 $k=3$ ，且推薦檔數以 3 檔最能兼顧效率與相似度 (推薦 4-5 檔時 KL 相似度明顯下降)。此研

究與 GraphDCF、動態效用學習相比方法複雜度較低，可作為本研究「熱門推薦→分群輔助推薦」漸進式比較架構中，介於簡單與複雜之間的一個具體參照點。在台灣本土場域，王怡（2023）之研究是本研究研究場域最直接的先行研究：該論文以台灣國內五家代理銷售共同基金的電子交易平台（基富通、中租、鉅亨、富蘭克林、好好證券——好好證券本身即為其中一家個案）為研究對象，使用 2020 年全年 52 週交易資料（約 80 萬筆交易、5 萬名投資人、逾 2,000 檔基金），提出基於前景理論與遷移學習的效用推薦演算法，並以訓練測試 4:1 切分驗證推薦準確率優於單純相似度排序之非個人化推薦。然而，王怡（2023）的研究設計以**質性個案研究**（結合田野調查、參與觀察，並以 Canvas 多維表格比較五家平台之關鍵影響因素）為主軸，推薦演算法僅是第三章第三節的單一貢獻點之一；作者亦誠實指出其推薦準確率**仍低於電影推薦領域的 0.32 基準**，且演算法僅解決「買什麼」，未納入「何時買」與「買多少」的價量因素，也未針對協同過濾、內容導向、矩陣分解等多種推薦模型進行系統性比較。這正是本研究與王怡（2023）的關鍵差異：本研究以**量化模型比較**為主軸（而非質性個案研究），並在同一資料集上系統性比較熱門推薦、內容導向推薦、協同過濾與分群輔助 CF 四種模型，以 Precision@K、Recall@K、MAP 等標準指標呈現各模型間的相對增量效果，補足王怡（2023）在模型系統性比較上的不足。

此外，Shah et al.（2022）雖與基金推薦相關，但性質上有所限制：其為印度大學部學生的「提案型」論文，僅提出知識圖譜嵌入結合深度學習的推薦架構設計，**沒有任何實驗、資料集或結果數據**，其文獻回顧雖詳細複述了 GraphDCF（Chou et al., 2022）之方法與成效，可作為該研究具領域代表性的間接佐證，但 Shah et al.（2022）本身的方法設計並未經實證驗證。Sanz-Cruzado et al.（2024）則品質相對紮實：作者具學術與業界雙重背景（Glasgow 大學與希臘國家銀行），提出首個同時包含定價與真實客戶交易的公開金融資產推薦資料集 FAR-Trans（29,090 位客戶、388,049 筆交易），並以依時間點切分（而非隨機切分）的方式比較 11 種基準演算法。

2. 常見推薦方法或模型

基金／金融商品推薦常見模型可分為五類。第一，協同過濾模型：以使用者歷史購買、贖回或評分資料建立使用者—基金互動矩陣。第二，內容式推薦：依基金

屬性進行匹配，包括基金類型、風險等級、投資區域、費用率等。第三，混合式推薦：依常見分類可分為模型層融合（CF/CBF 聯合訓練）、分數層融合（加權合併）與切換機制（新用戶用內容式、成熟用戶用協同過濾）三種，可作為本研究「分群輔助 CF」定位為切換機制變形之分類依據。第四，圖模型與深度協同過濾：Chou et al.（2022）之 GraphDCF 即屬此類，將使用者、基金與交易行為建構為圖，並比較 Mean、Max-pooling、Mean-pooling、LSTM 四種 GraphSAGE 聚合函數，發現 Mean 聚合器表現最佳。第五，效用學習與探索－利用模型：Wei & Liu（2025）之 ϵ -greedy 動態效用學習即屬此類。

Sanz-Cruzado et al.（2024）進一步將既有金融資產推薦（Financial Asset Recommendation, FAR）方法歸納為三類：**價格導向**（以資產價格時間序列預測獲利性，不具個人化）、**交易導向**（以交易紀錄為核心，含矩陣分解式協同過濾與客戶分群）、**混合方法**（結合價格、交易與基本面等多種資訊源）。依此分類，本研究採用的「投資人分群＋協同過濾」路線屬於交易導向方法中的客戶分群支線。

若以本研究的可行性與碩士論文研究範圍考量，建議以熱門推薦、內容導向推薦、協同過濾（ALS）與分群輔助 CF 作為主要實作模型；GraphDCF 與動態效用學習可作為進階文獻與未來研究方向的對照。如此可兼顧方法完整性、資料可取得性與論文可完成性。

3. 資料型態

基金推薦所需資料通常比一般商品推薦更複雜。GraphDCF 之特徵設計具體示範了這種複雜性：基金端納入「固定屬性」（風險等級 RR1 – RR5）與「動態表現」（依淨值序列計算之短中長期報酬序列、依交易量計算之熱門度排名）；顧客端則納入「固定屬性」（KYC 蒐集之背景、財務狀況、風險承受度）與「動態行為」（歷史交易基金之平均淨值變化、基金以外資產如 ETF/AUM 之變動百分比），實驗證實同時納入雙方動態因子的組合效果最佳。Sanz-Cruzado et al.（2024）之 FAR-Trans 資料集則額外提供了客戶分群變數的具體參考：依資產管理規模分為 Mass（< 6 萬歐元）/Premium/Professional/Legal Entity，並依 MiFID II 問卷分風險輪廓為 Conservative/Income/Balanced/Aggressive，可與本論文吳忠義

(2008) 之 KYC 風險三級對照，佐證「資產規模＋風險問卷」是金融機構常見的客戶分類維度。

本研究資料設計與上述文獻高度相符。基金交易資料可支撐使用者－基金互動矩陣；基金基本資料可支撐內容式推薦與候選商品篩選；KYC 風險等級可支撐適合度檢核；GA4 行為資料則可捕捉尚未轉化為交易的投資興趣。相較於僅使用交易資料的研究，本研究的雙軌資料整合可更完整反映數位券商投資服務中的「瀏覽－比較－交易」流程。

4. 評估指標

GraphDCF 以 Precision@k ($k=1, 3, 5, N$) 作為核心評估指標，並以「隨機推薦」與「熱銷基金 (Hot Fund)」兩種基準比較，發現決策樹、隨機森林、Adaboost 等傳統機器學習模型在此高度不平衡的分類任務中，表現甚至不如隨機基準，凸顯傳統方法難以處理稀疏交易資料。Sanz-Cruzado et al. (2024) 則使用兩類指標回答兩個不同問題：ROI@k 衡量推薦資產的「獲利性」，nDCG@k 衡量推薦排序與客戶實際交易行為的「吻合程度」；其實驗發現價格導向的迴歸模型 ROI 表現最好但 nDCG 極低（接近隨機），協同過濾方法（尤其 LightGCN）則 nDCG 表現最佳但 ROI 普遍不佳——沒有一種演算法能同時在「獲利性」與「符合客戶偏好」兩個目標上都表現最好。這項發現對本研究的評估設計具有重要提醒：本研究以 Precision@K、Recall@K、MAP 衡量的是「命中投資人偏好」，並不涵蓋「推薦基金是否真的值得投資」的獲利性驗證，應在研究範圍中明確說明此一區隔。

然而，金融商品推薦不能只用準確率評估。若一個模型精準預測投資人會購買高風險基金，但該基金不符合投資人的風險承受度，則在金融服務實務上並不能被視為良好推薦。因此，除 Precision@K、Recall@K 與 MAP 外，第二章應補充金融情境下的適合度評估概念，例如：推薦基金是否符合投資人 KYC 風險等級、推薦清單是否過度集中於單一類型，以及是否具備可解釋性。

5. 應用場景

基金／金融商品推薦的應用場景包括：一、基金搜尋結果排序；二、相似基金推薦；三、基金比較與替代標的推薦；四、新手投資人的入門基金推薦；五、依投

資人分群提供差異化基金清單；六、機器人理財或投資組合建議；七、投資人再行銷與精準行銷。Shah et al. (2022) 之個人化解釋設計提供了另一種應用場景的思路：其提出以知識圖譜之「使用者－基金」中介路徑（如共同的收入區間、職業、風險類型）作為推薦理由，即使沒有直接購買紀錄也能產生解釋，這呼應本研究文獻探討中對投資人信任議題的討論——推薦系統若能附帶理由，有助於建立投資人信任，惟此設計本身未經該研究之實證驗證，僅供概念參考。

在數位券商場景中，本研究較適合聚焦於「個人化基金推薦」而非完整投資組合建議。前者是根據投資人過去行為與交易偏好推薦可能感興趣且具適合度的基金；後者則涉及資產配置、風險預算與投資顧問責任，監理要求更高。因此，本研究在第二章應清楚界定推薦系統的角色：它是投資服務中的資訊輔助與商品發現機制，而非保證收益或替代投資顧問判斷的決策工具。

6. 主要研究發現

基金推薦文獻普遍顯示，納入金融商品特性與投資人行為序列的模型，通常優於僅依熱門度或靜態評分的推薦方法。GraphDCF 之個案分析發現：交易行為多元的顧客（如跨 5 種投資市場購買 5 檔產品），模型能推薦符合其偏好的產品而非僅推薦熱銷基金；但若顧客過去僅購買過熱銷基金，模型也會傾向推薦熱銷基金，顯示低交易頻率顧客仍是模型限制所在。Sanz-Cruzado et al. (2024) 之實驗進一步指出，金融資產推薦領域普遍存在交易資料長尾分佈的問題——其 FAR-Trans 資料集中超過 50% 客戶僅有 3 筆以下交易，這與 GraphDCF 「低頻交易顧客推薦效果受限」的發現相互印證，也預告本研究若面對台灣數位券商的基金交易資料，很可能同樣遭遇類似的資料稀疏挑戰。

這些發現共同指出，金融商品推薦的核心並非單純找出「最多人買的商品」，而是需要理解投資人與基金之間的多維關係，包括交易行為、風險偏好、商品屬性、時間變化與可解釋性；同時，「推薦準確度」與「推薦資產的獲利性」是兩個不易同時兼顧的目標（Sanz-Cruzado et al., 2024），本研究應明確界定聚焦於前者。此一觀點可作為本研究比較「個人化推薦」與「熱門基金推薦」的理論基礎。

7. 與數位券商基金投資服務之關聯

基金推薦文獻可直接支撐本研究的核心研究問題。第一，GraphDCF 以台灣真實銀行資料證明基金推薦可透過使用者交易行為與圖結構建立有效模型，是本研究「台灣數位券商基金投資服務場域實證不足」此一研究缺口論述最直接的正面反例，也支持本研究以基金交易資料建構推薦模型的可行性。第二，Wei & Liu（2025）動態效用學習強調網頁點擊與互動序列可用於動態偏好學習，支持本研究納入 GA4 行為資料。第三，Sanz-Cruzado et al.（2024）之 FAR-Trans 資料集與 Chou et al.（2022）之 GraphDCF 皆採用真實金融機構客戶交易資料（分別為希臘與台灣銀行），顯示金融推薦系統研究已從公開電商資料集，轉向與金融機構合作取得真實交易資料的趨勢，本研究之研究設計正呼應此一趨勢。第四，Shah et al.（2022）之解釋性設計與下節之監理文獻共同提醒，金融推薦需重視可解釋性、資料風險與投資人保護，支持本研究在模型設計與限制中納入風險適合度與監理考量。

2.3.3 FinTech 與數位券商應用文獻脈絡

1. 研究主題演進

FinTech 與數位券商應用研究關注金融服務數位化如何改變投資人的資訊取得、交易行為、投資組合選擇與金融服務使用經驗。早期研究多聚焦於網路銀行、電子交易與機器人理財採用意圖；近年則更關注 AI、演算法推薦、行為偏誤、投資人保護與監理治理。

Gambacorta et al.（2023）以義大利家庭與銀行 2004–2020 年微觀資料，理論與實證雙管齊下地檢驗了金融科技的雙面性：其理論模型將投資人依「資訊處理容量」區分為成熟（sophisticated）與非成熟（unsophisticated）投資人，實證發現金融科技（以銀行數位服務程度衡量）進步後，成熟投資人的報酬優勢與風險資產持有比例進一步擴大，而非成熟投資人則逐漸退出風險性資產交易——樣本期間成熟與非成熟投資人平均年報酬差距約 42 個基點；以 2002 年為基準之累積報酬計算，至 2020 年底兩者累積報酬差距達約 5 個百分點，即使該期間義大利股市表現不佳（約 -25%）。核心結論是：金融科技若僅提供「取得管道」而不同時提升投資人的資訊處理能力，將無法縮小、反而擴大投資人間的不平等。

國際證券管理機構組織（International Organization of Securities Commissions，下稱 IOSCO）（2025，須注意此文件為諮詢報告草案，意見徵詢截止於 2025 年 4 月 11 日，尚未定案為正式最終報告，引用時應以「現況調查」而非「監理定論」層級處理）作為 IOSCO（2021）治理報告的後續更新版，聚焦大型語言模型與生成式 AI 帶來的新興應用與風險：報告指出資產管理業者已將 AI 用於「客戶分群（client segmentation）」以支援行銷、鎖定目標與個人化投資建議，且依 IOSCO 會員調查觀察，資產管理業者採用 AI 之比例以機器人理財／資產管理（60%）居冠、投資研究（40%）次之，這與本研究的分群輔助推薦方向高度呼應。CFA Institute（2022）之跨國問卷則從投資人態度角度提供互補證據：78% 法人投資人認為 AI 應用於投資決策將帶來正面效果，其中最被看好的應用領域是風險管理（61%）與投資組合管理（59%）。IOSCO（2025）同時警示生成式 AI 的擬人化互動可能加劇「自動化偏誤（automation bias）」——推薦系統越個人化、越像真人互動，使用者越容易不加思索地依循其建議。

2. 常見方法或模型

FinTech 與數位券商應用研究的方法可分為三類。第一，理論建模與大樣本迴歸：Gambacorta et al.（2023）建立具資訊不對稱的一般均衡投資組合選擇模型，並以固定效果迴歸驗證五項理論預測。第二，監理機關的問卷調查與利害關係人座談：IOSCO（2025）以 IOSCO 會員問卷（24/33 個轄區回覆）、附屬會員委員會問卷（184 份回覆）與四場跨洲利害關係人座談，蒐集 AI 應用現況；IOSCO（2021）則透過業界訪查歸納出六大風險領域與六項監理指引措施。第三，大型跨國市場調查：CFA Institute（2022）以 Coalition Greenwich 執行之問卷，調查全球 15 個市場共 3,588 位散戶與 976 位法人投資人的信任程度。

本研究雖不直接採用上述方法，但可引用 Gambacorta et al.（2023）的理論框架說明投資人異質性的堅實學理基礎，並引用 IOSCO（2025）／IOSCO（2021）的監理指引作為本研究模型治理與可解釋性設計的參考依據。

3. 資料型態

Gambacorta et al.（2023）使用義大利銀行「家庭所得與財富調查」（SHIW）與「區域銀行放款調查」（RBLS）兩組資料，以問卷正確答題比例衡量投資人金

融素養（成熟度代理變數），並以銀行提供數位服務的比例建構「數位化程度」指標——作者也在研究限制中明確指出，此研究僅衡量銀行數位服務的「供給面」，未直接測量投資人對數位工具的「實際使用強度」與行為資料（如點擊、瀏覽、下單頻率），這正是本研究採用 GA4 行為資料的獨特互補價值所在。IOSCO（2021）與 IOSCO（2025）的資料則來自監理機關對業者的問卷與訪查，涵蓋 AI/ML 應用情境、風險領域與治理作法；CFA Institute（2022）則是散戶與法人投資人的自陳式問卷，涵蓋信任程度、科技接受度與個人化服務需求。本研究使用 GA4 行為資料與基金交易資料，正好填補 Gambacorta et al.（2023）所指出的「供給面指標」與「投資人實際行為資料」之間的落差。若能再結合匿名化 KYC 風險等級與用戶屬性，則可更完整地對應該文獻中「金融科技使用能力差異」與「投資人適合度」兩項議題。

GA4 官方文件（Google Analytics Help）進一步界定了本研究可運用的行為資料結構：其中「世代分析（cohort exploration）」功能文件說明如何以 event、transaction、conversion 等維度追蹤使用者群體隨時間的行為變化，並指出 User-ID 追蹤方式在跨裝置辨識上的限制；「區隔（segment）」功能文件則說明 GA4 區分使用者層級（user scope）、工作階段層級（session scope）與事件層級（event scope）三種範疇，可分別對應「該投資人整體輪廓」「單次造訪行為」與「單一互動事件」三種顆粒度的特徵設計。這兩份官方文件屬於技術規格文件而非學術文獻，第二章僅說明其與本研究行為特徵設計的對應關係，詳細的欄位定義與擷取限制將於第三章資料前處理段落具體說明。

4. 評估指標

Gambacorta et al.（2023）以迴歸係數大小（基點、百分點）衡量金融科技對報酬與風險資產配置的異質化效果；CFA Institute（2022）則以問卷比例（如「50% 散戶認為科技提升信任」「78% 散戶希望獲得個人化服務」）衡量投資人態度；IOSCO（2025）／IOSCO（2021）作為監理報告，未使用量化模型評估指標，而是以七項治理原則（透明度、可靠性、投資人與市場保護、公平性、安全隱私、課責、人為監督）與六項監理指引措施作為業者自我檢核的定性框架。

對本研究而言，模型評估仍以 Precision@K、Recall@K 與 MAP 為主，但第二章應補充金融科技應用層面的評估視角，包括：推薦是否提升基金探索效率、是否

降低資訊不對稱、是否避免不適合推薦，以及是否具有足夠透明度供平台與投資人理解——此一視角可直接對應 IOSCO（2025）／IOSCO（2021）之治理原則與 Gambacorta et al.（2023）之資訊落差論述。

5. 應用場景

IOSCO（2025）具體列舉 AI 在資本市場的應用場景排序：與客戶溝通（66.7%）、演算法交易（63.3%）、機器人理財／資產管理（60.0%）、監控與詐欺偵測（53.3%）；其中資產管理業者運用 AI 於客戶分群、依市場動態再平衡、依客戶偏好客製化，與本研究的應用場景高度重疊。CFA Institute（2022）進一步從投資人端呈現：78% 散戶投資人希望獲得個人化產品或服務，其中 68% 願意為此支付更高費用，最受歡迎的個人化產品前三名為指數個人化、影響力基金與個人化研究。

本研究聚焦之數位券商基金投資服務，可被視為「數位金融平台上，以資料驅動方式提供個人化基金探索與推薦」的應用場景，恰好對應 IOSCO（2025）所述資產管理業者「客戶分群」與「客製化」的實務作法。然而，數位平台也可能因介面設計、推播策略或推薦排序而影響投資人決策，故推薦系統應納入風險揭露與適合度控制，而非僅以轉換率最大化為目標。

6. 主要研究發現

Gambacorta et al.（2023）之核心發現是：金融科技進步會擴大而非縮小成熟與非成熟投資人間的異質性，此不平等僅在金融科技對所有人皆可及、且所有投資人具備相似使用能力時才會被消除。IOSCO（2021）歸納六大 AI/ML 風險領域（治理與監督、演算法開發測試、資料品質與偏誤、透明度與可解釋性、外包、倫理疑慮），IOSCO（2025）則補充生成式 AI 時代的新興風險（惡意使用、模型幻覺與崩潰、集中化風險、自動化偏誤）。CFA Institute（2022）之調查發現，儘管科技信任度持續上升（56% 散戶預期未來更依賴科技工具），仍有四分之三散戶投資人偏好真人顧問勝過機器人理財顧問，「人加科技（people plus technology）」是投資人心目中的最佳模式，而非純演算法或純人力。

這些發現共同指出：金融科技與 AI 應用雖能提升效率與個人化程度，但（一）其效益並非對所有投資人一致，可能擴大既有的資訊與財富不平等（Gambacorta

et al., 2023)；(二)需要治理框架管控資料品質、可解釋性與偏誤風險 (IOSCO, 2025, 2021)；(三)投資人對純演算法推薦仍保有疑慮，人工介入與透明度是建立信任的關鍵 (CFA Institute, 2022)。因此，本研究若能在數位券商場景中設計兼顧分群、推薦準確度與風險適合度的基金推薦模型，將有助於回應「如何讓金融科技真正支援不同成熟度投資人」此一問題，同時避免加劇 Gambacorta et al. (2023)所指出的資訊不平等。

7. 與數位券商基金投資服務之關聯

FinTech 與數位券商文獻提供本研究的場域正當性與實務貢獻基礎。第一，Gambacorta et al. (2023)之理論與實證證實投資人金融素養／資訊處理能力存在顯著且會隨科技進步擴大的異質性，說明分群分析在基金推薦前具有必要性，且本研究若能透過個人化推薦精準識別並協助非成熟投資人，可視為呼應其政策意涵的具體技術實作。第二，IOSCO (2025)、IOSCO (2021)之 AI/ML 治理框架提醒，推薦模型需納入資料品質、可解釋性、公平性與人為監督等考量，避免將金融推薦等同於一般電商推薦；IOSCO (2021)明確將非監督式學習定義為「演算法自行偵測資料相似特徵並發掘結構」，可作為本研究 K-prototypes 分群方法在治理脈絡下的正當性依據 (K-means 於第三章僅作方法論對照)。第三，CFA Institute (2022)之信任調查與 Gaspar & Oliveira (2024)、Cardillo & Chiappini (2024)兩篇 Robo-advisor 文獻共同指出，投資人對純演算法推薦仍存疑慮：Gaspar & Oliveira (2024)以相對風險趨避 (RRA) 指標檢驗 Riskalyze 平台之實際推薦組合，發現其風險評估存在系統性「過度保守 (ultraconservatism)」傾向——即便「積極型」組合，實際風險水準也僅相當於中度保守，此發現與本論文吳忠義 (2008)「積極型投資人實際偏好穩健型商品」的台灣本土實證相互呼應，兩篇文獻從機器推薦與人工問卷兩種不同路徑，共同指向「投資人風險屬性與實際商品配置之間存在系統性落差」；Cardillo & Chiappini (2024)之系統性文獻回顧則將 Alsabah et al. (2021)、Dong et al. (2022，皆轉引自 Cardillo & Chiappini, 2024，本研究未直接取得並核對原文)等研究歸入「演算法建模」研究群，並歸納出 Robo-advisor 演算法建模正從「依賴問卷」轉向「依賴投資人過去交易選擇推斷偏好」的趨勢，可支撐本研究以交易行為資料（而非僅問卷）進

行投資人分群的方法論正當性。這三篇文獻合而觀之，共同支撐本研究「分群輔助推薦」而非「全自動化決策」、且應保留人工覆核與風險揭露機制的產品定位。

2.3.4 金融商品推薦與一般電商推薦之差異

金融商品推薦與一般電商推薦存在本質差異。一般電商推薦主要處理商品偏好與購買轉換，推薦錯誤的成本通常是退貨、低滿意度或短期購買失敗；金融商品推薦則可能影響投資人的資產配置、風險曝險、長期報酬與財務安全，推薦錯誤的後果更高，且具有監理與投資人保護意涵。

第一，在風險屬性上，金融商品具有市場風險、信用風險、利率風險、匯率風險、流動性風險與集中度風險；一般商品則多以價格、品質與偏好匹配為主。第二，在適合度上，基金推薦須考量投資人 KYC 風險等級、投資經驗、投資目的與風險承受度，不能僅因使用者可能感興趣就推薦高風險商品。第三，在監理要求上，金融機構需符合適合度原則、資訊揭露、利益衝突管理與個人資料保護等規範；一般電商推薦的監理密度相對較低。第四，在投資人保護上，金融推薦需避免誘發過度交易、追高殺低、羊群效應或過度集中於單一資產類別。

因此，本研究的個人化基金推薦定位為「在風險與適合度約束下的個人化資訊排序」，而非單純的「最可能成交商品預測」。此一定義使本研究區隔於一般電商推薦，也更符合數位券商基金投資服務的學術與實務情境。

2.4 文獻整理與研究缺口分析

2.4.1 研究缺口彙整表

綜合 2.1–2.3 節文獻探討，本研究可辨識出四項具體研究缺口。以下表格先列出缺口本身，再列出最貼近但仍有具體差異的既有研究（若有），避免研究缺口論述迴避已存在的相關文獻。

表 2-1 研究缺口彙整表

缺口	說明	最貼近之既有研究（須承認其存在）	與本研究之具體差異
----	----	------------------	-----------

缺口	說明	最貼近之既有研究（須承認其存在）	與本研究之具體差異
缺口一： 投資人分群多依賴交易資料或靜態屬性，較少整合交易前的平台行為資料	既有 RFM／分群研究（鄭婕妤，2010；陳一慈，2021；Tan, E. H. L. et al., 2025；Christy et al., 2021；Aliyev et al., 2020）多以交易紀錄之 Recency、Frequency、Monetary 或人口統計變數為分群輸入，較少同時納入瀏覽、搜尋、觀察清單等交易前行為訊號	許仲廷（2022）以台灣統一證券真實客戶資料，比較 K-means 與 K-prototype 後採用後者進行分群+羅吉斯迴歸分類	許仲廷（2022）之分群特徵仍以交易金額、風險等級、年齡等靜態／交易屬性為主，未納入網站瀏覽或搜尋行為；且分類模型僅輸出二元購買機率，未建立排序型推薦清單，也未以 Precision@K／Recall@K／MAP 評估
缺口二： 基金推薦研究較少以台灣數位券商真實平台資料，系統性比較多種推薦模型之增量效果	Chou et al.（2022，GraphDCF）、Wei & Liu（2025，動態效用學習）等基金推薦文獻多聚焦單一模型之演算法效能，較少與熱門推薦、內容導向、協同過濾等多種基準模型並列比較	王怡（2023）以台灣五家基金代理銷售平台（含好好證券）為研究對象，提出基於前景理論與遷移學習的效用推薦演算法	王怡（2023）之研究設計以質性個案研究（田野調查、參與觀察，並以 Canvas 多維表格比較五家平台）為主軸，量化推薦模型僅為次要貢獻，作者亦自陳其推薦準確率低於電影推薦領域之 0.32 基準，且未系統性比較協同過濾、內容導

缺口	說明	最貼近之既有研究（須承認其存在）	與本研究之具體差異
			向、矩陣分解等多種推薦模型
缺口三： 金融商品推薦研究易忽略風險適合度與投資人保護，未必能直接套用一般電商推薦邏輯	Wu & Li（2025）指出金融商品推薦具多目標性、寬廣特徵空間、時間敏感性與平行互動行為，有別於一般推薦領域	此缺口屬方法論定位問題，非既有研究於此議題完全缺席	本研究將推薦系統定位為「風險與適合度約束下的個人化資訊排序」，並以 IOSCO（2021, 2025）、CFA Institute（2022）之治理與信任觀點，於模型設計中納入可解釋性與人為監督考量
缺口四： 個人化推薦較少與熱門推薦（popularity-based）baseline 進行系統性比較，增量效益不易判斷	GraphDCF（Chou et al., 2022）以熱銷基金（Hot Fund）作為對照組之一，但多數基金推薦文獻仍以模型間比較為主	此缺口同屬評估設計問題，非既有研究缺席	本研究明確將熱門基金推薦設定為 baseline，依序與內容導向推薦、協同過濾（ALS）、分群輔助 CF 以 Precision@K、Recall@K、MAP 進行系統性比較，並依投資人分群結果檢驗增量效果是否因群體而異

2.4.2 與國內先行研究之比較：許仲廷（2022）、王怡（2023）

在正式主張研究缺口之前，必須先處理兩篇與本研究場域最直接重疊的既有文獻，避免研究缺口論述被誤認為迴避既存研究。

許仲廷（2022）是目前唯一直接以台灣券商真實資料進行分群之公開研究：該研究以統一證券財富管理、保代、海外市場三大業務之客戶資料，從 K-means 分群出發，因年齡與交易金額尺度差異過大，比較 K-means 與 K-prototype 之顯著性檢定結果後（K-prototype 於 1% 水準下全部變數顯著，優於 K-means）採用 K-prototype 建立客戶素描，再以羅吉斯迴歸分類預測新開戶客戶購買大財管商品之機率，方法論上（混合型變數分群、分群後接分類模型）與本研究高度相似。然而，許仲廷（2022）的分類模型僅止於「會不會買」的二元機率輸出，並未建立排序型推薦清單，也未以 Precision@K、Recall@K 或 MAP 等標準指標評估推薦成效；分類目標亦是大財管商品整體，而非個別基金。此外，許仲廷（2022）本人亦於研究限制中坦言，其分群結果之顯著變數逐年變化，靜態模型泛化性有限。本研究在分群之後進一步建構並比較熱門推薦、內容導向推薦、協同過濾與分群輔助 CF 四種個人化推薦模型，並以標準 Top-K 推薦評估指標驗證分群對推薦成效的增量貢獻，是許仲廷（2022）尚未觸及的下一步。

王怡（2023）則是本研究場域最直接的先行研究——該論文以台灣國內五家代理銷售共同基金的電子交易平台（基富通、中租、鉅亨、富蘭克林、好好證券）為研究對象，好好證券本身即為其研究個案之一。王怡（2023）以 2020 年全年交易資料（約 80 萬筆交易、5 萬名投資人、逾 2,000 檔基金）提出基於前景理論與遷移學習的效用推薦演算法，並以訓練測試 4:1 切分驗證推薦準確率優於非個人化的相似度排序。然而，王怡（2023）之研究設計以質性個案研究（結合田野調查、參與觀察，並以 Canvas 多維表格比較五家平台之關鍵影響因素）為主軸，量化推薦模型僅是論文第三章第三節的單一貢獻點；作者亦誠實指出其推薦準確率仍低於電影推薦領域之 0.32 基準，且演算法僅處理「買什麼」，未納入「何時買」與「買多少」之價量因素，也未針對協同過濾、內容導向、矩陣分解等多種推薦模型進行系統性比較。本研究之差異在於：以量化模型比較為主軸而非質性

個案研究，並在同一資料集上系統性比較四種推薦模型，以標準 Top-K 指標呈現各模型間的相對增量效果，補足王怡（2023）在模型系統性比較上的不足。

小結：許仲廷（2022）、王怡（2023）已分別證明「台灣真實金融機構資料可支撐分群」與「台灣數位券商基金平台可建立推薦模型」兩項可行性，本研究並非在無先例的場域中開創方法，而是在此基礎上，補足兩篇文獻皆未觸及的「分群＋多模型系統性比較＋標準 Top-K 評估」這一整合環節。

2.4.3 本研究如何填補缺口

1. **整合交易 RFM 與行為 RFM 雙軌特徵：**回應缺口一，本研究同時使用基金交易資料（申購、贖回、投資金額）與 GA4 平台行為資料（基金頁面瀏覽、搜尋、觀察清單使用），在鄭婕妤（2010）、陳一慈（2021）、Tan, E. H. L. et al.（2025）之 RFM／機器學習分群方法論基礎上，額外納入交易前的興趣訊號，是許仲廷（2022）所缺乏的資料維度。
2. **系統性多模型比較，以標準 Top-K 指標驗證增量效果：**回應缺口二與缺口四，本研究依序建構熱門推薦、內容導向推薦、協同過濾（ALS）、分群輔助 CF 四種模型，並以 Precision@K、Recall@K、MAP 系統性比較，補足王怡（2023）效用推薦模型缺乏的基準比較設計，也呼應 Chou et al.（2022，GraphDCF）以熱銷基金為對照組的評估精神。
3. **以風險適合度與治理觀點約束推薦設計：**回應缺口三，本研究參照 Wu & Li（2025）金融商品推薦四大特性、IOSCO（2021, 2025）之 AI/ML 治理框架、CFA Institute（2022）之投資人信任調查，將推薦系統定位為「風險與適合度約束下的個人化資訊排序」而非純粹的成交率最大化，並在模型設計中保留人工覆核與可解釋性空間。
4. **在台灣數位券商真實場域中，銜接分群與推薦兩個既有文獻皆未完整整合的環節：**許仲廷（2022）證明了台灣金融機構資料可支撐分群、王怡（2023）證明了台灣基金平台可建立推薦模型，但兩者皆未完整走完「分群 → 多模型推薦比較 → Top-K 增量效果驗證」這條路徑。本研究以此作為核心貢獻定位：不是提出全新演算法，而是在台灣數位券商基金投資服務場域中，首次將分群、多元推薦模型比較與標準化評估指標完整串接的應用型實證研究。

2.4.4 綜合性論述

綜合 2.1 至 2.3 節文獻可知，投資人行為研究（吳忠義，2008；許信輝，2023；Tan, G. K. S., 2020）已說明投資人具有高度異質性，且「宣稱偏好」與「實際行為」之間存在系統性落差；顧客分群與 RFM 文獻（鄭婕妤，2010；陳一慈，2021；Tan, E. H. L. et al., 2025；Christy et al., 2021；Aliyev et al., 2020）提供將此異質性轉化為可操作區隔的具體方法；基金與金融商品推薦文獻（Chou et al., 2022；Wei & Liu, 2025；Wu & Li, 2025；Chiou-Wei & Lee, 2024）則提供協同過濾、圖模型、動態效用學習等方法基礎；FinTech 與數位券商文獻（Gambacorta et al., 2023；IOSCO, 2025, 2021；CFA Institute, 2022；Gaspar & Oliveira, 2024；Cardillo & Chiappini, 2024）進一步說明，金融科技若缺乏適當治理與個人化設計，可能擴大而非縮小投資人間的資訊落差。在此文獻脈絡下，許仲廷（2022）與王怡（2023）兩篇文獻已分別證明「台灣金融機構真實資料可支撐分群」與「台灣數位券商平台可建立基金推薦模型」的可行性，但皆未完整整合分群與多模型系統性比較。本研究之貢獻在於：整合 GA4 使用者行為資料、基金交易資料與用戶屬性資料，建立投資人分群，並以熱門基金推薦作為 **baseline**，系統性比較個人化推薦與分群輔助推薦模型在 **Precision@K**、**Recall@K**、**MAP** 等指標上的增量效果，於台灣數位券商基金投資服務場域中，補足既有文獻在資料整合廣度、模型系統性比較與治理考量三方面之不足。

第三章 研究方法

3.1 研究架構設計

研究設計屬性：本研究為**量化研究（quantitative research）**，採用**好好證券既有之次級資料（secondary data）**——使用者網站行為資料、基金交易資料、用戶屬性資料——進行分析，不涉及問卷調查或受試者招募；模型建置與評估採**離線實驗設計（offline experiment）**，以歷史資料之訓練期／測試期時間切分模擬線上部署情境，不進行即時線上系統開發與部署；**分析單位為使用者層級（user-level）**——分群、推薦模型訓練與評估之基本單位均為單一投資人，而非個別交易或個別瀏覽事件。

3.1.1 設計理念：管線順序與基準階梯之理由

為何是「先分群、再推薦、再比較」，而非直接比較推薦模型：本研究之核心貢獻（分群輔助 CF）本質上是一個「分群結果是否能提升推薦成效」之問題，此問題邏輯上必須先有分群結果，才談得上「輔助」。若不先建立分群模型（RQ1），第四層即無法產生分群標籤以供第四種推薦模型使用，RQ2、RQ3 亦無從回答「分群是否有增量效果」——分群模型與推薦模型並非兩個平行、各自獨立之子研究，而是前者為後者之必要輸入，此為五層架構採線性管線（而非分群與推薦並行設計）之根本原因。

為何需要四個由簡至繁排序之推薦模型，而非直接比較「有分群 vs. 無分群」兩組：推薦成效可能同時受多種資訊來源影響——群體熱門程度、使用者個人歷史偏好、跨使用者協同訊號、以及分群資訊本身——若僅比較「加入分群」與「未加入分群」兩個模型，兩者之差異將混雜多種來源，無法乾淨地將「分群」此一單一變數之增量貢獻分離出來。本研究因此設計一組**由簡至繁之基準階梯（baseline ladder）**：熱門推薦（僅用群體統計，不具個人化）→ 內容導向推薦（加入使用者個人歷史偏好）→ 協同過濾 ALS（加入跨使用者協同訊號）→ 分群輔助 CF（在協同過濾基礎上加入分群資訊，且採候選集篩選之 post-hoc 方式，

不變動潛在因子估計本身，見 3.1.6 節）。此設計使分群輔助 CF 與其直接前一階（ALS）之差異，得以乾淨歸因於「分群資訊之候選集篩選」單一變數，而非同時混雜個人化程度、協同訊號有無等多重差異，此為 RQ2 統計檢定之因果推論基礎，亦是四模型階梯順序之設計理由（詳見 3.6.1 節候選基金池統一規則）。

3.1.2 五層架構總覽與層間資料介面

在此設計理念下，本研究採用「資料蒐集 → 特徵工程 → 分群模型 → 推薦模型 → 評估」五層研究架構。下圖除各層對應之本章小節外，並標示層與層之間傳遞之資料介面格式，以說明各層並非僅是章節劃分，而是實際資料形態逐層轉換之管線：




圖 3-1 五層資料處理架構圖

3.1.3 第一層：資料蒐集

本研究資料來源涵蓋三類：使用者網站行為資料（GA4／BigQuery 每日匯出）、基金交易資料（內部交易資料庫）、用戶屬性資料（KYC／帳戶衍生欄位），三者規劃以 `user_id` 為共同鍵值於使用者層級串接。此層之角色是為第二層提供原始輸入，本身不涉及特徵計算；欄位範圍、資料期間、欄位鑑別力分類與資料倫理原則詳見 3.3 節。

3.1.4 第二層：特徵工程與資料前處理

此層將第一層之原始事件與欄位資料轉換為第三、四層可直接使用之訓練期特徵矩陣，是五層架構中承上啟下之樞紐——其產出品質直接決定分群（第三層）與推薦模型（第四層）之輸入可靠度。此層之方法論層級承諾——訓練期／測試期嚴格切分、標準化參數僅以訓練期資料鎖定——貫穿本研究架構第二至五層，為避免資料洩漏之核心設計原則；執执行程序與方法論細節詳見 3.4 節。

3.1.5 第三層：投資人分群

以第二層產出之訓練期特徵矩陣為輸入，採用 K-prototypes 演算法進行投資人分群，同時處理連續型（RFM、年收入）、次序類別型（KYC 風險等級、交易經驗）與無序類別型（職業、所得來源、裝置類型等）混合尺度特徵；K-means 因無法原生處理類別型特徵，僅作為方法論對照而非正式比較對象。此層直接回應 1.2 節之研究問題 **RQ1（分群識別）**，其產出（分群標籤）是第四層「分群輔助協同過濾」得以存在之前提，此依賴關係即 3.1.1 節「先分群、再推薦」設計理念之具體體現。演算法原理、最佳分群數選取方法與資料洩漏防範設計詳見 3.5 節。

3.1.6 第四、五層：個人化推薦模型與評估

第四層以第二層特徵與第三層分群標籤為輸入，依 3.1.1 節之基準階梯理念，依序建置熱門推薦、內容導向推薦、協同過濾（ALS）、分群輔助協同過濾四種模型；第四種模型採候選集篩選（post-hoc filtering）之整合方式——ALS 僅以訓練期全體使用者互動資料訓練一次，分群完全不影響潛在因子估計，僅於推論階段依分群結果縮小候選基金池，差異純粹來自候選範圍之限縮，而非模型依群體重重新訓練，操作型定義詳見 3.6.5 節。第五層以第二層時間切分所留出之測試期資料為評估基礎，定義 ground truth（測試期購買之新基金，排除既有持股之複購與定期定額續扣），並以 Precision@K、Recall@K、MAP（NDCG@K 為輔助指標）比較四種模型之成效：以配對統計檢定回應 **RQ2（推薦成效比較）**——分群輔助 CF 相較其餘三種基準模型是否具統計上顯著之增量效果；以群體間比較回應 **RQ3（群體間差異）**——此增量效果是否因投資人所屬群體而異。兩層之候選基

金池定義、已持有基金排除邏輯、評估對象範圍界定與統計檢定設計詳見 3.6、3.7 節。

3.1.7 貫穿五層之方法論層級承諾

以下原則貫穿本研究架構第二至五層，為方法論層級承諾，不因實際資料結果而調整：(1) **時間切分與資料洩漏防範**——分群特徵、標準化參數、識別碼對照表均僅以訓練期資料計算或建立，測試期資料僅用於推薦模型評估階段；(2) **user_id 作為串接鍵值**——三類原始資料以 user_id 於使用者層級合併，作為分群與推薦模型之共同分析單位；(3) **K-prototypes 為正式分群方法、K-means 僅作方法論對照**——因應候選特徵包含無序類別型變數之技術必要性；(4) **「新基金探索」任務界定**——第四層候選基金池與第五層 ground truth 一律排除訓練期已持有基金，本研究之推薦任務聚焦於「使用者尚未接觸過之新基金」，而非既有持股之複購或定期定額續扣預測；此界定同時約束 3.6、3.7 兩節，直接決定第四章各項指標數字之解讀方式（例如「命中」恆指命中一檔新基金），並連帶決定第五章關於複購行為之研究限制陳述，詳見 3.6.1 節「候選基金池之統一規則」。實際分群數、群體命名、 γ 權重具體數值、各推薦模型之超參數，則須待取得完整期間實際資料後於第四章確認。

3.2 研究流程說明

本研究方法論流程共分六個步驟，對應 3.1 節五層研究架構之實際執行順序。與 3.1 節之靜態結構不同，本節之重點在於執行順序、每一步驟結束時之產出檢核點，以及檢核未通過時之回頭調整路徑——方法論規劃並非保證一次線性執行即可成功，以下流程圖以虛線標示可能之回饋迴圈：




圖 3-2 研究流程圖

3.2.1 步驟一：資料蒐集與整合規劃

確認並整理三類資料來源之欄位範圍、資料期間與鑑別力分類，並規劃以 `user_id` 為共同鍵值之串接方式，同時建立資料倫理與脫敏原則，執行細節詳見 3.3 節。這些欄位確認之結果將影響步驟二之特徵計算範圍，若交易資料表確認含贖回紀錄或 `content_group` 值域擴增，需回頭調整步驟二之對應規則。

3.2.2 步驟二：資料前處理與特徵工程

依步驟一確認之欄位，執行識別碼歸戶（僅以訓練期登入事件建立對照表）、依欄位性質分三類之缺值處理、交易與行為 RFM 特徵計算、GA4 篩選行為與交叉驗證特徵萃取，以及依下游用途分流之特徵標準化，程序細節詳見 3.4 節。**本步驟同時執行訓練期／測試期之時間切分**，此切分貫穿後續所有步驟，為本研究防範資料洩漏之核心設計。

產出檢核點 A： 本步驟結束時，須檢核識別碼歸戶率（訓練期有登入事件之使用者占比）與各欄位缺值比例是否落於合理範圍——若歸戶率過低，可歸戶進入分群與推薦模型之匿名行為樣本將大幅縮水，影響第三層分群特徵之代表性；若缺值比例超出 3.4.2 節規劃之填補門檻，需重新評估該欄位是否納入特徵集合。**檢核未通過時**，回頭調整步驟一之欄位取得範圍（例如延長資料蒐集期間以取得更多登入事件）或步驟二之處理規則（例如調整缺值填補門檻或排除該欄位），而非逕行帶入品質不佳之特徵進入下一步驟。

3.2.3 步驟三：投資人分群

以步驟二產出之訓練期特徵矩陣為輸入，執行 K-prototypes 分群，以 Elbow、Silhouette 等指標選定最佳分群數並為各群體賦予商業意義之命名，本步驟回應研究問題 RQ1，執行細節詳見 3.5 節。

產出檢核點 B： 分群完成後，須檢核分群品質指標（依 3.5 節混合距離相容版本之 Silhouette、Davies-Bouldin 等）是否落於可接受範圍，並檢視各群體是否具備可解讀之商業意義（例如群體輪廓過於接近、無法區分）。**檢核未通過時**，回頭調整步驟二之特徵組合（如新增或移除特徵）或標準化方式（如重新評估 γ 權重），重新執行分群，而非強行採用品質不佳之分群結果進入步驟四——分群標籤之品質直接決定第四層「分群輔助協同過濾」候選集篩選之意義，品質不佳之分群將使 RQ1 之回答本身缺乏說服力，也連帶弱化 RQ2、RQ3 之解讀基礎。

3.2.4 步驟四：個人化推薦模型建置

以訓練期之「使用者 × 基金」互動資料與步驟三之分群標籤為輸入，依 3.1.1 節基準階梯之設計理念，依序建置熱門推薦、內容導向推薦、協同過濾（ALS）、

分群輔助協同過濾四種模型，候選基金池統一排除訓練期已持有基金，執行細節詳見 3.6 節。

產出檢核點 C：分群輔助 CF 建置後，須檢核候選集篩選後之候選基金池是否過度稀疏——即「使用者所屬群體其他成員曾購買、且使用者自身尚未購買」之基金集合若過小甚至為空集合，將使該使用者之推薦清單退化（Top-K 不足額或需回退至全域候選池）。檢核未通過時，回頭調整步驟三之分群數（分群數過多可能使各群成員過少、候選池稀疏）或放寬本步驟之候選集篩選門檻（如同群定義範圍擴大納入次相似群體），調整原則已於 3.6.5 節預先規劃，實際調整結果將於第四章記錄，不視為偏離計畫書。

3.2.5 步驟五：模型評估與比較

以步驟二切分之測試期資料為評估基礎，定義 ground truth（測試期購買之新基金，排除複購與定期定額續扣），計算四種模型之 Precision@K、Recall@K、MAP（NDCG@K 為輔助指標），並執行統計檢定回應研究問題 RQ2、RQ3，執行細節與檢定方法詳見 3.7 節。

產出檢核點 D：計算指標前，須檢核評估對象是否確實符合 3.7.1 節之三層條件（訓練期有交易、測試期有交易、測試期至少購買一檔新基金），若某使用者 ground truth 為空集合卻仍被納入 Recall 計算，將使該指標分母出現零值或計算失真。三層條件本身由 3.7.1 節定義，實際篩選則發生於步驟二建立分析資料集時，而非步驟一（步驟一僅涉及欄位範圍、資料期間、鑑別力分類與串接規劃，不含評估對象篩選）。檢核未通過時，回頭檢視 3.7.1 節三層條件於步驟二之落實情況，而非在指標計算階段以特例處理掩蓋範圍界定之疏漏。

3.2.6 步驟六：結果整合與應用建議

整合步驟三之分群輪廓、步驟五之模型比較結果與 RQ1-RQ3 之回應，作為第四章實驗結果與分析之呈現基礎，並進一步歸納對好好證券之實務應用建議與後續研究限制，呼應第五章結論與建議之撰寫方向。此步驟為銜接方法論（第三章）與實證結果（第四、五章）之整合階段，本身不涉及新增之資料處理或模型訓練工作，亦不預期產生回頭調整前述步驟之需求。

3.3 資料來源與資料說明

3.3.1 研究場域與資料期間

本研究資料來源為好好證券（數位券商）之基金投資服務平台，涵蓋三類資料：使用者網站行為資料（GA4／BigQuery）、基金交易資料（內部交易資料庫）、用戶屬性資料（KYC 與帳戶衍生欄位）。研究期間依 1.4 節規劃為最近 12–18 個月（暫定 2024/10 – 2026/03，實際區間依資料取得狀況調整），三類資料以 `user_id` 為共同鍵值於使用者層級串接（串接流程見 3.4.1 節）。

3.3.2 GA4 使用者行為資料

取得方式：透過 Google Analytics 4（GA4）之 BigQuery 每日匯出功能取得，資料以事件（event）為單位記錄，每一列對應使用者之一次網站互動行為。惟樣本欄位名稱與 BigQuery 原生匯出 schema 未完全一致，實際資料取得路徑（原生匯出表或經 Data API／報表介面轉換）待正式研究執行時進一步確認，將影響第四章實際查詢與特徵計算之欄位參照方式。

事件類型：依已取得之樣本觀察，已知事件類型至少包含 `page_view`（頁面瀏覽）、`session_start`（session 起始）、`first_visit`（首次造訪）、`scroll`／`td_scroll`（頁面捲動，後者為平台自訂事件）、`user_engagement`（使用者互動）、`fs_fund_click`（基金選擇點擊，平台自訂事件）、`view_item`（GA4 標準電商事件，對應瀏覽基金詳情）。完整事件類型清單（含各事件觸發時機與頻率）待取得完整期間資料後於第四章資料集描述中補充。

欄位總表：GA4 匯出資料共 66 個欄位，依 3.4 節前處理規劃之鑑別力分類如下：

表 3-1 GA4 使用者行為資料欄位分類

分類	欄位	說明
識別與時間軸	<code>user_pseudo_id</code> 、 <code>user_id</code> 、 <code>event_timestamp</code> 、 <code>date</code> 、	使用者識別與事件時間戳； <code>user_id</code> 僅登入狀態下寫入，串接方式見 3.4.1 節

分類	欄位	說明
	ga_session_id、 session_number	
事件與頁面分類	event_name、 content_group、 page_path、 landing_page	content_group 為平台已標準化之頁面分類（樣本中僅見「找基金」「基金詳情頁」兩例），可直接篩選基金相關行為，無須自行解析 page_path；惟目前僅取得示例值，非完整值域清單，此為 3.4.3 節行為 RFM 之 R/F 構面篩選條件之直接依據
基金識別	eventfund、 eventfund_id （平台自訂事件參數） items[].item_id、 items[].item_name（GA4 標準電商參數）	依觸發事件類型不同，基金名稱與代碼寫入前述兩組欄位之一；fs_fund_click 等自訂事件使用 eventfund_id，view_item 等標準電商事件使用 items[].item_id
基金屬性 （隨 view_item 事件帶出）	items[].item_category、 items[].item_category2、 items[].item_brand	依樣本觀察：item_category 為資產類別（如 oversea-fund）、item_category2 為基金風險等級（ RR1-RR5 五級評級）、item_brand 為基金系列（如「富達系列」）
篩選行為 （基金總覽頁面）	fliter_risk_level、 fliter_APR、 fliter_category、 fliter_region、 fliter_series、	記錄使用者於基金總覽頁面之篩選條件，八個欄位可複選、每次篩選事件皆重複帶入當下全部生效之篩選條件（詳見下方「篩選欄位之操作邏輯」）；fliter 為 GA4 匯出資料之原始欄位命名（filter 之系統端筆誤），本文逐字沿用

分類	欄位	說明
	fliter_TOP10 、 fliter_asset_size 、 fliter_dividend_frequency	
互動強度	engagement_time_msec 、 session_engaged 、 session_duration	反映使用者與頁面之互動程度，作為 3.4.3 節興趣強度之次特徵來源
裝置與流量來源	deviceCategory (mobile／desktop／tablet) 、 platform 、 set_session_source	deviceCategory 作為 3.5 節 K-prototypes 分群之補充無序類別特徵
電商／購買相關 (確認不使用)	transaction_id 、 purchase_revenue 、 price 、 quantity 、 item_revenue* 、 item_refund* 、 coupon 、 affiliation 、 item_list_* 、 promotion_* 、 creative_*	基金申購／贖回等實際交易事實僅記錄於內部交易資料庫，GA4 不追蹤購買事件，此組欄位於樣本中恆為空值或無意義，不納入分群或推薦特徵
描述性欄位 (暫不	eventDescription 、	樣本中多數為空值，與 event_name 、content_group 可能重疊，待取得完整事件類

分類	欄位	說明
使用)	eventCategory、 eventLabel、 eventLabel2、 eventAction、 eventlocation	型清單後再評估是否具補充價值
技術性欄位 (不使用)	stream_id、 is_active_user、 item_params、 item_variant、 item_category3、 — item_category5、 location_id	無研究意義或樣本中恆為 (not set)

篩選欄位之操作邏輯： fliter_risk_level 之值域為基金風險等級 **RR1-RR5**，與 items[].item_category2 (基金詳情頁所見之風險等級) 採同一評級系統，兩者可直接對應比較；fliter_asset_size 指**基金本身之資產規模** (基金 AUM)，與使用者個人資產或所得無關，兩者概念不可混淆。使用者可於基金總覽頁面同時複選多項篩選條件 (如同時篩風險等級與資產規模)，篩選結果通常為符合條件之基金清單而非單一基金；且每次觸發篩選事件時，當下全部生效中之篩選條件皆會重複帶入該筆事件紀錄 (而非僅記錄本次變動之欄位)，此一操作邏輯已於 3.4.2、3.4.4 節之篩選次數計數與交叉驗證特徵設計中一併考量。

3.4.4 節規劃之「篩選風險等級與 KYC 自陳風險等級是否一致」交叉驗證特徵，其可行性繫於 KYC 風險等級欄位之實際值域是否與 fliter_risk_level 之 RR1-RR5 可直接對應。KYC 風險等級欄位亦採 RR1-RR5 五級制，與基金風險評級 (items[].item_category2、fliter_risk_level) 為同一評級系統，無須建立對照表即可直接比較，此一致性驗證特徵已可正式定案 (見 3.4.4 節)。

3.3.3 基金交易資料

基金申購、贖回等實際交易事實記錄於好好證券內部交易資料庫，非 GA4／BigQuery 所能取得。具體欄位清單尚待使用者提供，以下並非實際交易資料表之確認欄位，而是本論文計畫書階段依第三章其餘各節方法論設計回推之最小假設欄位集合，用以說明交易資料至少須具備哪些欄位方能支撐交易 RFM（3.4.3 節）、ALS 推薦模型（3.6.4 節）與模型評估（3.7.1、3.7.2 節）之設計：user_id（使用者識別碼，匿名化，與 KYC、GA4 資料共同之串接鍵值，3.4.1、3.5、3.6、3.7 節皆須依賴）；fund_code（基金代碼，供 3.4.3 節 F 構面、3.6 節候選集與內容導向屬性比對、3.7 節 ground truth 判定使用）；transaction_date（交易日期，供 3.4.3 節 R／F 構面與 3.7.1 節訓練／測試期切分使用）；amount（交易金額，為必要欄位，供 3.4.3 節 M 構面與 3.6.4 節 ALS 信賴權重觀察強度使用）；transaction_type（申購／贖回，若交易資料表含贖回紀錄則為必要欄位，供 3.4.3 節 R／F／M 三構面排除贖回、3.6.1 節候選基金池持有判定、3.7.1 節 ground truth 購買判定使用，必要性理由詳見下方說明）。

交易類型欄位之必要性：若交易資料表含贖回紀錄，而 R、F、M 之計算未區分申購與贖回：(1) 3.4.3 節交易 RFM 之 F_u （訓練期交易筆數）與 M_u （ $\sum \text{amount}$ ）會將一筆贖回計入交易次數與金額加總， R_u 亦可能因贖回活動而被視為「近期活躍」，R、F、M 三構面同時失真；(2) 3.6.1 節候選基金池之「訓練期已持有（購買）基金集合」若逕自依「曾出現於交易紀錄」判定，將把已全數贖回、投資人實際上已不再持有之基金誤判為持有，錯誤排除於候選池之外；(3) 3.7.1 節 ground truth 之「測試期購買之新基金」若未排除贖回事件，贖回動作會被誤當成推薦命中之目標。因此，交易類型欄位是否存在、交易資料表是否包含贖回紀錄，為本節最優先待確認事項，其答案將決定 3.4.3、3.6.1、3.7.1 三節是否需要回頭修正（修正方向已於各該節以決策準則預先寫明）。

其餘延伸欄位（如幣別、基金風險等級等基金屬性主檔欄位）待使用者提供完整清單後補齊，可能之延伸方向已於 3.4.3 節「延伸指標」段落列出（帳戶年資、贖回次數、申購／贖回比例等），惟均待實際欄位確認後方能定案。

3.3.4 用戶屬性資料

取得方式：由好好證券內部 KYC（Know Your Client）問卷與帳戶系統提供，依 1.4 節研究範圍限制，僅能取得公司已完成匿名化／去識別化處理之資料，無法取得使用者真實身份資訊。

欄位總表與鑑別力分類：

表 3-2 用戶屬性資料欄位分類

分類	欄位	尺度類型	說明
高價值	職業	無序類別	K-prototypes 無序類別變數需求之直接支撐（見 3.5.2 節）
高價值	交易經驗／投資時長	次序類別	性質上接近帳戶年資（比照第二章 Tan, E. H. L. et al.（2025）之 Maximum Account Vintage），屬客觀行為衍生指標
高價值	風險等級	次序類別	值域為 RR1 - RR5，與 items[].item_category2、fliter_risk_level 之基金風險評級同一系統，可直接對應；屬使用者自陳之主觀 KYC 屬性，惟依第二章 Thompson et al.（2021）之發現，其分群鑑別力未必優於行為特徵，僅作補充維度
中價值	年收入	連續數值	取代原規劃但無對應欄位之「資產區間」，無須人工分箱
中價值	所得來源	無序類別	與年收入互補（收入性質 vs. 收入多寡）
低價值 （不納入分群）	性別、年齡、職位	—	依 Thompson et al.（2021）之 KYC 人口統計低鑑別力發現（性別、年齡）與職位／職業高度重疊區分力存疑（職位），暫不列入分群特徵，僅作第四章資料集描述之

分類	欄位	尺度類型	說明
			樣本輪廓統計使用

風險等級欄位之實際值域為 RR1 - RR5，與基金風險評級（items[].item_category2、fliter_risk_level）同一評級系統，兩者可直接對應比較，無須另建對照表。

3.3.5 資料倫理與脫敏方式

依 1.4 節研究範圍之資料隱私限制，本研究僅能使用公司提供之匿名化／去識別化資料：

- **識別碼匿名化：**三類資料共用之 user_id 鍵值為匿名化識別碼，不對應使用者真實姓名、身分證字號等可識別個人身份之資訊。
- **GA4 匿名瀏覽器識別碼：**user_pseudo_id 為瀏覽器端 cookie-based 識別碼，本身不含個人身份資訊，僅於登入事件中與 user_id 建立對照（對照範圍限定訓練期，見 3.4.1 節）。
- **KYC 資料之去識別化：**依 3.3.4 節欄位總表，取得之 KYC 欄位為職業、年齡等統計類別欄位，不含姓名、聯絡方式、身分證號等直接識別資訊。
- **研究資料使用範圍限制：**本研究資料僅用於學術分析目的，不對外公開原始資料、不重新識別（re-identify）任何使用者身份，分析結果以群體統計或聚合形式呈現於論文中。

3.3.6 資料限制與待確認事項

本節所述之三類資料來源界定、user_id 作為共同串接鍵值之設計，以及資料倫理與脫敏原則，為方法論層級承諾，不因實際資料結果而調整。

須待實際資料驗證或使用者確認之項目如下，依優先順序排列：(1) 交易資料表是否包含贖回紀錄、transaction_type 欄位是否存在，直接決定 3.4.3 交易 RFM、3.6.1 候選基金池、3.7.1 ground truth 三節定義是否須回頭修正；(2) user_id 寫入率（登入事件占全部事件之比例）——目前樣本為單日、16 位皆為匿名使用者、共 100 筆事件，是否含任一筆登入事件尚未核實，而 3.4.1 節識別碼歸戶機制之

核心前提即為訓練期內存在足夠登入事件可建對照表，此為 3.3 節與 3.4 節之間最大未驗證依賴；(3) content_group 之完整值域清單——目前僅取得「找基金」「基金詳情頁」兩個示例值，行為 RFM 之 R、F 構面完全依賴此欄位篩選基金相關事件（見 3.4.3、3.4.4 節）；(4) 基金交易資料之完整欄位清單，直接影響交易 RFM 延伸指標；(5) GA4 資料實際取得路徑——欄位總表所列名稱混合原生 BigQuery export schema 與 Data API／報表介面之維度命名，例如 date、session_number、page_path、landing_page、session_duration、deviceCategory 皆非原生匯出欄位名稱；(6) GA4 完整事件類型清單，目前僅有單日樣本。相關確認結果將於第四章資料集描述中完整記錄。

3.4 資料前處理方法

3.4.1 資料串接與識別碼歸戶（前置步驟）

本研究之 GA4 行為資料匯出以事件（event）為單位記錄，user_id 欄位僅於使用者登入狀態下寫入，未登入之瀏覽行為僅有瀏覽器端匿名識別碼 user_pseudo_id；user_id 與 user_pseudo_id 之對照表目前尚未建立。因此，資料串接須以下列步驟進行：

1. 建立識別碼對照表（僅以訓練期登入事件建立）：篩選出訓練期內同時具有 user_id 與 user_pseudo_id 之事件（即使用者於訓練期內處於登入狀態之任一事件），建立 user_pseudo_id → user_id 之對照表。明確排除以測試期登入事件建立對照表，理由與範疇界定如下：
 - 若對照表涵蓋測試期登入事件，將出現「以使用者於測試期才發生之登入行為，回溯歸戶其訓練期之匿名瀏覽紀錄」之情形。雖然識別碼對映本身屬身分資訊（回答「這個匿名瀏覽器屬於誰」），不直接攜帶行為或交易結果，與 3.5.1、3.7.1 節所防範之「特徵計算涵蓋未來結果資訊」性質不同；但若換一個角度看：在真實線上部署情境下，模型於訓練期結束當下即須完成訓練，此時根本不會知道使用者未來（測試期）才發生之登入事件，故以測試期登入事件

建立對照表，仍隱含使用了「訓練當下不可能取得」之未來資訊，與本研究「僅用過去資料預測未來」之核心設計原則不符。

- 因此，本研究採**較嚴格之範疇界定**：對照表僅以訓練期登入事件建立，測試期登入事件不納入對照表建置。
 - **一對多之資料品質規則（共用裝置風險）**：識別碼對照存在兩種方向性——(a) 同一帳戶跨多裝置／瀏覽器登入，對應多個 user_pseudo_id 指向同一 user_id（多對一），此為正常情形，直接建立多筆對照紀錄即可；(b) 同一裝置或瀏覽器被多人共用（如家用電腦、共用瀏覽器），對應同一 user_pseudo_id 於訓練期內先後登入過**多個不同** user_id（一對多）。後者若比照 (a) 之邏輯無差別回溯歸戶，將把裝置上其他使用者之瀏覽行為誤歸戶至任一登入者，污染行為特徵。因此規劃資料品質規則：**建立對照表時，先依 user_pseudo_id 分組並計算其對應之相異 user_id 個數**；若恰為 1（單一使用者裝置），依步驟 2 正常回溯歸戶全部訓練期匿名歷史；若為 2 個以上（共用裝置），**限縮回溯歸戶範圍至僅與登入事件同一 ga_session_id 之匿名事件**（即當次連續瀏覽 session 內、登入前之事件），不回溯歸戶該 user_pseudo_id 於其他 session 之匿名歷史——因單一 session 通常對應一次連續造訪，同一次造訪由同一人完成之可能性遠高於跨 session 而言，可大幅降低誤歸戶風險；該 user_pseudo_id 名下其餘無對應登入事件之 session，其匿名行為維持無法歸戶狀態，不納入任一使用者之特徵計算。
2. **回溯歸戶匿名行為**：依上述僅以訓練期建立之對照表，並套用共用裝置之限縮規則，將匿名瀏覽事件歸戶至對應之 user_id，使登入前之基金瀏覽、搜尋、篩選等行為亦能納入該投資人之訓練期行為特徵計算範圍，而非僅採計登入後之片段行為。
3. **與 KYC、交易資料串接**：以 user_id 為共同鍵值，將 GA4 行為特徵、KYC／用戶屬性資料、交易資料三方在使用者層級合併為單一分析資料集，作為 3.5 節分群與 3.6 節推薦模型之輸入。

已知限制與歸戶率之預期影響：若使用者於訓練期內從未登入（例如僅於測試期才首次登入，或全程未登入即完成所有瀏覽行為），其訓練期匿名行為將無法歸戶，此類使用者之匿名行為資料不納入分析範圍；共用裝置情境下，非當次登入 `session` 之匿名行為同樣無法歸戶（見上方資料品質規則）。惟此一限制之實際衝擊預期有限：依 3.7.1 節評估對象範圍之三層條件，本研究評估對象本即限定為「訓練期與測試期皆有交易紀錄」之使用者——多數線上券商平台之基金申購需要登入後始能完成，故此類使用者絕大多數應於訓練期內即已至少登入一次，訓練期登入事件應足以涵蓋其身分歸戶需求，歸戶率損失預期集中於「訓練期僅瀏覽未交易、直到測試期才首次登入並交易」之少數使用者，以及共用裝置下無法對應到登入 `session` 之匿名瀏覽片段。此限制將於第五章研究限制中一併說明，實際歸戶率、共用裝置（一對多）之 `user_pseudo_id` 比例將於第四章資料集描述中揭露。須特別註明：上述論證目前仍屬推論而非資料驗證——3.3.2 節目前取得之 GA4 樣本為單日、16 位匿名使用者、共 100 筆事件，其中是否包含任一筆帶有 `user_id` 之登入事件尚未核實；若樣本恰好落在無登入事件之時段，不代表實際資料全期間亦無登入事件，但也意味著本節識別碼歸戶機制之核心前提（訓練期內存在足夠登入事件可建對照表）至今未經任何實際資料驗證。`user_id` 寫入率（登入事件占全部事件之比例）為 3.3 節與本節之間最大的未驗證依賴，取得完整期間資料後須優先核實。

3.4.2 缺值處理策略

缺值處理依欄位性質分三類處理，而非機械式套用單一補值規則：

- **KYC／用戶屬性欄位：**類別型欄位（如職業、所得來源）之缺值，規劃以「未知」設為獨立類別而非刪除或眾數填補，避免人為假設使用者屬性；數值型欄位（如年收入）之缺值，規劃視缺失比例決定——缺失比例低（如 5% 以下）時以中位數填補，缺失比例偏高時另評估是否納入該欄位。
- **交易資料欄位：**核心交易欄位（`user_id`、`fund_code`、`transaction_date`、`amount`）原則上不應有缺值，若出現則視為資料品質異常，規劃排除該筆交易紀錄而非填補，避免捏造不存在之交易事實。

- **GA4 行為欄位**：此類欄位之「缺值」多數並非資料品質問題，而是「使用者未觸發該行為」本身即為有意義之資訊——例如 `fliter_risk_level` 等八個篩選欄位（`fliter` 為 GA4 匯出資料中之原始欄位命名，應為 `filter` 之系統端筆誤，本文為與實際資料庫欄位一致，逐字沿用原始拼寫；GA4 行為資料欄位總表見第三章 3.3.2 節），僅於使用者在基金總覽頁面實際使用篩選功能時才有值，並非每位使用者都會使用篩選功能。因此，此類欄位規劃**不進行數值填補**，而是轉換為「是否觸發該行為」之二元旗標（0／1）與「行為次數」之計數特徵，缺值本身即對應「未觸發」（旗標為 0、計數為 0），非統計上的資料缺失。**計數方式須考量篩選欄位之操作邏輯**（見 3.3.2 節）：使用者每次觸發篩選事件時，當下全部生效中之篩選條件會重複帶入同一筆事件紀錄（而非僅記錄本次變動之欄位），故「篩選次數」規劃以**篩選事件之次數**（即觸發篩選之 `session` 內事件筆數）計算，而非以八個 `fliter_*` 欄位個別非空值之加總計算，避免使用者一次複選多項篩選條件時，同一次篩選行為被重複計入多次。

3.4.3 RFM 特徵計算公式

交易 RFM

依 3.6.1、3.7.1 節已定案之訓練期／測試期時間切分原則，交易 RFM 特徵僅以**訓練期**交易資料計算（呼應 3.5.1 節資料洩漏防範原則）。以訓練期最後一日為計算基準日 T ，對使用者 u ：

$$R_u = T - \max(\text{transaction_date} \mid u, \text{申購}) \quad F_u$$

$$= |\{\text{申購交易} \mid u, \text{訓練期內}\}| \quad M_u = \sum \text{amount} \mid u, \text{申購, 訓練期內}$$

交易類型之必要性：上式明確將 R、F、M 三構面之計算範圍限定為**申購（purchase）**類型交易，排除**贖回（redemption）**交易——此為條件式定義，依 3.3.3 節「待確認事項」第一項之答案分流：(1) 若交易資料表確認含贖回紀錄（`transaction_type` 欄位存在），上式依申購／贖回篩選後方可代入計算，缺乏此篩選步驟將使一筆贖回被誤計為一次購買，R（近期活躍度）、F（交易次數）、M（申購金額）三構面同時受污染；(2) 若交易資料表確認僅含申購紀錄（無贖回），則篩選步驟形同無操作，上式與未篩選前完全等價，不影響既有設

計。此一條件式定義使本節無論交易資料表是否含贖回紀錄，皆可直接套用，不需等待欄位確認後才能定案。

延伸指標（規劃項目，待交易資料欄位確認後定案）：平均單筆申購金額（ M_u/F_u ）、持有基金檔數（不重複 fund_code 數，對應 3.6.1 節候選集排除規則所需之「訓練期已持有基金集合」，若含贖回紀錄，持有判定須進一步排除已全數贖回之基金，詳見 3.6.1 節說明）、帳戶年資（若交易資料含首次交易日期，可比照第二章 Tan, E. H. L. et al. (2025) 之 Maximum Account Vintage 設計）。若交易資料包含贖回紀錄，另規劃計算贖回次數與申購／贖回比例，作為投資人穩定度之延伸特徵。

行為 RFM

依 GA4 事件資料，僅採計 content_group 標註為基金相關頁面類別（如「找基金」「基金詳情頁」）之事件，計算方式與交易 RFM 對應但意涵不同。content_group 目前僅取得「找基金」「基金詳情頁」兩個示例值，非完整值域清單，此欄位為本節 R、F 構面篩選「基金相關事件」之唯一依據，完整值域清單確認後可能需要擴充「基金相關」之判定範圍：

$$R_u^{behav} = T - \max(\text{event_timestamp} \mid u, \text{基金相關事件}) \quad F_u^{behav} \\ = |\{\text{基金相關事件} \mid u, \text{訓練期內}\}|$$

行為 RFM 無交易金額（Monetary）之直接對應，規劃以**興趣強度**（interest intensity）替代，由以下次特徵組成：engagement_time_msec 於基金相關事件之加總、篩選功能使用次數（3.4.2 節之行為旗標與計數）、瀏覽之不重複基金數（依 eventfund_id 或 items[].item_id 去重計算）。此設計呼應研究背景所述「行為資料可捕捉交易前興趣訊號」之核心論點。

偏態分布之處理：比照第二章 Tan, E. H. L. et al. (2025) 之作法，交易與行為 RFM 特徵若呈現嚴重右偏分布（少數高頻大量交易或瀏覽者、多數低頻少量使用者），規劃採用**反雙曲正弦轉換**（Inverse Hyperbolic Sine Transformation, IHS）而非 log 轉換，因 IHS 可同時處理零值（如 $F_u = 0$ 之未交易或未瀏覽者）與負值，並有效壓縮右尾極端值使分布趨近常態，同時保留變數間相對大小關係。是否需要轉換將依訓練期實際資料之偏態係數（skewness）判斷，非無條件套用。

3.4.4 GA4 行為特徵計算方式

除 3.4.3 節之行為 RFM 外，另規劃下列補充特徵：

- **裝置類型**（deviceCategory：mobile／desktop／tablet）：作為 3.5.2 節無序類別特徵之補充來源，與 KYC 之「職業」共同構成 K-prototypes 所需之無序類別變數組。
- **篩選行為特徵**：依 3.4.2 節之旗標與計數設計，額外規劃「篩選之風險等級與 KYC 自陳風險等級之落差」此一交叉驗證特徵，呼應第二章吳忠義（2008）「積極型投資人實際偏好穩健型商品」與 Thompson et al.（2021）「KYC 生成之風險容忍度與實際行為不一致」之文獻發現。
fliter_risk_level 與 KYC 風險等級兩側之值域全數同為 RR1 – RR5（見 3.3.2、3.3.4 節），兩者屬同一評級系統，可直接相減，此一致性判定邏輯已可正式定案：**採有號差值 Δ = fliter_risk_level 之整數編碼（1–5） – KYC 風險等級之整數編碼（1–5），而非單純之一致／不一致二元旗標——正值（ $\Delta > 0$ ）代表使用者篩選之風險等級高於其 KYC 自陳風險等級，對應吳忠義（2008）「自陳穩健／保守卻篩選較積極商品」之方向；負值（ $\Delta < 0$ ）代表篩選風險等級低於自陳風險等級，對應相反方向之落差（自陳積極卻篩選較保守商品）； $\Delta = 0$ 則為一致。相較於純二元旗標僅能標示「是否落差」，有號差值可同時保留落差之方向與幅度，使吳忠義（2008）、Thompson et al.（2021）兩篇文獻分別強調之特定方向落差得以在特徵層級被區分，而非合併為單一「不一致」類別。 Δ 之值域為 -4 至 4 之整數，性質上為次序尺度之有號差值，標準化方式與歸類詳見 3.4.5 節。**
- **基金屬性瀏覽分布**：依 view_item 事件之 item_category（資產類別）、item_category2（風險等級，如 RR5）等欄位，統計使用者瀏覽基金之資產類別／風險等級分布，可作為 3.6.3 節內容導向推薦之補充特徵來源，或作為分群特徵之延伸選項（規劃項目，優先序低於交易與核心行為 RFM）。

eventDescription、eventCategory、eventLabel 等描述性欄位於樣本中多數為空值，且與 event_name、content_group 可能重疊，暫不納入正式特徵規劃，待取得完整 event_name/content_group 值清單後再評估是否有補充價值。

3.4.5 特徵標準化方法

標準化方法依 3.5.2、3.5.3 節已定案之特徵尺度分組原則一致處理，此為 3.5 節「標準化前提」段落所依賴之前置步驟。須特別注意：同一特徵之標準化方法須依其所屬之下游距離空間決定，而非全域套用單一規則——3.5 節 K-prototypes 分群之混合距離（平方歐氏距離）與 3.6.3 節內容導向推薦之基金屬性向量（餘弦相似度）是兩個性質不同之向量空間，標準化方法不可混用：

- **連續型特徵**（交易金額、瀏覽次數、年收入、興趣強度等）：以 **z-score 標準化** ($(x - \mu)/\sigma$) 處理，若該特徵經 3.4.3 節之 IHS 轉換，則於轉換後之數值上再行標準化。
- **次序類別特徵用於 3.5 節 K-prototypes 分群時**（KYC 風險等級、交易經驗／投資時長之分級）：整數編碼後同樣以 **z-score 標準化**，與連續型特徵採用同一標準化方法、併入同一數值變數組計算。**理由**：K-prototypes 之混合距離以平方歐氏距離加總數值變數組之各維度差異，若連續特徵採 z-score（標準化後變異數為 1）而次序特徵改採 [0,1] min-max（以 5 級之 RR1–RR5 KYC 風險等級為例，變異數約僅 0.125，假設各級近似均勻分布；3 級之次序變數則約為 0.167），兩者變異數相差約 6–8 倍，將使連續特徵在距離計算中之貢獻度為次序特徵之 6–8 倍，等同以不同倍率重新引入 3.5.3 節「標準化前提」段落原欲避免之量綱主導問題（僅程度由「完全稀釋」降為「稀釋一個數量級」，本質相同）。統一採 z-score 後，數值變數組全體變異數皆為 1，亦使 3.5.3 節 γ 權重之 Huang 經驗法則（以數值變數之平均標準差作為預設值）重新具備明確意義——標準化後之數值變數組標準差恆為 1，不受連續／次序特徵混合縮放影響。
- **次序類別特徵用於 3.6.3 節內容導向推薦時**（基金屬性之風險等級）：維持整數編碼後正規化至 [0,1] 區間，與無序類別之獨熱編碼（數值範圍同為 [0,1]）同尺度，以符合餘弦相似度衡量整體向量方向之需求。此為

3.6.3 節既有規劃，僅限於基金屬性向量空間使用，不可與上述 3.5 節分群特徵空間之 z-score 規則混淆或互換。

- **無序類別特徵**（職業、所得來源、裝置類型）：維持原始類別形式，作為 K-prototypes 類別變數組，以配對相異度計算，不進行具大小意義之數值編碼。
- **二元旗標特徵（binary flag，歸入無序類別組，n=2 之特例）**：3.4.2 節「是否觸發該行為」旗標（如篩選功能使用與否），本質為兩類別（是／否）之無序類別變數，規劃歸入無序類別組，以 K-prototypes 之配對相異度（matching dissimilarity）計算，不編碼為 0／1 後併入數值變數組。理由：若併入數值變數組，將與 3.5.3 節「次序類別特徵須採 z-score」之論證面臨同一問題——單一二元變數之變異數（ $p(1-p)$ ， $p = 0.5$ 時最大為 0.25）遠小於 z-score 標準化後連續特徵之變異數（固定為 1），距離計算貢獻度同樣會被稀釋；而歸入無序類別組後，二元變數以配對相異度處理（值相同計 0、不同計 1），恰為兩類別情形下數學上最自然之處理方式，無需另行標準化，亦不受本節量綱不一致問題影響。已知之特徵冗餘須留意：3.4.2 節「是否觸發篩選行為」旗標與「行為次數」計數特徵間存在確定性關係（次數 > 0 若且唯若旗標為 1），兩者併入分群特徵可能造成同一訊號以不同形式重複計入；規劃於第四章依實際分群結果評估此冗餘是否影響分群品質，必要時可考慮僅保留計數特徵、移除旗標特徵。
- **有號差值特徵（signed difference，歸入數值變數組）**：3.4.4 節「篩選風險等級與 KYC 風險等級之落差」 Δ （值域 -4 至 4 之整數）並非二元旗標，規劃歸入數值變數組，以 z-score 標準化後併入 K-prototypes 之平方歐氏距離計算，理由與次序類別特徵一致： Δ 具真實之大小與方向意義（落差幅度愈大、方向愈明確，代表風險偏好落差愈顯著），若改以無序類別之配對相異度處理，將完全捨棄其大小與方向資訊，僅能區分「有落差／無落差」，與本節捨棄純二元旗標、改採有號差值之設計初衷（保留方向與幅度）互相矛盾。

所有標準化參數（平均數、標準差）規劃僅以訓練期資料計算並鎖定，測試期資料套用訓練期參數轉換而非重新計算，此為呼應 3.5.1、3.7.1 節資料洩漏防範原

則之必要延伸——若標準化參數涵蓋測試期資料，將與分群特徵、評估設計之訓練／測試期隔離原則產生相同性質之資料洩漏風險。

3.4.6 資料限制與待確認事項

本節所述之三大原則——(1) 識別碼歸戶流程（僅以訓練期登入事件建立對照表、回溯歸戶訓練期內之匿名行為、共用裝置限縮回溯範圍至同一 session）、(2) 缺值處理依欄位性質分三類而非機械式套用單一規則、(3) 標準化參數僅以訓練期資料計算並鎖定——為方法論層級承諾，不因實際資料結果而調整。次序類別特徵之標準化方法依下游距離空間分流（3.5 節分群特徵採 z-score、3.6.3 節推薦特徵採 [0,1] min-max）、二元旗標特徵歸入無序類別組處理、風險偏好落差改採有號差值並歸入數值變數組以 z-score 標準化，同屬本節之方法論層級承諾，非待資料調整之項目。旗標與計數特徵之潛在冗餘是否移除旗標，則須待第四章依實際分群結果評估。

須待實際資料驗證之項目：交易 RFM 之延伸指標（待交易資料欄位確認後定案）、缺值填補之具體門檻（如中位數填補之缺失比例上限）、是否對特定特徵套用 IHS 轉換（依訓練期實際偏態係數判斷）、GA4 描述性欄位（eventDescription 等）是否具補充價值。相關確認結果將於第四章資料集描述中完整記錄。

3.5 投資人分群方法

本章屬 10/2 論文計畫書之計畫性內容，資料實驗尚未執行；演算法選擇（K-prototypes）、分群特徵計算期間限定於訓練期（呼應 3.7.1 資料洩漏防範原則）、須先標準化再計算距離之原則為方法論層級承諾，最佳分群數、各群體命名，以及 γ 權重之具體數值則須待取得實際資料後確認。

3.5.1 分群特徵之計算期間與資料洩漏防範

依 3.7.1 節訓練集／測試集時間切分原則，分群特徵（RFM 交易特徵、GA4 瀏覽時長等行為特徵）一律僅以訓練期資料計算，測試期資料不參與分群模型之訓練與分群標籤之產生。K-prototypes 分群模型於訓練期資料上配適（fit），所得之群

體原型（**prototype**）與分群標籤，即為 3.6 節分群輔助 CF 模型所使用之「投資人分群標籤」；測試期資料僅用於模型評估階段之正確答案（**ground truth**），不回饋影響分群結果。

此一設計之必要性在於：若分群特徵計算涵蓋全期（訓練期＋測試期）資料，分群標籤將間接攜帶測試期之交易與行為資訊，據此標籤產生之推薦結果再以同一測試期資料評估，即構成資料洩漏（**data leakage**）——本質上等同於「用未來資訊預測未來」，將使評估結果高估分群輔助推薦之實際效果，並與 3.7.1 節建立之時間切分嚴謹性直接矛盾。因此，分群特徵計算範圍與訓練期範圍完全一致，是本研究資料洩漏防範設計不可分割的一環，非 3.7.1 之孤立規則。

3.5.2 分群特徵之尺度組成

本研究之候選分群特徵同時包含三種不同尺度，此一資料特性直接決定了分群演算法之選擇：

表 3-3 分群特徵之尺度組成

尺度類型	特徵範例	說明
連續型 (continuous)	交易頻率、交易金額、瀏覽時長等交易與行為 RFM 特徵、年收入	具真實數值大小與距離意義，經 3.4 節標準化後可以平方歐氏距離衡量相似度
次序類別型 (ordinal categorical)	KYC 風險等級（RR1 – RR5，與基金風險評級同一系統，詳見 3.3.4 節）、交易經驗／投資時長之分級	類別間存在明確順序關係，但級距未必等距
無序類別型 (nominal categorical)	職業、裝置類型（手機／電腦／平板）	類別間不具大小關係，不宜以具大小意義之數值直接編碼

尺度類型	特徵範例	說明
)		

三種尺度並存之混合型資料（mixed-type data），是本研究分群演算法選擇的核心考量依據。

依 3.4 節資料前處理規劃，KYC 欄位依鑑別力與尺度分類如下：**職業**（無序類別，K-prototypes 必要性之直接支撐）；**交易經驗／投資時長**（次序類別，性質上接近帳戶年資，非純靜態屬性，為高價值特徵，比照第二章 Tan, E. H. L. et al.（2025）之 Maximum Account Vintage 處理）；**風險等級**（次序類別，整數編碼保留順序）；**年收入**（連續數值，無需人工分箱）；**所得來源**（無序類別，補充特徵）；**性別、年齡、職位**因第二章 Thompson et al.（2021）已實證 KYC 人口統計變數對交易行為解釋力甚微、職位與職業高度重疊區分力存疑，暫不列入分群特徵，僅作第四章資料集描述之樣本輪廓統計使用。此分類為初步評估，待交易與 GA4 行為資料欄位一併確認後，於 3.4 節資料前處理方法正式定案。

KYC 特徵鑑別力之提醒：Thompson et al.（2021，見第二章 2.2.2 節「核心先行研究」）以真實金融交易資料證實，KYC 人口統計資訊（性別、居住地、婚姻狀況等）對客戶交易行為之解釋力甚微，真正具鑑別力的是交易頻率與金額等行為特徵。此一發現對上表之 **KYC 風險等級**此項次序類別特徵構成提醒：風險等級屬使用者自陳之主觀 KYC 屬性，其分群鑑別力未必優於交易與行為 RFM 特徵，分群結果應避免過度依賴此類主觀屬性而弱化行為特徵之實質貢獻。**交易經驗／投資時長**雖亦為次序類別特徵，惟其性質上接近帳戶年資（比照第二章 Tan, E. H. L. et al.（2025）之 Maximum Account Vintage），屬客觀行為衍生指標而非主觀 KYC 屬性，不在此一提醒範圍內。本研究之因應方式為：交易 RFM 與行為 RFM 特徵在特徵數量與計算方式上均獲得完整發展（詳見 3.4 節前處理規劃），風險等級僅作為次序類別之補充維度，而非分群依據之主體；若第四章實際分群結果顯示風險等級對群體區分之貢獻確實有限（例如特徵重要性分析中排名極低），將於結果分析中如實呈現並討論，而非預設其必然有效。

3.5.3 分群演算法選擇：K-prototypes

傳統 K-means 演算法（MacQueen, 1967）以歐氏距離作為分群依據，本質上假設輸入特徵皆為連續數值。若將無序類別特徵（如職業）以整數直接編碼（例如老

師 = 1、工程師 = 2、醫師 = 3) 代入 K-means，將產生「醫師與老師之距離為工程師與老師之距離兩倍」之假象數值關係，而此種順序與距離在原始類別中並不存在，屬於統計上無意義的編碼假設。

為避免此一問題，本研究之特徵依尺度分組處理：

- **次序類別特徵**（KYC 風險等級、交易經驗／投資時長之分級）：因類別間具真實順序關係，以整數編碼（KYC 風險等級為 RR1–RR5 五級，編碼 1／2／3／4／5；交易經驗／投資時長之分級級數則待實際資料確認）保留其順序資訊，再以 **z-score 標準化**（與連續型特徵採用同一標準化方法，詳見 3.4.5 節）併入數值變數組計算——不可改採 [0,1] min-max 正規化，否則其變異數將遠小於 z-score 後連續特徵之變異數（固定為 1）：以 5 級之 RR1–RR5 風險等級為例，min-max 正規化後變異數約為 0.125（假設各級近似均勻分布），若為 3 級之次序變數則約為 0.167，無論級數為何皆遠小於 1，使次序特徵於距離計算中之貢獻度被稀釋約一個數量級，與下方「標準化前提」段落之論證直接抵觸。
- **無序類別特徵**（職業、裝置類型）：維持原始類別形式，獨立為類別變數組，不進行具大小意義之數值編碼。

本研究採用 **K-prototypes 演算法** (Huang, 1997) 進行分群。K-prototypes 演算法之原始出處為 Huang (1997) 發表於 PAKDD (Pacific-Asia Conference on Knowledge Discovery and Data Mining) 之會議論文 “Clustering Large Data Sets with Mixed Numeric and Categorical Values”，該文首次提出結合平方歐氏距離（數值變數）與簡單配對相異度（類別變數）之混合距離度量，與本節下方之距離公式一致。Huang (1998) 發表於 *Data Mining and Knowledge Discovery* 期刊之論文 “Extensions to the k-Means Algorithm for Clustering Large Data Sets with Categorical Values”，則是在 1997 年 PAKDD 會議論文基礎上擴充之期刊完整版，同時涵蓋 k-modes（純類別資料）與 k-prototypes（混合型資料）兩種演算法之完整推導與實驗，兩篇文獻可並列引用（會議論文為原始提出來源，期刊論文為完整擴充版本）。

K-prototypes 之整體相異度量結合兩部分計算方式：數值變數組以平方歐氏距離（squared Euclidean distance，即距離平方和，未開根號）計算，類別變數組以配

對相異度（matching dissimilarity，即類別值不相同時計為 1、相同時計為 0）計算，兩者以權重參數 γ 加權合併為單一距離指標：

$$d(x, y) = \sum_{j \in \text{數值變數}} (x_j - y_j)^2 + \gamma \sum_{j \in \text{類別變數}} \delta(x_j, y_j)$$

其中 $\delta(x_j, y_j) = 0$ （當 $x_j = y_j$ ）或 1 （當 $x_j \neq y_j$ ）， γ 為平衡數值與類別變數尺度差異之權重參數。

數值變數之標準化前提：上式之數值變數組須先經過 3.4 節之標準化處理（如 z-score 標準化）方可代入計算，否則量綱差異將使距離度量被特定變數主導——例如 KYC 風險等級編碼為 RR1 – RR5（1 – 5）之整數，而交易金額動輒萬元計，若未標準化，數值變數組之距離將幾乎完全由交易金額決定，KYC 等級之區分力實質上被稀釋為零。本節之混合距離公式，其數值變數組 $(x_j - y_j)^2$ 恆假設 x_j, y_j 為 3.4 節標準化後之數值，此為 3.5 節與 3.4 節之必要銜接關係，非各自獨立之步驟。

權重參數 γ 之決定方式： γ 之數值須視數值變數組標準化後之離散程度而定，並無普遍適用之固定值，規劃依下列優先順序決定：(1) 優先採用 Huang (1997, 1998) 建議之經驗法則，以數值變數之平均標準差作為 γ 之預設值，使類別變數之相異度貢獻與數值變數之離散尺度相當；(2) 若採用之分群套件（如 kmodes 套件之 KPrototypes 類別）提供 γ 自動估計功能，則以套件預設之估計方式為輔助參考；(3) 於取得實際資料後，另以敏感度分析（sensitivity analysis）檢視 γ 於一定範圍內變動時，分群結果（以 3.5.4 節驗證指標衡量）是否穩定，作為最終 γ 值選定之依據。 γ 之具體數值屬須待實際資料確認之參數，非本節之核心方法論承諾。K-means 於本節僅作為「為何不適用混合型資料」之方法論對照，不列入正式分群結果之比較實驗。

3.5.4 最佳分群數選取方法

分群數 K 之驗證指標選用，須與 3.5.3 之混合相異度定義相容，而非直接套用僅適用於連續歐氏距離之傳統指標——若指標本身即建立在「輸入皆為連續數值」之假設上，將與本研究採用 K-prototypes 之理由（避免對類別變數強加不具意義之數值距離）自相矛盾。規劃驗證方式如下：

- **Elbow Method (Thorndike, 1953；主要依據)**：不採用傳統 K-means 之群內誤差平方和 (WCSS，本身即以平方歐氏距離定義)，改為觀察 **K-prototypes** 演算法自身之目標函數總成本 (total cost) ——即各樣本與其所屬群體原型 (prototype) 之 γ 加權混合相異度總和 (同 3.5.3 距離公式 $d(x,y)$) ——隨 K 增加之遞減趨勢，取邊際改善明顯趨緩之轉折點。此一總成本即為演算法迭代求解之最小化目標，故與 K-prototypes 之混合距離定義天然相容。
- **Silhouette Score (主要依據)**：不採用預設假定連續 (平方) 歐氏距離之計算方式，改以 **K-prototypes** 之混合相異度矩陣 (即 3.5.3 之 γ 加權合併距離) 作為樣本間距離依據 (Rousseeuw, 1987 之原始定義並未限定距離度量必須為歐氏距離，可直接代入任一相異度矩陣)，衡量個別樣本與同群成員之緊密程度相對於與最近鄰群之分離程度，數值介於 -1 至 1 之間，數值愈高代表分群品質愈佳。
- **Davies-Bouldin Index (Davies & Bouldin, 1979) 與 Calinski-Harabasz Index (Caliński & Harabasz, 1974) (輔助參考，範疇限定)**：此二指標之原始定義建立於連續變數之質心距離與變異數分解 (組間／組內離散度) 之上，對無序類別變數 (如職業、裝置類型) 並無對應之數學定義，無法直接套用於 K-prototypes 之混合相異度。本研究規劃僅於數值變數子空間 (即交易頻率、交易金額等連續特徵) 上輔助計算此二指標，作為分群結果於連續特徵維度上之品質參考，不作為對整體混合型分群品質之驗證，此一範疇限制將於第四章實驗結果中明確標註。

多指標收斂之結果將作為最終分群數之判斷依據，而非僅依賴單一指標之結果。分群完成後，將依各群體於交易與行為特徵上之輪廓差異，予以商業意義之命名 (例如「高頻積極型」「保守長期持有型」)，作為後續推薦模型設計與第五章實務應用建議之基礎。

3.5.5 方法論承諾與待驗證項目

本節所述之演算法選擇 (K-prototypes) 與混合距離計算方式，係根據特徵尺度混合此一結構性事實所作之方法論決策，不受實際資料分布結果影響，為本研究之核心承諾；驗證指標須與混合距離定義相容之原則 (Elbow 改用 K-prototypes 總

成本、Silhouette 改用混合相異度矩陣、Davies-Bouldin／Calinski-Harabasz 限定於數值子空間輔助參考）亦屬本研究之方法論承諾，非待資料調整之項目。分群特徵一律僅以訓練期資料計算、測試期資料不參與分群（3.5.1 節）亦為與 3.7.1 節共同構成之資料洩漏防範核心承諾，不因實際資料結果而調整。惟最佳分群數 K 之最終數值、各驗證指標之實際收斂結果，以及各群體之商業命名，均須待取得實際資料並執行分群後方能確認；若各指標結果不一致，將以多指標收斂情形輔助判斷，相關調整過程將於第四章實驗結果完整記錄。 γ 權重之具體數值（依 Huang 1997/1998 經驗法則、套件預設或敏感度分析決定其一），以及各數值變數標準化後之實際離散程度，均須待取得實際資料後確認。

3.6 個人化推薦模型方法

3.6.1 推薦模型設計總覽

本研究規劃建構四種推薦模型，依複雜度遞增排序，皆完全依據訓練期歷史資料運算產出推薦清單，不需使用者即時互動：

表 3-4 個人化推薦模型設計總覽

模型	產出邏輯	所需資料
熱門推薦 (Baseline)	依訓練期全體使用者之購買次數排行榜，排除使用者於訓練期已購買之基金，取排行最高之未持有基金產出推薦清單	訓練期交易紀錄（全體）
內容導向推薦	依使用者於訓練期已購買基金之屬性（風險等級、資產類別、地區、幣別），計算屬性相似度，推薦屬性相近但尚未購買之基金	訓練期個人交易紀錄＋基金屬性資料
協同過濾 (ALS)	將訓練期「使用者 × 基金」互動整理為二元偏好矩陣（購買 = 1，未購買 = 0）並依觀察強度（購買次數或金額）計算信賴權	訓練期「使用者 × 基金」互動矩陣（含購買次數或金額，用於信賴權重計算）

模型	產出邏輯	所需資料
	重，以交替最小平方法（Alternating Least Squares, ALS）進行矩陣分解，估計使用者對 尚未購買基金 之偏好分數，取 Top-K 作為推薦清單，詳細公式見 3.6.4	
分群輔助 CF（本研究核心貢獻）	沿用 3.6.4 全域 ALS 模型之偏好分數，先依 3.5 節分群結果將候選基金池縮小為「使用者所屬群體其他成員於訓練期購買過、且該使用者自身尚未購買之基金」，再於縮小後之候選池內依原分數排序取 Top-K；分群僅作用於候選集生成，不改變 ALS 模型本身之訓練方式，操作型定義見 3.6.5	訓練期互動矩陣＋投資人分群標籤

四模型由簡至繁排序，前三者作為比較基準（baseline），第四者為本研究欲驗證其增量效果之核心方法，對應研究問題 RQ2「分群輔助推薦是否比既有方法更準」。

資料洩漏防範之一致性說明：上表「投資人分群標籤」係依 3.5.1 節所述，僅以訓練期資料配適 K-prototypes 分群模型所得——分群模型之訓練範圍與四模型之推薦運算範圍完全一致，皆限定於訓練期，測試期資料不參與分群或推薦模型之任何訓練步驟，僅作為 3.7 節評估階段之正確答案。

候選基金池之統一規則（排除訓練期已持有基金）：基金投資存在大量定期定額（SIP）與加碼申購（複購）行為，若四模型之候選項排除規則不一致，指標將不可比：3.6.3 內容導向已明確排除「尚未購買」之基金，但熱門推薦與 ALS 若未同步排除，則「推薦使用者已持有之基金」將成為熱門推薦與 ALS 之隱性優勢（使用者持續加碼同一檔基金之機率本即偏高），與內容導向推薦立足點不同，四模型比較即失去意義。因此，本研究明確規定：四模型之候選基金池，一律排

除使用者於訓練期已購買（持有）之基金，僅對使用者尚未接觸過之基金進行評分與排序（已反映於上表各模型之產出邏輯敘述）。此規則之設計動機有二：(1) 確保四模型之候選範圍定義一致，指標可直接比較；(2) 使本研究之推薦任務聚焦於「新基金探索」（discovering new funds），對應個人化推薦系統文獻中常見之 explore（發掘新項目）情境，而非 repeat-purchase（複購預測）此一性質截然不同之子問題。此規則須與 3.7.1 節之 ground truth 定義一併理解。

「已持有」之操作型定義：「訓練期已持有（購買）之基金」須依 3.3.3 節「交易資料表是否含贖回紀錄」之答案精確定義：(1) 若交易資料表含贖回紀錄（transaction_type 欄位存在），「已持有」定義為訓練期內淨部位為正之基金——即訓練期內曾申購、且未於訓練期內被完全贖回之基金（若有數量／單位欄位可用，以累積申購單位數減累積贖回單位數判定；若僅有金額欄位，則以累積申購金額與累積贖回金額之相對關係近似判定，精確計算方式待交易欄位確認後於第四章補充）。此一定義下，已於訓練期內全數贖回之基金不視為持有，仍可能出現於候選基金池中——因使用者贖回後，若日後重新申購同一基金，仍屬合理之個人化推薦情境，不應因歷史上曾持有而永久排除。(2) 若交易資料表確認僅含申購紀錄（無贖回），「已持有」等同於「訓練期內曾出現於交易紀錄之基金」，即現行定義維持不變。此一條件式定義使本規則得以在交易欄位確認前先行定案，屆時僅需依答案套用對應分支，不影響本節其餘設計。

3.6.2 熱門推薦（Baseline）

以訓練期全體使用者之基金購買次數進行排序，產出單一份全域熱門排行榜；此排行榜之計算與排序邏輯對所有使用者一致，不涉及任何個人化邏輯，是四模型中唯一不依賴個別使用者資料計算分數之模型。惟依 3.6.1 節候選基金池之統一規則，推薦階段須對每位使用者依序過濾該排行榜——依全域排名依序檢視，排除使用者於訓練期已購買（持有）之基金，取排名最高之前 K 檔尚未持有基金作為該使用者之最終推薦清單。因此，熱門推薦之底層排名邏輯對所有使用者一致，但因過濾條件因人而異，各使用者實際收到之 Top-K 推薦清單內容可能不同——此為與「個人化程度僅依賴單一使用者自身歷史」之內容導向推薦（3.6.3 節）之本質差異：熱門推薦之個人化僅來自候選集之過濾，排序依據本身不具個人化。

此設計與 3.6.5 節分群輔助 CF 之「候選集篩選、排序依據不變」邏輯一致，為本研究候選集排除規則之統一體現。

3.6.3 內容導向推薦

依使用者於訓練期已購買基金之屬性特徵（風險等級、資產類別、計價幣別、投資地區等），計算候選基金與使用者歷史購買基金之屬性相似度，取相似度最高且尚未購買之 Top-K 檔基金作為推薦清單。此模型之個人化程度僅依賴單一使用者自身歷史，未納入其他使用者之群體資訊，作為與協同過濾類模型比較之基準。
操作型定義：相似度度量與使用者輪廓聚合方式。 為避免「屬性相似度」流於抽象描述，本節明確規劃：

- **基金屬性向量化（依尺度分組編碼，與 3.5.2 節原則一致）：**基金屬性同樣包含次序類別與無序類別兩種尺度，編碼方式須與 3.5.2 節「次序類別以整數編碼保留順序、無序類別以獨熱編碼避免假象距離」之原則一致，而非不加區分地一律採獨熱編碼——若將風險等級（具真實高低順序）獨熱編碼，將使「風險等級 1 與 5」之相似度等同於「風險等級 1 與 2」，順序資訊完全流失，且與 3.5 節「次序類別須以整數編碼保留順序」之論證自相矛盾。因此：**風險等級（次序類別）**以整數編碼後正規化至 $[0, 1]$ 區間（保留順序與相對距離資訊）；**資產類別、計價幣別、投資地區（無序類別，類別間無大小關係）**以獨熱編碼（one-hot encoding）轉為二元向量。次序類別之正規化數值與無序類別之獨熱編碼向量並列合併為單一基金屬性向量。**此處之 $[0,1]$ min-max 正規化，與 3.5 節 K-prototypes 分群特徵之次序類別標準化方法（z-score，見 3.5.2、3.4.5 節）刻意不同，不可互換：**本節之基金屬性向量供餘弦相似度計算，向量各維度須與獨熱編碼之 $\{0,1\}$ 值域同尺度， $[0,1]$ min-max 恰能滿足此需求；3.5 節之 K-prototypes 混合距離則以平方歐氏距離加總數值變數組差異，須與連續特徵之 z-score 同尺度（變異數皆為 1），若誤用 $[0,1]$ min-max 將使次序特徵之距離貢獻度被嚴重稀釋（詳見 3.4.5 節）。兩節分屬不同之向量空間與相似度／距離定義，標準化方法之選擇邏輯亦不同，此為刻意設計而非不一致。

- **相似度量**：採用**餘弦相似度（cosine similarity）**衡量基金屬性向量間之相似程度。由於向量同時包含正規化數值（風險等級）與二元獨熱編碼（資產類別等），餘弦相似度對向量整體方向之衡量方式，仍可合理處理此類混合尺度向量，且對向量長度（維度數）不敏感，優於直接使用歐氏距離；惟正規化與獨熱兩部分之相對尺度是否需額外加權，須待實際資料驗證，相關調校將於第四章記錄。
- **使用者輪廓聚合方式**：使用者於訓練期可能購買多檔基金，其「偏好輪廓」規劃以**向量平均（centroid）**方式聚合——將使用者訓練期購買之所有基金屬性向量取算術平均，作為代表該使用者偏好之輪廓向量，再計算此輪廓向量與各候選基金屬性向量之餘弦相似度並排序。採平均而非「逐檔取最大相似度」之理由是：向量平均可反映使用者整體偏好之重心，避免推薦結果被單一極端持股過度主導；惟若後續資料顯示使用者偏好呈現明顯之多群集分布（例如同時持有高風險與低風險基金而非居中偏好），亦可能改採逐檔取最大相似度或其他聚合方式，此為須待實際資料驗證之設計選擇，相關比較將於第四章記錄。

3.6.4 協同過濾（ALS 隱性回饋矩陣分解）

本研究採用交替最小平方法（Alternating Least Squares, ALS）進行隱性回饋（implicit feedback）矩陣分解，方法依循 Hu, Koren, & Volinsky (2008) 之隱性回饋框架，而非單純之二元矩陣分解（binary matrix factorization）。此框架之核心，是明確區分「觀察到的購買行為」與「使用者對基金之真實偏好」二者並不同：使用者購買某檔基金，不代表其偏好程度必然高；使用者未購買某檔基金，也不代表其對該基金抱持負面偏好，可能僅是尚未注意到、或尚無資金配置，屬於**低信賴之缺失值**，而非負向樣本。

具體而言，對每一使用者 u 與基金 i 之組合，定義原始觀察強度 r_{ui} （本研究規劃以訓練期購買次數為主，若資料完整度允許則改用累積申購金額，對應 3.7.2 節「所需資料欄位」中之 amount 欄位），並據此建構兩組量：

$$p_{ui} = \begin{cases} 1, & r_{ui} > 0 \\ 0, & r_{ui} = 0 \end{cases} \quad c_{ui} = 1 + \alpha r_{ui}$$

其中 p_{ui} 為二元偏好指標（購買過 = 1，未購買 = 0）， c_{ui} 為信賴權重（confidence）， α 為控制觀察強度影響力之超參數（Hu et al., 2008 建議之常見設定為 $\alpha = 40$ ，實際數值須依資料規模調校）。ALS 之目標函數為信賴加權之平方誤差，對使用者潛在因子 x_u 與基金潛在因子 y_i 求解：

$$\min_{x_u, y_i} \sum_{u,i} c_{ui} (p_{ui} - x_u^T y_i)^2 + \lambda \left(\sum_u \|x_u\|^2 + \sum_i \|y_i\|^2 \right)$$

透過交替固定使用者潛在因子與基金潛在因子並反覆求解最小平方問題收斂。信賴權重之設計使模型不會將「未購買」一律視為與「購買」對等之負向樣本，而是依購買次數或金額之高低，賦予已觀察到之正樣本不同強度之信賴程度——此為隱性回饋矩陣分解與傳統二元矩陣分解之本質差異，亦為本研究引用 Hu et al. (2008) 之方法論依據。

此模型可捕捉「購買模式相似之使用者」間之群體規律，其個人化依據不受限於單一使用者自身歷史，較內容導向推薦更能反映跨使用者之協同訊號。實作規劃採 Python implicit 套件之現成 ALS 實作（該套件原生支援信賴權重輸入，無需自行實作最佳化流程）。

3.6.5 分群輔助 CF：候選集篩選整合方式（方案 A）之操作型定義

分群資訊與協同過濾之整合，理論上存在兩種截然不同之設計方式，兩者對分群結果的依賴程度與實驗結論之意涵完全不同，須明確擇一並清楚定義：

- 方式一：分群導向候選集篩選（**candidate-set filtering**，即方案 A，本研究採用）。ALS 模型僅訓練一次，且訓練方式與 3.6.4 之全域 ALS 完全相同——以訓練期全體使用者之互動矩陣配適單一潛在因子模型，不因分群而拆分訓練資料或另建子模型。分群結果僅作用於推薦階段（**inference-time**）之候選集生成：先依 3.5 節分群結果，篩出候選基金池（即「使用者所屬群體其他成員於訓練期購買過之基金集合」），再取該全域 ALS 模型對候選池內各基金之原始偏好分數進行排序，取 Top-K 作為最終推薦清單。換言之，分群不影響潛在因子本身之估計，僅影響最終

呈現給使用者之候選範圍，本質上是一種 post-hoc 過濾機制，非修改評分模型之訓練邏輯。

- 方式二：分群別獨立訓練（**per-cluster ALS**，本研究不採用）。依分群結果將使用者切分為多個子群，各群獨立配適一個 ALS 模型，使潛在因子估計本身即依群體而異。此法之分群輔助效果來自模型本身學到之群體專屬購買模式，而非候選範圍之限縮；惟各子群樣本量較全體為小，潛在因子估計之穩定性可能因資料稀疏而受影響，且與 3.6.4 之基準 ALS 模型不再共用同一組潛在因子，模型間之比較基礎亦隨之改變。

本研究採方式一（**候選集篩選**）作為分群輔助 CF 之核心整合機制，「分群輔助 CF」之名稱應理解為「以分群結果輔助篩選 ALS 之候選推薦範圍」，而非「以分群訓練出不同的推薦模型」。此設計實作單純，候選池篩選與 ALS 訓練流程均可以現成套件（implicit）完成，不需修改矩陣分解演算法內部結構，亦不涉及方式二之子群樣本稀疏化風險，為本研究方法論層級之核心承諾。若實際資料規模或候選池稀疏度不足以支撐候選集縮減之效果，將視情況調整篩選門檻（如放寬同群定義、納入次相似群體）或改採混合策略，調整原因與結果將於第四章說明；方式二列為第五章未來研究方向。

已知之潛在效果消長（trade-off）：由於分群輔助 CF 與 3.6.4 之基準 ALS 共用同一組潛在因子與偏好分數，兩者之差異純粹來自候選範圍之限縮，此一操作型定義使 trade-off 之解釋更為明確：候選池縮小後，Precision 預期因排除雜訊候選項而提升；但 Recall 可能因使用者實際購買之基金恰好不在同群成員購買清單內而下降。此一消長關係須於第四章結果分析中明確呈現，而非僅報告單一指標即宣稱模型優劣。

3.6.6 方法論承諾與待驗證項目

本節所述之四種模型組合、分群輔助 CF 採「分群導向候選集篩選」（方式一／方案 A，而非分群別獨立訓練 ALS 之方式二）之整合設計、以及候選基金池一律排除訓練期已持有基金（聚焦「新基金探索」而非複購預測）之範圍界定，係根據推薦系統文獻常見之基準模型比較架構、工程可行性考量，以及四模型指標可比性之要求所作之方法論決策，為本研究之核心承諾，預期不因實際資料結果而調整——此範圍界定亦直接決定第五章對於複購／定期定額此一實務重要行為之

研究限制陳述。惟候選集篩選之具體門檻（如同群定義範圍、候選池最小規模）、ALS 潛在因子維度、信賴權重超參數 α 、觀察強度 r_{ui} 採購買次數或金額等超參數與設計選擇，均須待取得實際資料並完成前處理後，依資料規模與稀疏度進行調校，相關調整過程與結果將於第四章實驗結果完整記錄，不視為偏離計畫書。

3.7 模型評估方法

3.7.1 訓練集／測試集切分方式

本研究規劃依時間切分訓練期與測試期（例如以前 10–14 個月資料為訓練期、最後 2–4 個月資料為測試期），採時間切分而非隨機切分。採此設計之理由為：真實推薦情境必然是「以過去已發生之資料，推薦尚未發生之未來行為」，若採隨機切分，測試集中可能包含訓練期之後才產生之市場資訊或使用者行為模式，導致模型在訓練階段間接取得「未來」資訊，形成資料洩漏（data leakage），使評估結果高估模型之實際預測能力。

Ground truth 之定義（排除複購）： 基金投資存在大量定期定額與加碼申購（複購）行為，此一特性對 ground truth 之界定有決定性影響，須於此明確定義，而非留待第四章才決定：若測試期 ground truth 涵蓋使用者對訓練期已持有基金之複購，則「推薦使用者已持有之基金」將成為命中率極高之廉價策略（使用者對既有持股加碼之機率本即偏高），使指標嚴重失真且無法反映真正的個人化推薦能力；反之若一律排除已購買項，模型將永遠無法命中複購，而複購在基金投資場域占比甚高。本研究依 3.6.1 節「候選基金池統一規則」之一致邏輯，明確規定：測試期 ground truth 僅計入使用者於測試期購買、且訓練期未曾購買（依 3.6.1 節條件式定義）之「新基金」，即 ground truth 與候選基金池採用同一項排除條件（排除訓練期已持有基金）。換言之，本研究之推薦任務範圍聚焦於「新基金探索」，複購／定期定額續扣行為不納入本研究主要評估範圍，另列為第五章研究限制，並於該章實務應用建議中另行討論複購對好好證券之商業意義。

交易類型之必要性： 上述「測試期購買」須明確限定為申購類型交易，排除贖回交易——若交易資料表含贖回紀錄而 ground truth 之判定未排除贖回事件，測試期之贖回動作將被誤當成推薦命中之目標，使 Precision／Recall 計算納入與

「新基金探索」任務無關之雜訊。此一條件式定義與 3.4.3 節交易 RFM、3.6.1 節候選基金池之邏輯一致（見 3.3.3 節「交易類型欄位之必要性」）：若交易表確認僅含申購紀錄，此限定形同無操作，不影響既有 ground truth 定義。

評估對象範圍（須與上述 ground truth 定義一致）：僅納入「訓練期有交易紀錄，且測試期購買至少一檔訓練期未持有之新基金」之使用者，此為三層過濾條件之交集：(1) 訓練期須有交易紀錄，否則屬純新戶冷啟動情境，缺乏歷史互動資料可供 ALS 學習；(2) 測試期須有交易紀錄；(3) 測試期之交易須至少包含一筆「新基金」（訓練期未持有）之購買，而非全數為既有持股之複購或定期定額續扣。第三層條件係呼應上述 ground truth 定義而生之必要限縮：若僅要求「測試期有交易紀錄」（未限定是否為新基金），則「測試期僅續扣既有定期定額、未購買任何新基金」之使用者雖符合表面條件，其 ground truth 集合（新基金購買）實為空集合，Recall 分母仍為零、無法計算，此正是本節原欲排除之情形。基金投資人中「測試期僅續扣舊有定期定額」之比例可能不低，此一第三層條件將使實際評估樣本較僅採前兩層條件時更為縮限，具體縮減幅度將於第四章資料集描述中揭露，並與第一章 1.4 節之研究限制說明一致對應。

3.7.2 評估指標定義與計算方式

本研究以 Precision@K、Recall@K、MAP（Mean Average Precision）三項資訊檢索領域常用指標作為主要評估依據（Manning, Raghavan, & Schütze, 2008），並補充 NDCG@K（Normalized Discounted Cumulative Gain）（Järvelin & Kekäläinen, 2002）作為輔助指標——NDCG@K 之分母為「理想排序下之最大可能得分」而非固定之 K 或使用者實際購買數，可部分緩解 3.7.3 節所述「Precision@K 分母天生受限」之問題，使跨使用者（測試期購買數量差異大）之分數更具可比性。以單一使用者、K = 5 為例：若模型推薦之 Top-5 清單為基金 A/B/C/D/E，該使用者測試期實際購買且屬訓練期未持有之「新基金」為 B/E/F（共 3 檔；依 3.7.1 節 ground truth 定義，此處已排除該使用者訓練期已持有基金之複購紀錄），則：

- **Precision@K** = 命中數 ÷ K = 2 ÷ 5 = 0.4，代表推薦清單中命中使用者實際購買之比例。

- **Recall@K** = 命中數 ÷ 使用者實際購買數 = $2 \div 3 \approx 0.67$ ，代表使用者實際購買中被推薦到之比例。
- **MAP (Mean Average Precision)**：在 Precision 之基礎上，額外考慮命中項目於推薦清單中之排序位置，命中項目排序愈靠前，分數愈高，符合使用者較關注清單前段內容之真實情境。單一使用者之 Average Precision (AP@K) 定義為：

$$AP@K = \frac{1}{\min(m, K)} \sum_{k=1}^K P(k) \cdot \text{rel}(k)$$

其中 m 為該使用者於 ground truth 中之相關項目總數（本例 $m = 3$ ）， $P(k)$ 為推薦清單前 k 項之 Precision， $\text{rel}(k) \in \{0,1\}$ 表示第 k 個推薦項目是否命中。分母採 $\min(m, K)$ ，為推薦系統評估文獻常見慣例：當相關項目數少於 K （如本例 $m = 3 < K = 5$ ）時，避免以 K 作分母而人為壓低理論上可達之最高分數。以本例（推薦清單 A/B/C/D/E，命中 B 於第 2 名、E 於第 5 名）計算： $P(2) = 1/2 = 0.5$ 、 $P(5) = 2/5 = 0.4$ ，其餘位置未命中之 $\text{rel}(k) = 0$ ，故：

$$AP@5 = \frac{1}{\min(3,5)} (P(2) \cdot 1 + P(5) \cdot 1) = \frac{0.5 + 0.4}{3} = 0.3$$

MAP 即為所有使用者 AP@K 之平均值： $MAP@K = \frac{1}{|U|} \sum_{u \in U} AP@K(u)$ ，其中 U 為評估範圍使用者集合。

NDCG@K (輔助指標)：單一使用者之 NDCG@K 定義為：

$$NDCG@K = \frac{DCG@K}{IDCG@K}, \quad DCG@K = \sum_{k=1}^K \frac{\text{rel}(k)}{\log_2(k+1)}$$

其中 IDCG@K (Ideal DCG) 為將 $\min(m, K)$ 個相關項目排在最前面時之 DCG@K，作為正規化分母，使 NDCG@K 之值域固定介於 0 至 1 之間，且不受單一使用者相關項目數量多寡影響其可比性。以本例延續計算： $DCG@5 = \frac{1}{\log_2 3} + \frac{1}{\log_2 6} \approx 0.631 + 0.387 = 1.018$ （命中位置為第 2、5 名）；理想排序下 $\min(3,5) = 3$ 個相關項目排最前三名， $IDCG@5 = \frac{1}{\log_2 2} + \frac{1}{\log_2 3} + \frac{1}{\log_2 4} \approx 1 + 0.631 + 0.5 = 2.131$ ；故 $NDCG@5 = 1.018/2.131 \approx 0.48$ 。NDCG@K 僅作為 Precision@K/Recall@K/MAP 三項主要指標之輔助佐證，第四章之模型比較仍

以三項主要指標為主要論證依據，NDCG@K 用於交叉驗證排序品質之結論方向是否一致。

計算邏輯（對每個模型重複執行，虛擬碼僅用於說明指標定義，非實作規劃）：

```
for 每位使用者 in 評估範圍使用者：
    推薦清單 = 模型.產出 TopK(使用者, K) # 候選池已排除訓練期已持有基金
    (
        3.6.1 節
    )
    實際購買 = 測試期資料[使用者的所有 fund_code, 僅申購類型交易] - 訓練
    期已持有基金集合 # ground truth 排除複購與贖回
    命中數 = 推薦清單與實際購買的交集數量
    該使用者 _Precision = 命中數 / K
    該使用者 _Recall = 命中數 / len(實際購買)
    該使用者 _AP = 依上述 AP@K 公式計算
    該使用者 _NDCG = 依上述 NDCG@K 公式計算（輔助指標）
```

最終 Precision@K = 所有使用者之 該使用者 _Precision 取平均
 最終 Recall@K = 所有使用者之 該使用者 _Recall 取平均
 最終 MAP@K = 所有使用者之 該使用者 _AP 取平均
 最終 NDCG@K = 所有使用者之 該使用者 _NDCG 取平均（輔助指標）

實作套件之選用（須待實際資料驗證）：上述虛擬碼僅用於明確定義四項指標之計算邏輯，正式實作規劃直接採用現成套件而非自行刻寫，以降低計算錯誤風險。候選套件包括 Python recmetrics 套件（提供 Precision@K、Recall@K、MAP@K 現成函式，惟是否涵蓋 NDCG@K 尚待核對）與 implicit 套件內建之 ranking_metrics_at_k（同時輸出 Precision、Recall、MAP、NDCG 四項指標，天然對應本研究需求）。因 recmetrics 套件近年維護頻率較低，正式實作前將先核對其是否完整支援本研究所需之四項指標、計算邏輯是否與上述 AP@K／NDCG@K 定義一致；若不一致或功能不齊備（尤其 NDCG@K 部分），改採 implicit 套件內建函式，或依上述公式自行實作並以現成套件結果交叉驗證。套件選用結果將於第四章實驗結果中註明。

所需資料欄位（僅需交易紀錄）：

資料來源：以下四項欄位均取自內部交易資料庫（非 GA4／BigQuery——已確認基金申購／贖回等交易事實僅記錄於內部資料庫，GA4 不追蹤實際購買事件，見 3.4.4 節與第三章 GA4 欄位評估紀錄）。

表 3-5 評估所需資料欄位

欄位	說明
user_id	使用者識別碼（匿名化）

欄位	說明
fund_code	基金代碼
transaction_date	交易日期（買入）
amount	交易金額（必要欄位）——3.4.3 節交易 RFM 之 Monetary 定義為 $M_u = \sum \text{amount}$ ，為分群核心特徵之一，若無 amount 則 RFM 之 M 構面無法計算；此欄位同時作為 3.6.4 節 ALS 信賴權重 $c_{ui} = 1 + \alpha r_{ui}$ 之觀察強度 r_{ui} 來源（替代退而求其次之購買次數計數）

3.7.3 分數之意義與模型間比較邏輯

K 值之報告範圍： 前述範例以 $K = 5$ 說明指標計算方式，惟正式實驗規劃報告多組 K 值（如 $K = 5、10、20$ ），而非僅單一 K 值，理由是不同 K 值反映不同之實務情境（K 較小對應「首頁精選推薦」，K 較大對應「完整推薦清單頁」），且可觀察模型排序品質在不同截斷點下是否穩定。各 K 值下之 Precision@K、Recall@K、MAP@K、NDCG@K 將於第四章以表格並列呈現，具體 K 值組合視資料規模於取得實際資料後最終確認。

單一指標數值本身並無絕對之好壞標準：本研究之基金型錄約達 4,000+ 檔，使用者於測試期之購買數量通常僅為個位數，Precision@K 之分母天生受限，即使為理想模型，數值亦不會接近 1；業界推薦系統於此類指標之常態表現多落於 0.1–0.2 區間。此一限制部分可由 3.7.2 節之 NDCG@K 緩解——其正規化分母為理想排序下之最大可能得分，較不受使用者相關項目數量多寡之影響，可作為 Precision@K/Recall@K 之交叉佐證。

本研究之核心論證邏輯為模型間之相對比較，而非單一數值之絕對高低：分群輔助 CF 之指標分數，是否顯著高於熱門推薦、內容導向推薦、純 ALS CF 三個基準模型？

RQ2 統計檢定之決策準則（與 3.7.4 RQ3 採一致嚴謹度）： 四模型任兩者之比較共 $\binom{4}{2} = 6$ 組配對比較（每一 K 值、每一指標各自進行）。規劃如下：

1. **檢定方法選擇：** 因四模型皆於同一批使用者上計算指標，屬配對樣本（paired samples）設計。規劃先對各配對之分數差異執行常態性檢定

(Shapiro-Wilk 檢定；Shapiro & Wilk, 1965)：若差異分布符合常態假設，採成對 **t** 檢定 (**paired t-test**)；若不符合，則採 **Wilcoxon 符號等級檢定** (**Wilcoxon signed-rank test**)，此決策準則與 3.7.4 節 RQ3 之常態性依賴邏輯一致。

2. **多重比較校正**：因單一 K 值、單一指標下即涉及 6 組配對比較，若不校正顯著水準，將提高型一誤差 (**false positive**) 機率。規劃採 **Holm-Bonferroni 校正** (Holm, 1979，逐步下修顯著水準，統計檢定力優於傳統 Bonferroni 校正) 調整 6 組比較之顯著水準。
3. **顯著水準與效果量**：家族錯誤率 (**family-wise error rate**) 設定為 $\alpha = 0.05$ ，經 Holm-Bonferroni 校正後逐組比較。除顯著性外，另計算效果量：成對 **t** 檢定情境採 **Cohen's d** (Cohen, 1988)，Wilcoxon 檢定情境採 **rank-biserial correlation**，避免僅依賴 **p** 值判斷實務顯著性 (**practical significance**)，尤其在使用者樣本數較大時 **p** 值容易因樣本量而顯著，效果量可補充判斷差異之實質大小。

若四模型分數呈遞增趨勢，且分群輔助 CF 與其餘三個基準模型之配對比較皆通過校正後之顯著水準，即可回答研究問題 RQ2：「分群輔助之個人化推薦，相較基準模型具有統計上顯著之增量效果」，此為全論文最核心之研究發現。

3.7.4 RQ3 群體間差異之計算方式

為回答研究問題 RQ3「分群輔助帶來之效果提升，是否因投資人群體而異」，規劃計算方式如下：

1. 對每位使用者計算 **Δ 值** = 分群輔助 CF 分數 - 純 ALS baseline 分數 (**Precision@K**、**Recall@K**、**MAP** 各自計算)，代表該使用者因分群輔助獲得之效果提升幅度，而非單純比較各群體之絕對分數高低。
2. 依 3.5 節分群標籤，將使用者之 **Δ 值** 依所屬群體分組。
3. **統計檢定方法之決策準則**：投資交易資料常呈右偏分布 (少數使用者交易頻率／金額遠高於多數人)，故預期採用不要求常態假設之 **Kruskal-Wallis 檢定** (Kruskal & Wallis, 1952) 為主要方法，比較各群體 **Δ 值** 排名是否具顯著差異。實際取得資料後，將先執行常態性檢定 (如 Shapiro-Wilk 檢定；Shapiro & Wilk, 1965)，若 **Δ 值** 分布符合常態假設，則改採統

計檢定力較高之 ANOVA 或 Welch's ANOVA (Welch, 1951)；若不符合常態假設，則維持 Kruskal-Wallis 檢定。

4. 整體檢定顯著時，以對應之事後檢定找出具體哪些群體間差異顯著：無母數情境採 **Dunn's test** (Dunn, 1964)；母數情境依變異數是否同質，採 **Tukey HSD** (Tukey, 1949，變異數同質時)或 **Games-Howell** (Games & Howell, 1976，變異數不同質時)。據此回答「哪一類投資人從分群輔助推薦中受益最多」，作為好好證券未來個人化推薦資源優先分配之實務建議依據（對應第五章實務應用建議）。
5. 效果量（與 3.7.3 節 RQ2 一致之嚴謹度）：整體檢定之效果量，無母數情境 (Kruskal-Wallis) 採 **epsilon-squared** (ϵ^2)，母數情境 (ANOVA/Welch's ANOVA) 採 **eta-squared** (η^2)，衡量群體別對 Δ 值變異之解釋力；事後兩兩比較之效果量，無母數情境 (Dunn's test) 採 **rank-biserial correlation** 或 **Cliff's delta**，母數情境 (Tukey HSD/Games-Howell) 採 **Cohen's d** (Cohen, 1988)。效果量之補充可避免僅因樣本數龐大而使統計檢定達顯著，卻誤判為具實務意義之群體差異，與 3.7.3 節 RQ2 之效果量報告原則一致。

已知之檢定力限制（次要問題，須預先說明）：單一使用者之 Precision@K (K 較小時，如 K=5) 僅能取 0, 1/K, 2/K, ..., 1 等離散值（例如 K=5 時僅有 0、0.2、0.4、0.6、0.8、1.0 六種可能值），使 Δ 值（兩模型分數之差）之離散程度受限，組間統計檢定之檢定力 (statistical power) 可能因此偏低，尤其在 K 較小、使用者測試期購買數量亦少（如本研究常態情境之個位數）時更為明顯。相較之下，MAP 之 Δ 值因涉及排序位置之連續加權，離散程度較低，檢定力相對較高。因此，本研究規劃以 MAP 之 Δ 值作為 RQ3 群體間差異分析之主要依據，Precision@K、Recall@K 之 Δ 值則作為輔助佐證，並於第四章明確揭露此一檢定力限制對結果解讀之影響，必要時可另以較大之 K 值（如 K=20）之 Precision/Recall Δ 值降低離散度作為補充分析。

RQ2、RQ3 群體間差異之統計檢定方法，規劃為一組**決策準則**而非單一定案方法：RQ2 主要依據配對差異分布之常態性檢定結果，於成對 t 檢定與 Wilcoxon 符號等級檢定之間擇一，並統一以 Holm-Bonferroni 校正處理 6 組配對比較；RQ3 主要依據 Δ 值分布之常態性檢定結果，於 Kruskal-Wallis 檢定與 ANOVA/Welch's

ANOVA 之間擇一，並搭配對應之事後檢定。此設計使本研究得以在取得實際資料後，依資料實際分布特性選擇統計檢定力最適當之方法，相關選擇過程與結果將於第四章實驗結果完整記錄。

3.7.5 方法論承諾與待驗證項目

本節所述之訓練／測試集時間切分原則、評估對象範圍界定、Precision@K／Recall@K／MAP 三項評估指標之選用，以及 ground truth 排除訓練期已持有基金之複購紀錄（與 3.6.1 節候選基金池規則一致），係根據推薦系統評估之標準實務、避免資料洩漏之方法論考量，以及四模型指標可比性之要求所作之決策，為本研究之核心承諾，預期不因實際資料結果而調整。複購排除此一範圍界定直接影響第四章全部指標之數值與解讀，故於計畫書階段即明確定義。正式實驗報告之 K 值具體組合、統計檢定與評估指標所採用之實作套件（recmetrics 或 implicit 內建函式）等實作細節，均須待取得實際資料後依規模與套件核對結果確認。

參考文獻

中文文獻

- 工商時報（2026 年 1 月 2 日）。少年股神向前衝 2025 年新增股民 55.18 萬人
總開戶數 1,376.78 萬人寫新高（記者呂淑美）。
<https://www.ctee.com.tw/news/20260102700507-430201>
- 中國時報（2026 年 8 月 18 日）。台股震盪催出投資潮 基金定期定額人數、扣
款筆數雙創新高。<https://www.chinatimes.com/realtimenews/20260818004441-260410>
- 中華民國證券投資信託暨顧問商業同業公會〔SITCA〕（2025 年 9 月 12 日）。
投信投顧公會發布截至 114 年 8 月底境內基金、私募基金及全權委託投資業
務規模〔新聞稿〕。<https://www.sitca.org.tw/CWEB/境內基金新聞稿1140912.pdf>
- 王怡（2023）。推薦系統之應用——以共同基金電子交易平台為例〔未出版碩士
論文〕。東吳大學巨量資料管理學院碩士學位學程。
<https://hdl.handle.net/11296/xaz6j9>
- 自由財經（2021 年 9 月 19 日）。〈財經週報-金融監理沙盒〉基金互換實驗結束
好好投資改制券商（記者王孟倫）。<https://ec.ltn.com.tw/article/paper/1473687>
- 吳忠義（2008）。共同基金投資人投資行為及風險偏好之研究〔未出版碩士論
文〕。國立中央大學財務金融學系。
- 陳一慈（2021）。利用 RFM 模型與購物籃分析進行電子商務顧客分群與銷售策
略之研究〔未出版碩士論文〕。國立政治大學企業管理研究所。
<https://doi.org/10.6814/NCCU202100799>
- 許仲廷（2022）。運用機器學習方法推廣綜合券商大財管業務。數據分析
（Journal of Data Analysis），17(2)，31 - 58。
[https://doi.org/10.6338/JDA.202206_17\(2\).0002](https://doi.org/10.6338/JDA.202206_17(2).0002)

許信輝（2023）。網路關鍵字搜尋行為反映投資人情緒之研究〔未出版博士論文〕。淡江大學財務金融學系。

經濟日報（2025 年 11 月 18 日）。境內基金總規模突破 10.9 兆元創新高 統一投信年規模成長王二連霸（記者廖賢龍）。
<https://money.udn.com/money/story/5618/9146153>

臺灣證券交易所（2026 年 9 月 15 日）。電子式交易統計資訊〔開放資料集，成交月份：114 年 8 月〕。<https://openapi.twse.com.tw/v1/opendata/t187ap19>

鄭天澤、陳莉貞、郭怡君（2021）。2021 基金投資人投資行為與偏好問卷調查分析〔資產管理人才培育與產業發展基金委託專題研究〕。財團法人中華民國證券暨期貨市場發展基金會。https://www.sfi.org.tw/files/1114/f110_2.pdf

鄭婕妤（2010）。基於 RFM 分析法之顧客適性化產品推薦機制〔未出版碩士論文〕。朝陽科技大學資訊管理系。

西文文獻

Aliyev, M., Ahmadov, E., Gadirli, H., Mammadova, A., & Alasgarov, E. (2020). *Segmenting bank customers via RFM model and unsupervised machine learning* (arXiv:2008.08662). arXiv. <https://arxiv.org/abs/2008.08662>

Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3), 307–327.

Caliński, T., & Harabasz, J. (1974). A dendrite method for cluster analysis. *Communications in Statistics*, 3(1), 1–27.

Cardillo, G., & Chiappini, H. (2024). Robo-advisors: A systematic literature review. *Finance Research Letters*, 62, Article 105119. <https://doi.org/10.1016/j.frl.2024.105119>

CFA Institute. (2022). *Enhancing investors' trust: 2022 CFA Institute investor trust study*. CFA Institute. https://www.cfainstitute.org/sites/default/files/-/media/documents/article/Enhancing-Investors-Trust-Report_2022_Online.pdf

Chiou-Wei, S.-Z., & Lee, Y.-T. (2024). Application of KL distance-based intelligent recommendation method to fund recommendation for users with investment

- behavior in Asia region. *Heliyon*, 10(12), Article e32959. <https://doi.org/10.1016/j.heliyon.2024.e32959>
- Chou, Y.-C., Chen, C.-T., & Huang, S.-H. (2022). Modeling behavior sequence for personalized fund recommendation with graphical deep collaborative filtering. *Expert Systems with Applications*, 192, Article 116311. <https://doi.org/10.1016/j.eswa.2021.116311>
- Christy, A. J., Umamakeswari, A., Priyatharsini, L., & Neyaa, A. (2021). RFM ranking – An effective approach to customer segmentation. *Journal of King Saud University – Computer and Information Sciences*, 33, 1251–1257. <https://doi.org/10.1016/j.jksuci.2018.09.004>
- Cohen, J. (1988). *Statistical power analysis for the behavioral sciences* (2nd ed.). Lawrence Erlbaum Associates.
- Davies, D. L., & Bouldin, D. W. (1979). A cluster separation measure. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, PAMI-1(2), 224–227.
- Dunn, O. J. (1964). Multiple comparisons using rank sums. *Technometrics*, 6(3), 241–252.
- Engle, R. F. (1982). Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation. *Econometrica*, 50(4), 987–1007.
- Gambacorta, L., Gambacorta, R., & Mihet, R. (2023). FinTech, investor sophistication, and financial portfolio choices. *Review of Corporate Finance Studies*, 12(4), 834–866. <https://doi.org/10.1093/rcfs/cfad014>
- Games, P. A., & Howell, J. F. (1976). Pairwise multiple comparison procedures with unequal n's and/or variances: A Monte Carlo study. *Journal of Educational Statistics*, 1(2), 113–125.
- Gaspar, R. M., & Oliveira, M. (2024). Robo advising and investor profiling. *FinTech*, 3(1), 102–115. <https://doi.org/10.3390/fintech3010007>
- Hansen, B. E. (1999). Threshold effects in non-dynamic panels: Estimation, testing, and inference. *Journal of Econometrics*, 93(2), 345–368.
- Holm, S. (1979). A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, 6(2), 65–70.

- Hu, Y., Koren, Y., & Volinsky, C. (2008). Collaborative filtering for implicit feedback datasets. *2008 Eighth IEEE International Conference on Data Mining*, 263–272. <https://doi.org/10.1109/ICDM.2008.22>
- Huang, Z. (1997). Clustering large data sets with mixed numeric and categorical values. In *Proceedings of the First Pacific-Asia Conference on Knowledge Discovery and Data Mining* (pp. 21–34). World Scientific.
- Huang, Z. (1998). Extensions to the k-means algorithm for clustering large data sets with categorical values. *Data Mining and Knowledge Discovery*, 2, 283–304.
- International Organization of Securities Commissions [IOSCO] . (2025). *Artificial intelligence in capital markets: Use cases, risks, and challenges* (Consultation Report CR/01/2025). IOSCO.
- International Organization of Securities Commissions Board [IOSCO] . (2021). *The use of artificial intelligence and machine learning by market intermediaries and asset managers* (Final Report FR06/2021). IOSCO. <https://www.iosco.org/library/pubdocs/pdf/IOSCOPD684.pdf>
- Järvelin, K., & Kekäläinen, J. (2002). Cumulated gain-based evaluation of IR techniques. *ACM Transactions on Information Systems*, 20(4), 422–446.
- Kruskal, W. H., & Wallis, W. A. (1952). Use of ranks in one-criterion variance analysis. *Journal of the American Statistical Association*, 47(260), 583–621.
- MacQueen, J. B. (1967). Some methods for classification and analysis of multivariate observations. *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*, 1, 281–297.
- Manning, C. D., Raghavan, P., & Schütze, H. (2008). *Introduction to information retrieval*. Cambridge University Press.
- Miglausch, J. R. (2000). Thoughts on RFM scoring. *Journal of Database Marketing & Customer Strategy Management*, 8(1), 67–72. <https://doi.org/10.1057/palgrave.jdm.3240019>
- Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, 20, 53–65.

- Sanz-Cruzado, J., Droukas, N., & McCreddie, R. (2024). *FAR-Trans: An investment dataset for financial asset recommendation* (arXiv:2407.08692). arXiv. <https://arxiv.org/abs/2407.08692>
- Shah, A., Joshi, A., Sheth, D., Shah, M., & Chawan, P. M. (2022). Mutual fund recommendation system with personalized explanations. *International Research Journal of Engineering and Technology*, 9(9).
- Shapiro, S. S., & Wilk, M. B. (1965). An analysis of variance test for normality (complete samples). *Biometrika*, 52(3–4), 591–611.
- Tan, E. H. L., Hamed, Y., Daud, H., Abdul Wahab, M. A. F., Azhar, A. A. A., & Tan, S. Y. (2025). Profiling investor behavior in the Malaysian derivatives market using K-means clustering. *Frontiers in Artificial Intelligence*, 8, Article 1640776. <https://doi.org/10.3389/frai.2025.1640776>
- Tan, G. K. S. (2020). Robo-advisors and the financialization of lay investors. *Geoforum*, 117, 46–60. <https://doi.org/10.1016/j.geoforum.2020.09.017>
- Thompson, J. R. J., Feng, L., Reesor, R. M., & Grace, C. (2021). Know your clients' behaviours: A cluster analysis of financial transactions. *Journal of Risk and Financial Management*, 14(2), Article 50. <https://doi.org/10.3390/jrfm14020050>
- Thorndike, R. L. (1953). Who belongs in the family? *Psychometrika*, 18(4), 267–276. <https://doi.org/10.1007/BF02289263>
- Tukey, J. W. (1949). Comparing individual means in the analysis of variance. *Biometrics*, 5(2), 99–114.
- Wei, J., & Liu, J. (2025). Personalized fund recommendation with dynamic utility learning. *Financial Innovation*, 11, Article 48. <https://doi.org/10.1186/s40854-024-00720-5>
- Welch, B. L. (1951). On the comparison of several mean values: An alternative approach. *Biometrika*, 38(3–4), 330–336.
- Wu, D., & Li, X. (2025). A systematic literature review of financial product recommendation systems. *Information*, 16(3), Article 196. <https://doi.org/10.3390/info16030196>